



人工智能的发展与应用

从符号推理到大语言模型，再到智能贸易

模块一 | 智能贸易导论·本科高年级·课堂讲义

学习目标与路线图

完成本章后，你能：

1. 用**历史—范式—能力**三条线解释 AI 的演进；
2. 推导感知机、反向传播、注意力与自回归语言模型的核心公式；
3. 区分 LLM 的**预训练、对齐、推理、工具使用**；
4. 从生产率、就业、信息生态与治理理解其“深远”影响；
5. 把技术机制映射到智能贸易的询盘、履约、风控与决策。

概念

数学

实验

案例

批判性讨论

开场问题：AI 到底改变了什么？

旧范式：软件执行规则

人写规则 → 机器重复执行。规模优势来自复制与自动化。

新范式：模型学习分布

数据与目标 → 参数化模型。能力来自预测、生成与适应。

当“语言”成为通用人机接口，知识工作也开始模块化。

本章结构：四个尺度



贯穿问题：能力提升是否必然转化为社会福利？

01

人工智能的概念、边界与历史

什么是人工智能 (Artificial Intelligence, AI)?

操作性定义

使计算系统能够完成通常与人类智能相关的任务：学习、推理、问题求解、感知与决策。

研究目标


学习 | 推理 | 知识表示 | 规划 | 自然语言 | 感知 | 机器人

主要方法

搜索与优化 | 形式逻辑 | 概率统计 | 神经网络 | 运筹与经济学


来源: Wikipedia, "Artificial intelligence", accessed 2026-08-30, CC BY-SA 4.0.

智能 (Intelligence) 不是单一刻度



同一系统可以在翻译上超人、在常识校验上脆弱。评价必须说明：**任务、环境、指标、成本、风险。**

AI、机器学习与深度学习的关系



- ▶ 人工智能 (Artificial Intelligence, AI) 是最外层研究领域;
- ▶ 机器学习 (Machine Learning, ML) 是通过数据学习规律的方法族;
- ▶ 深度学习 (Deep Learning, DL) 是使用多层神经网络的机器学习分支;
- ▶ 大语言模型 (Large Language Model, LLM) 通常建立在深度学习与 Transformer 之上。

来源: Wikipedia/Wikimedia Commons, 用户提供图片; CC BY-SA, 访问 2026-08-30。

弱 AI、通用 AI 与超级智能

类别	能力范围	判断重点
狭义/弱 AI	特定任务或领域	可验证性能与边界
AGI	广泛认知任务可迁移	定义与测量尚无共识
超级智能	多数认知活动显著超越人类	主要是前瞻性风险概念

能力强 ≠ 有意识；语言流畅 ≠ 理解已被证明。

来源：Russell & Norvig (2021); Wikipedia (2026).

图灵测试：行为标准与局限

若询问者仅凭对话无法稳定区分机器与人，机器是否“会思考”？

$$\Pr(\hat{Y} = \text{human} \mid Y = \text{machine}) \geq \tau$$

- ▶ 优点：把形而上问题转为可观察行为；
- ▶ 局限：奖励模仿，不能证明真实理解、可靠性或价值一致；
- ▶ 今日转向：任务基准、鲁棒性、校准、成本与安全的多维评测。

AI 的三条思想谱系 (Schools of Thought)

符号主义

知识 = 符号 + 规则

优势：可解释

弱点：知识工程瓶颈

连接主义

知识 = 权重分布

优势：表征学习

弱点：难解释

行为/强化


智能 = 行动策略

优势：闭环学习

弱点：奖励错设

现实系统越来越多地采用**混合架构**。

具身交互案例：Kismet 情感机器人




来源：Wikimedia Commons, Kismet robot head; 用户提供图片。

Kismet 是 1990 年代研制的社会机器人 (Social Robot)，通过面部结构、视觉与控制系统识别并模拟情绪表达。

它提示我们：智能不仅是计算答案，也包括**感知 (Perception)**、**行动 (Action)** 与**社会互动 (Social Interaction)**。

时间轴：从计算到生成



关键不是一条直线，而是**算法 × 数据 × 算力 × 制度需求**的共振。

来源：Wikipedia, "Artificial intelligence" and "History of artificial intelligence" (2026).

第一次浪潮：搜索 (Search) 与符号推理 (Symbolic Reasoning)


状态空间搜索：给定初态 s_0 、动作集 A 、转移 T 与目标 G ，寻找

$$\pi^* = \arg \min_{\pi: s_0 \rightarrow G} \sum_{a \in \pi} c(a).$$

启发式搜索 A^* ： $f(n) = g(n) + h(n)$ 。若 $h(n)$ 不高估剩余成本，则可保证最优性。

贸易例子：运输路径、装箱、报关规则校验，本质上都含搜索与约束满足。

专家系统 (Expert System): 把经验写成规则



瓶颈：规则冲突、例外爆炸、环境变化。**能解释但难扩展。**

AI 寒冬：为什么乐观反复破灭？

- ▶ 组合爆炸：问题规模增长，搜索空间指数膨胀；
- ▶ 常识瓶颈：现实知识难以穷举编码；
- ▶ 算力与数据不足；
- ▶ 演示系统与生产环境之间存在“最后一公里”。

历史教训

把基准进步外推为通用能力，往往忽略部署成本、外部性与制度适配。

第二次浪潮：统计学习 (Statistical Learning)

从“写规则”到“从样本估计函数”：

$$\hat{f} = \arg \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i) + \lambda \Omega(f).$$

经验风险衡量拟合，正则项控制复杂度。学习的核心是**泛化**而非记忆。

回归误差可分解为

$$\mathbb{E}[(Y - \hat{f}(X))^2] = \sigma^2 + \text{Bias}^2[\hat{f}(X)] + \text{Var}[\hat{f}(X)].$$

模型太简单：高偏差；模型太灵活：高方差。深度学习通过数据规模、正则化和优化改变了传统权衡，但没有消除分布外风险。

第三次浪潮：深度学习（Deep Learning）的共振

数据

互联网与传感器

算力

GPU/云计算

算法

反向传播与架构

Wikipedia 将 2012 后的跃迁归因于 GPU 加速与大规模训练数据；2017 Transformer 进一步加速了生成式 AI。

来源：Wikipedia, "Artificial intelligence", sections History and Deep learning (2026).

从判别到生成

判别模型

学习 $p(y | x)$

回答 “这是什么/会怎样?”

分类、评分、预测

生成模型

学习 $p(x)$ 或 $p(x | c)$

回答 “可能的数据长什么样?”

文本、图像、音频、代码

生成不是数据库检索，而是从学习到的分布中**条件采样**。

02

机器学习与神经网络：从损失函数到表征

监督学习 (Supervised Learning) 的最小闭环



训练是优化；测试是检验泛化；部署是面对分布变化。

线性模型 (Linear Model): 最简单的可学习机器

$$\hat{y} = \mathbf{w}^\top \mathbf{x} + b, \quad \mathcal{L}(\mathbf{w}, b) = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2.$$

闭式解 (可逆时): $\hat{\beta} = (X^\top X)^{-1} X^\top y$.

经济解释: 参数是边际相关关系; 预测准确不等于因果识别。

逻辑回归 (Logistic Regression): 概率与决策边界


$$p(y = 1 \mid x) = \sigma(z) = \frac{1}{1 + e^{-z}}, \quad z = w^\top x + b$$

交叉熵:

$$\mathcal{L} = - \sum_i [y_i \log p_i + (1 - y_i) \log(1 - p_i)].$$

风控评分从概率到行动仍需阈值 τ : 误拒与漏放体现不同社会成本。

神经元 (Neuron) 与感知机 (Perceptron)



$$\hat{y} = \sigma(\sum_j w_j x_j + b)$$

为什么要“深”？

多层复合：

$$f_{\theta}(x) = f^{(L)} \left(f^{(L-1)} (\dots f^{(1)}(x)) \right).$$

低层捕捉局部模式，高层组合成抽象概念。深度带来高效表征，也带来不可解释性、优化不稳定与数据依赖。

来源：Wikipedia, “Artificial intelligence” , Deep learning (2026).

反向传播 (Backpropagation): 链式法则的工程化

若 $z = wx + b$, $a = \sigma(z)$, $\mathcal{L} = \ell(a, y)$, 则

$$\frac{\partial \mathcal{L}}{\partial w} = \frac{\partial \mathcal{L}}{\partial a} \frac{\partial a}{\partial z} \frac{\partial z}{\partial w}.$$

梯度下降: $\theta_{t+1} = \theta_t - \eta \nabla_{\theta} \mathcal{L}(\theta_t)$ 。

课堂检查: η 过大或过小分别会怎样?

表示学习 (Representation Learning): 特征不再全部手工设计

传统管线: 原始数据 $\rightarrow$ 人工特征 $\rightarrow$ 模型。

深度学习: 原始数据 $\rightarrow$ **可学习表征** $h_\theta(x)$ $\rightarrow$ 任务头。

$$\min_{\theta, \phi} \sum_i \ell(g_\phi(h_\theta(x_i)), y_i).$$

迁移学习使同一底座服务多任务, 是“基础模型”的技术前提。

卷积、循环与注意力：归纳偏置

架构	假设	适合
CNN	局部性、平移共享	图像、网格数据
RNN/LSTM	序列递归、状态记忆	时序、早期 NLP
Transformer	任意位置可直接交互	文本、多模态、长依赖

架构不是“更聪明”的魔法，而是对数据结构施加不同先验。

自监督从数据自身构造标签：遮住词让模型猜，或根据前文预测下一个词。

$$\mathcal{L}_{\text{CLM}} = - \sum_{t=1}^T \log p_{\theta}(x_t \mid x_{<t}).$$

海量未标注文本因此可以转化为训练信号。

强化学习 (Reinforcement Learning): 从反馈中学策略

马尔可夫决策过程 $\langle S, A, P, R, \gamma \rangle$:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t r_t \right].$$

奖励定义了“好”，但代理指标可能被钻空子。对齐问题首先是**目标设计问题**。

过拟合、数据泄漏与分布漂移

- ▶ 过拟合：训练误差低、测试误差高；
- ▶ 泄漏：未来或标签信息进入特征；
- ▶ 漂移： $p_{train}(x, y) \neq p_{deploy}(x, y)$ ；
- ▶ 反馈回路：模型决策改变未来数据。

贸易风控中，制裁名单、欺诈策略与市场制度持续变化，部署后监控不可省略。

评价：不只看准确率

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}.$$

还要衡量校准、鲁棒性、公平性、延迟、能耗与单位任务成本。

决策原则

指标权重必须来自业务损失与公共价值，而不是只追排行榜。

03

大语言模型：从 Token 到 Transformer

语言模型 (Language Model) 在做什么？

对序列联合概率作链式分解：

$$p(x_{1:T}) = \prod_{t=1}^T p(x_t \mid x_{<t}).$$

给定上下文，模型输出下一个 token 的概率分布；重复采样形成文本。

“预测下一个词” 很简单；在海量任务上把它做好并不简单。

词元 (Token): 模型眼中的基本单位

一句话先被分割为子词/字节单元:

“智能贸易正在重塑全球价值链” $\rightarrow (t_1, t_2, \dots, t_m)$.

词表 V 决定输入输出空间。中文、数字、代码的 token 化效率会影响上下文成本与模型表现。

嵌入 (Embedding): 把符号映射到几何空间

每个 token i 对应向量 $e_i \in \mathbb{R}^d$ 。相似语境使向量靠近:

$$\cos(e_i, e_j) = \frac{e_i^\top e_j}{\|e_i\| \|e_j\|}.$$

语义成为高维空间中的方向与距离, 但几何相似并不自动等于事实正确。

位置信息：顺序不能丢

Transformer 并行处理 token，需要加入位置表示：

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d}), \quad PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d}).$$

输入为 $h_i^{(0)} = e_i + PE_i$ 。

来源：Vaswani et al. (2017), "Attention Is All You Need" .

自注意力 (Self-attention): 让每个词 “看” 其他词

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V.$$

$QK^\top$ 衡量相关性; softmax 形成权重; 加权 V 聚合信息。

手算注意力：一个微型例子

若某 token 对三个位置的缩放分数为 $(2, 1, 0)$ ，则

$$\alpha = \text{softmax}(2, 1, 0) \approx (0.665, 0.245, 0.090).$$

输出 $z = 0.665v_1 + 0.245v_2 + 0.090v_3$ 。


思考：温度升高后，权重更尖锐还是更平坦？

多头注意力 (Multi-head Attention): 同时学习多种关系

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W_O.$$

不同头可捕捉句法、指代、位置与主题等关系。其解释应谨慎：注意力权重不是完整因果解释。

Transformer 块



堆叠多层后，每个 token 的表示逐步融合上下文。2017 年论文用纯注意力替代递归，显著提高并行性。

来源：Vaswani et al. (2017).

为何 Transformer 能规模化？

- ▶ 训练时可并行处理序列位置；
- ▶ 任意两位置路径长度为常数；
- ▶ 架构统一，易迁移到图像、语音与多模态；
- ▶ 代价：标准注意力时间/显存约为 $O(n^2)$ 。

来源：Vaswani et al. (2017); Wikipedia (2026).

预训练 (Pre-training): 压缩语料中的统计结构

$$\theta^* = \arg \min_{\theta} - \sum_{x \in \mathcal{D}} \sum_t \log p_{\theta}(x_t \mid x_{<t}).$$

为了降低损失，模型需要学习语法、风格、事实关联与某些任务规律。参数是分布式压缩，不是可逐条审计的知识库。

规模规律：更多并非无限更好

经验上，损失常随计算量 C 呈幂律下降：

$$L(C) \approx L_{\infty} + aC^{-\alpha}.$$

规模化带来可预测改进，但边际收益递减，并受数据质量、架构、推理计算与能源约束。

指令微调 (Instruction Tuning): 从续写器到助手

输入 “任务指令—理想回答” 样本, 优化

$$\mathcal{L}_{SFT} = - \sum_t \log p_{\theta}(y_t \mid x, y_{<t}).$$

它改变行为分布, 却不保证事实性、安全性或价值一致。

人类反馈强化学习 (RLHF) 与对齐 (Alignment)



偏好数据反映标注者与制度的价值选择；“有帮助、诚实、无害”之间可能冲突。

采样：温度控制随机性

$$p_i(T) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}.$$

$T \downarrow$: 更确定、更重复; $T \uparrow$: 更多样、更冒险。Top- p 仅在累计概率达到 p 的最小候选集中采样。

业务文书通常低温; 创意探索可适度升温。

上下文窗口与“工作记忆”

模型只直接看到窗口内 token。长上下文不等于完美记忆：信息可能被忽略、位置敏感，成本也增长。

工程策略

分块、摘要、检索、结构化状态、外部数据库与任务分解。

检索增强生成 (Retrieval-Augmented Generation, RAG)

$$d^* = \arg \max_{d \in \mathcal{D}} \text{sim}(q, d), \quad y \sim p_{\theta}(y \mid q, d^*).$$

提问 → 检索 → 重排 → 带证据生成 → 引用核验

RAG 降低知识陈旧，但不能自动消除错误检索与错误归因。

工具调用 (Tool Use) 与智能体 (Agent)

LLM 生成的不只是文本，也可生成结构化动作：

observe $\rightarrow$ plan $\rightarrow$ act(tool) $\rightarrow$ observe $\rightarrow$...

贸易智能体可查询运价、核验 HS 编码、计算关税、生成单证。新增风险：权限越界、提示注入、级联错误。

为什么会产生幻觉 (Hallucination)?

训练目标奖励**高概率续写**，不是“只说可验证事实”。

- ▶ 语料矛盾或稀缺；
- ▶ 提示诱导模型填补空白；
- ▶ 解码随机性；
- ▶ 模型缺乏可靠的“不知道”机制。

对策：检索、工具、引用、约束输出、人工复核与不确定性沟通。

多模态生成模型

文本、图像、音频、视频映射到共享或可对齐的表示空间。

自回归

逐 token 生成，适合离散序列。

来源：Wikipedia, "Artificial intelligence", Generative AI (2026).

扩散模型

从噪声逐步去噪，常用于图像/视频。

扩散模型：从噪声恢复数据

前向过程逐步加噪：

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t}x_{t-1}, \beta_t I).$$

神经网络学习预测噪声 $\epsilon_\theta(x_t, t, c)$ ，反向采样生成条件 c 下的新样本。

LLM 的能力边界

擅长	需要警惕
改写、摘要、模式迁移	事实与引用核验
代码草拟与解释	长链条可靠性
自然语言交互	分布外问题
多方案快速探索	隐私、版权、偏见

正确心智模型：**高带宽的概率型协作者，而非全知数据库。**

04

生成式 AI 的商业价值与智能贸易应用

$$\text{Net Value} = \Delta R + \Delta C + \Delta Risk - (C_{model} + C_{integration} + C_{governance}).$$

收入增长、成本节约、风险改善必须扣除模型、集成、审核和治理成本。POC 成功不等于规模化回报。

价值来自“任务”而非“岗位”

一个岗位包含任务集合 $J = \{j_1, \dots, j_m\}$ 。AI 对不同任务的影响不同：

$$T = \sum_j t_j, \quad T' = \sum_j (1 - a_j) t_j + \sum_j v_j.$$

a_j 是节省比例， v_j 是验证与协调新增时间。岗位重构取决于两者净效应。

四类价值机制

自动化

减少重复劳动：翻译、录入、归档

增强

辅助判断：合同审阅、市场研究


个性化

低成本多版本：营销、客服

创新

缩短试验周期：产品、流程、商业模式

智能贸易价值链地图



LLM 是语言层；预测模型是决策层；API/机器人是执行层；治理贯穿全链条。

场景一：多语言营销与客户开发

- ▶ 把产品参数转成不同市场的本地化卖点；
- ▶ 批量生成邮件、落地页与社媒内容；
- ▶ 从询盘抽取意图并排序商机。

控制点：品牌语调、文化禁忌、虚假承诺、客户数据合规。

场景二：合同与贸易合规

RAG 连接合同模板、Incoterms、制裁与海关资料，输出“条款—风险—证据”。

$$\text{Risk Score} = \sum_k w_k I(\text{clause}_k \text{ triggered}).$$

高风险结论必须由法务/合规人员确认；模型不能替代正式法律意见。

场景三：需求预测与库存

LLM 适合处理文本信号，时间序列模型负责数量预测：

$$y_t = \mu + s_t + \beta^\top x_t + \varepsilon_t.$$

x_t 可包含由新闻、评价、询盘抽取的情绪与主题。真正价值来自多模态信号融合。

场景四：智能客服与售后

意图识别 → 知识检索 → 答案生成 → 置信度门控 → 人工升级

关键指标：首次解决率、平均处理时长、引用正确率、升级率、客户满意度。


应用成熟度：Copilot 到 Autopilot

1. 草拟：人发起、人核验；
2. 协作：模型建议，系统内完成；
3. 编排：跨工具执行，人审批关键节点；
4. 自主：限定域内闭环，持续监控与可回滚。

越接近资金、合规和客户承诺，越需要**人在回路**。

组织采用：技术只是 20%？

规模化需要五层共同变化：数据、流程、系统、人才、治理。



从试点到规模化：实验设计

比较处理组与对照组：

$$\widehat{ATE} = \bar{Y}_1 - \bar{Y}_0.$$

预先定义质量、速度、风险与学习曲线；避免只测“完成更快”而忽略返工和错误外部性。

05

深远影响：生产率、劳动、信息与权力

社会影响的四层框架

层级	核心问题
个人	能力、隐私、认知依赖与意义
组织	工作流、控制权、责任与收益分配
市场	竞争、平台化、进入壁垒与劳动重组
社会	信息生态、民主治理、安全与代际风险

生产率悖论：能力提升为何不立刻进 GDP？

通用技术需要互补投资：流程重构、技能、数据和制度。短期常出现“J 曲线”：先投入、后收获。

$$Y = A F(K, L), \quad \Delta \ln Y \approx \Delta \ln A + \alpha \Delta \ln K + (1 - \alpha) \Delta \ln L.$$

AI 对 A 的贡献可能被测量误差与无形资本投入暂时遮蔽。

加速增长

AI 提高研发生产率，形成“创新—自动化—再创新”正反馈，增长率可能显著上升。

来源：Jones (2026), “AI and Our Economic Future”, pp. 1–7.

照常增长

弱环节、互补任务与扩散时滞限制加速，AI 只是维持长期约 2% 增长的新通用技术。

任务模型：自动化与弱环节

CES 聚合任务：

$$Y = \left[\int_0^1 y(i)^{\frac{\sigma-1}{\sigma}} di \right]^{\frac{\sigma}{\sigma-1}}.$$

当 $\sigma < 1$ ，任务互补，最薄弱环节限制整体产出；只自动化少数任务的收益有限。

来源：Jones (2026), based on task-based growth models.

无限自动化的上限公式


若初始 GDP 份额 s 的任务生产率趋于无穷, Jones 给出产出倍数:

$$M(s, \sigma) = (1 - s)^{\frac{\sigma}{\sigma-1}}.$$

当 $\sigma = 0.2$ 、 $s = 0.5$, $M \approx (0.5)^{-0.25} \approx 1.19$: 自动化一半任务, GDP 仅增约 19%。

来源: Jones (2026), Figure 2 and accompanying discussion.

复现 Jones 图 2：弱环节的非线性



来源：根据 Jones (2026), Figure 2 公式重绘； $\sigma = 0.2$.

“深远” 不等于 “立刻爆发”

Jones 的关键判断：正反馈可以加速增长，但大量薄弱环节必须先被自动化，宏观跃迁可能延迟数十年。

时间尺度决定叙事：企业季度、职业十年、增长百年。

来源：Jones (2026), conclusion.

就业：暴露度不等于失业

任务暴露衡量 “AI 能影响多少工作内容”，不是净就业变化：

$$\Delta L = \underbrace{-L_{sub}}_{\text{替代}} + \underbrace{L_{scale}}_{\text{规模效应}} + \underbrace{L_{new}}_{\text{新任务}} + \underbrace{L_{comp}}_{\text{互补}}$$


工资和就业取决于产品需求、组织重构、技能供给与制度。

报告将 Claude 对话中的任务使用映射到职业，构造 “observed exposure”。其重要性在于：**从可做什么转向实际在做什么。**

- ▶ 97% 的观察任务落在既有理论暴露分类范围；
- ▶ 职业之间的实际覆盖高度不均；
- ▶ 聚合失业率尚不足以给出简单因果结论。


来源：Anthropic Economic Index, “Labor market impacts of AI: A new measure and early evidence” (report v16), Figures 1–7.

职业类别：理论能力与观察使用



来源：Anthropic Economic Index report v16, Figure 2; 用户提供图片。蓝色为理论覆盖，红色为观察覆盖。

报告图示：理论能力 $\neq$ 观察暴露



来源：教学示意图；概念依据 Anthropic Economic Index report v16, Figures 1-3；非原始数值复刻。

早期劳动力证据：应该怎样读？


报告发现高观察暴露与较弱的职业就业增长预测相关；每增加 10 个百分点覆盖，BLS 预测增长约低 0.6 个百分点。对年轻劳动者的部分指标出现差异，但证据仍早期。

相关性不是因果；使用数据还存在平台用户、任务记录和职业映射的选择偏差。

来源：Anthropic Economic Index report v16, Figures 4–7 and limitations.

BLS 就业增长预测与观察暴露


BLS projected employment growth from 2024–2034 vs. AI exposure



来源: Anthropic Economic Index report v16, Figure 4; BLS 2024–2034 预测。斜率 -6.07 , $R^2 = 0.027$ 。

高暴露与零暴露劳动者的失业率趋势


Trends in unemployment rate for workers with high AI exposure and no AI exposure



来源: Anthropic Economic Index report v16, Figure 6。虚线标示 ChatGPT 发布; 合并事后估计 +0.0020 (SE 0.0019)。

青年劳动者的新工作开始率

New job starts among workers age 22-25 in occupations with high and no AI exposure



来源: Anthropic Economic Index report v16, Figure 7。22-25 岁劳动者; 合并事后估计 -14.3 (SE 7.2)。

技能偏向还是任务偏向？

技能偏向技术变革强调高技能溢价；任务框架区分替代与互补。LLM 可能同时：

- ▶ 压低部分例行认知任务价值；
- ▶ 提升领域专家的覆盖范围；
- ▶ 帮助新手追赶，也可能扩大顶尖者的杠杆；
- ▶ 创造验证、编排、治理和人际服务新任务。

信息生态：生成成本趋近于零

当内容边际成本下降，稀缺资源转为**可信度、注意力与来源**。

净信息价值 = 相关性 × 可信度 - 核验成本.

深度伪造、规模化操纵与个性化说服提高社会验证成本。

来源: Wikipedia, "Artificial intelligence", Misinformation and deepfakes (2026).

群体公平指标之一：机会均等

$$P(\hat{Y} = 1 \mid Y = 1, A = a) = P(\hat{Y} = 1 \mid Y = 1, A = b).$$

不同公平定义通常不能同时满足。选择指标是规范判断，需要受影响群体参与。

隐私：模型链条中的四个泄露面

1. 训练数据未经授权；
2. 提示中上传客户或合同机密；
3. 检索系统权限配置错误；
4. 输出泄露记忆或推断的敏感信息。

原则：最小化、分级、脱敏、权限隔离、留痕与删除机制。

知识产权：输入、模型与输出三层

需要分别判断训练材料许可、模型服务条款、输出的可保护性与侵权风险。跨境使用还叠加不同法域。

课堂原则

不要把“模型生成”误认为“权利清洁”；保留来源、提示、人工修改与审核记录。

大模型依赖算力、数据中心、芯片、云与分发渠道，可能强化规模经济和平台集中。

$$AC(q) = \frac{F}{q} + c,$$

高固定成本 F 使平均成本随规模下降。开源模型、专用小模型与公共算力可改变竞争结构。


来源：Wikipedia, "Artificial intelligence", Dominance by tech giants (2026).

环境影响 (Environmental Impact): 全生命周期核算

$$E_{total} = E_{train} + N_{infer}e_{infer} + E_{hardware} + E_{cooling}.$$

应报告任务单位能耗、碳强度、硬件利用率与替代效应，而非只比较单次查询。

AI 与数据中心电力需求 (Power Demand)



来源: Wikipedia/Wikimedia Commons, 用户提供图片; 美国数据中心已建与在建容量, 更新至 2025-11-26。

Jones 将风险分为滥用/事故等现实风险，以及先进 AI 失控的灾难性风险。即使概率不确定，若损失极大，期望损失仍可能显著：

$$\mathbb{E}[L] = p \times L.$$

来源：Jones (2026), sections on AI risks and cost-benefit reasoning.


竞赛困境：个体理性、集体风险

若每个主体都担心“减速即落后”，安全投资可能低于社会最优。可建模为外部性：

$$\max_{s_i} B_i(s_i) - C_i(s_i) - \underbrace{D(S)}_{\text{部分由他人承担}} .$$

治理需要共同标准、审计、事故报告与国际协调。

负责任 AI：风险与收益一起设计



责任不能只交给“模型团队”；业务所有者、数据方、法务、用户与管理层共同承担。

06

课堂综合：判断、设计与迁移

案例讨论：AI 外贸业务员

某企业让智能体自动筛选客户、生成报价、承诺交期并发送邮件。

1. 哪些环节可自动执行，哪些必须审批？
2. 需要接入哪些可信数据源？
3. 错价、泄密、歧视与制裁违规由谁负责？
4. 用什么指标判定试点成功？

设计练习：画出你的 AI 工作流

请选一个贸易任务，填写：

模块	你的设计
输入与权限	数据来自哪里？谁能看？
模型与工具	LLM、检索、预测或 API？
输出与阈值	何时自动，何时升级？
验证与追责	如何留痕、抽检、回滚？

辨析题：五个常见误区

1. 参数越多，所有任务必然越好；
2. 有引用就一定真实；
3. 暴露度高就会大量失业；
4. 自动化一半任务，GDP 会翻倍；
5. 模型是中性的，偏见只来自用户。

请逐项用本章概念反驳，并给出条件化表述。

知识检查：公式连线

公式	它回答的问题
$\prod_t p(x_t \mid x_{<t})$	如何生成语言？
$\text{softmax}(QK^\top / \sqrt{d})V$	如何聚合上下文？
$\sum \gamma^t r_t$	如何从反馈学行动？
$(1 - s)^{\sigma/(\sigma-1)}$	自动化收益为何非线性？

本章结论：六句话带走

1. AI 是多目标、多方法的工程与科学领域；
2. 深度学习的跃迁来自数据、算力与算法共振；
3. LLM 通过自监督学习语言分布，Transformer 是核心架构；
4. 生成能力强大，但概率生成不等于事实保证；
5. 商业价值来自任务重构与互补资产，不只来自模型；
6. 社会影响取决于扩散速度、弱环节、权力结构与治理选择。

与模块一后续内容的连接



下一章问题：数字化交易何时升级为“感知—决策—执行—学习”的智能闭环？

参考文献 (核心)

-  Wikipedia contributors. Artificial intelligence. 2026.
https://en.wikipedia.org/wiki/Artificial_intelligence
-  Vaswani, A. et al. Attention Is All You Need. NeurIPS, 2017.
-  Jones, C. I. AI and Our Economic Future. 2026. (用户提供 PDF)
-  Anthropic Economic Index. Labor Market Impacts of AI: A New Measure and Early Evidence, report v16. (用户提供 PDF)
-  Russell, S.; Norvig, P. Artificial Intelligence: A Modern Approach, 4th ed., 2021.
-  LeCun, Y.; Bengio, Y.; Hinton, G. Deep learning. Nature, 2015.

图表与素材来源说明

- ▶ 课件内技术结构图、流程图和示意图均用 TikZ/PGFPlots 原创绘制；
- ▶ Jones Figure 2 根据论文公式与参数重绘，并在页内明确标注；
- ▶ Anthropic Economic Index 的劳动力市场图为概念性课堂示意，不冒充原始数值复刻；
- ▶ 深圳大学视觉依据学校官网：校旗以“荔枝红”为标准色；校徽标识版权与使用应遵守校方规范；
- ▶ Wikipedia 内容按 CC BY-SA 署名，访问日期 2026-08-30。

谢谢

问题、质疑与应用设想