



AI 工具及大模型的性能比较

主流大模型产业图谱、Agent 工具体系与第三方评测机制

模块二 | 第二讲 | 面向非计算机专业学生

学习目标 (Learning Objectives)

1. 说清主流大模型厂商的产业格局、公司背景与商业模式，判断其开放策略与供应风险。
2. 梳理大模型与 AI Agent 的发展史，理解每个阶段解决了上一阶段的什么瓶颈。
3. 掌握大模型的分类维度（模态、架构、开放程度、规模、价格层级）并能为任务选类。
4. 认识主流第三方评测机构（LMArena、Artificial Analysis、HELM、Epoch AI、SEAL、OpenCompass、SuperCLUE 等）的评测机制。
5. 正确解读榜单与价格表，识别数据污染、口径差异与性价比拐点。
6. 能用“性能—价格”与“总拥有成本”框架完成一次模型选型的论证。

本讲路线图：十一节，从产业到选型

节	主题	回答的问题
1	比较坐标系	为什么“最强”不等于“最合适”？
2	产业图谱与公司背景	谁在做模型，靠什么赚钱，开放还是封闭？
3	大模型发展史	从 Transformer 到推理模型，经历了哪些范式？
4	Agent 发展史与工具	从“会说话”到“会干活”是怎么发生的？
5	大模型分类学	面对一个任务，应该选哪一类模型？
6	第三方评测机构	谁在评测，用什么机制，最新结果如何？
7	评测方法论与陷阱	怎样读榜才不会被误导？
8	价格体系与成本工程	每百万 token 单价如何变成每次任务的成本？
9	分方向横向评测	十三个细分方向，各自的最优区间在哪里？
10	选型方法论	如何做出可论证、可复核的选型决策？
11	实训、风险与总结	动手比较一次，并知道结论的边界。

01

能力、成本与风险：建立比较的坐标系

三个采购视角：能力、成本与风险

选模型不是选“最强的”，而是在约束条件下选“最合适的”。

- ▶ **能力 (Capability)**：峰值水平、稳定性、上下文长度、工具使用与多模态能力。
- ▶ **成本 (Cost)**：单价、词元效率、重试率，以及延迟带来的间接成本。
- ▶ **风险 (Risk)**：幻觉、合规、数据出境、供应商锁定与停服风险。

关键术语 Key Terms

基准测试 Benchmark

帕累托前沿 Pareto Frontier

总拥有成本 TCO

幻觉 Hallucination

💡 例 Example | 同一份合同抽取任务：旗舰档的单次成本可能是轻量档的 10 倍以上，而准确率差距常常只有几个百分点 (示意)。花多少钱，取决于这项任务失败一次的代价。

模型不是标准商品

■ 同一基座模型在不同“外壳”下，实测表现可能相差数十个百分点。

- ▶ 基座模型 (Base Model) 只提供生成与判断能力。
- ▶ 外壳 (Harness) 决定提示结构、工具、检索、重试与校验方式。
- ▶ 因此榜单上的模型分数不能直接等同于某个产品的能力。
- ▶ 比较时必须先声明：比的是模型，还是比的是产品与系统。

关键术语 Key Terms

基座模型 Base Model


外壳 Harness

智能体 Agent

工具调用 Tool Calling

📊 公式 Formula | 任务价值 $V = \Delta A \times N - \Delta C \times N$: 能力提升 ΔA 要乘以使用频次 N 才成为价值，成本差距同样被频次放大。高频任务对单价敏感，低频任务对能力敏感。

比较的四个层次：越往下越接近真实体验



同一模型可以在不同层次上得出完全不同的结论：比较前先确认层次

“ 榜一” 为什么不等于“ 适配”

■ 榜单衡量的是平均能力，而你的任务有具体约束。

- ▶ 榜单样本多为通用知识与竞赛题，与你的任务分布不同。
- ▶ 排名差距在统计误差内时，不应视为能力差异。
- ▶ 价格、延迟、上下文、数据合规可能比 1-2 个百分点更关键。
- ▶ 正确用法：用榜单做候选集筛选，用自建评测做最终决策。

关键术语 Key Terms

数据污染 Data Contamination

置信区间 Confidence Interval

黄金样本 Golden Set

候选集筛选 Shortlisting

💡 例 Example | 两个模型相差 1 分、置信区间却相互重叠时，把预算投在提示工程与检索质量上，通常比“ 换一个更强的模型” 回报更高。

能力—价格帕累托前沿

真正的问题不是“谁最强”，而是“在给定预算下谁最强”。

- ▶ 把每个模型的“能力得分”与“每百万词元价格”画在同一张图上。
- ▶ 帕累托前沿（Pareto Frontier）上的模型，是无法在不牺牲另一维的情况下改进的。
- ▶ 前沿下方的模型通常没有存在理由，除非有延迟、合规或部署约束。
- ▶ 实际选型常在“前沿拐点”附近：能力接近峰值而价格低一个数量级。

关键术语 Key Terms

帕累托最优 Pareto Optimal


性价比拐点 Knee Point

单位成本能力 Capability per Dollar

权衡 Trade-off

候选模型清单 → 画在能力—价格图上 → 只保留前沿点 → 自建样本验证

示意：能力—价格散点与帕累托前沿（方法论示意，非真实数据）




真实数据：智能指数 vs 每任务成本（Artificial Analysis）

Intelligence Index vs. Cost per Intelligence Index Task

Artificial Analysis Intelligence Index - Weighted average cost (USD) per Artificial Analysis Intelligence Index task

28 of 673 models



横轴为每任务成本（对数刻度，USD），纵轴为智能指数。左上方绿色区域为“最受关注象限”，虚线为帕累托前沿——越靠左上，性价比越高。

来源：Artificial Analysis: Intelligence Index vs. Cost per Intelligence Index Task。截图快照 2026-09；图为该机构榜单原始标注，引用时请注明机构与日期。

本讲的阅读约定与数据口径

■ 本讲所有数字都带“保质期”，方法比结论更耐用。

- ▶ 数据快照为 2026 年 9 月，来源标注在页面下方，均取自公开渠道。
- ▶ 价格与榜单排名变动频繁，任何结论都必须在使用前复核一次。
- ▶ 涉及厂商自述与第三方实测时，会明确区分。
- ▶ 页面中未获取到可靠来源的数据，会标注“待核实”而不估算填充。

关键术语 Key Terms

快照日期 Snapshot Date

厂商自述 Vendor-reported

第三方实测 Third-party Measured

可复现性 Reproducibility

⚠ 提示 Tip | 可复制的引用模板：「据〈机构〉〈日期〉榜单，配置为〈是否开启推理/工具〉，样本量〈N〉；本结论适用于〈任务类型〉，不适用于〈边界〉。」

02

谁在做模型：从算力芯片到应用的五层结构

产业分层：从算力芯片到终端应用（Industry Stack）

应用层 Application | 办公文档、编程助手、搜索问答、客服、图像视频创作等终端产品

工具与框架层 Tooling | Agent 编排框架、Agent SDK、MCP 协议、向量数据库、评测与可观测平台

基础模型层 Foundation Models | 闭源前沿实验室、开放权重阵营、云厂商自研模型

云与算力层 Cloud & Compute | GPU/TPU 集群、训练基础设施、推理服务与调度

芯片与硬件层 Silicon | NVIDIA、AMD、Google TPU、AWS Trainium、华为昇腾等

判断依据：越靠下越集中、越靠上越分散；投资的稀缺性集中在下三层，利润的想象力集中在上两层。

美国前沿实验室（一）：四大主要玩家

OpenAI | 成立 2015 年 ▪ 旧金山

早期为非营利研究机构，2019 年设立“利润上限”子公司并引入微软投资；代表作 ChatGPT (2022.11)、GPT 系列；2025 年完成组织重组：非营利基金会控股、公益公司 (PBC) 运营。开放策略：以闭源 API 与订阅为主。

Anthropic | 成立 2021 年 ▪ 旧金山

由前 OpenAI 研究副总裁 Dario Amodei 兄妹等创立；以“安全”为立身之本，提出宪法式 AI (Constitutional AI)；代表作 Claude 系列；2024 年 11 月发布 MCP 协议，成为 Agent 工具接口的事实标准；主要投资方为 Google 与 Amazon。

Google DeepMind | 成立 2010 年 ▪ 伦敦

2014 年被 Google 收购，2023 年与 Google Brain 合并为 Google DeepMind；代表作 AlphaGo、AlphaFold、Gemini 系列；拥有自研 TPU，是“模型 + 芯片 + 云”垂直整合最完整的一家。

Meta AI (FAIR / MSL) | 成立 2013 年

FAIR 由 Yann LeCun 领导，是深度学习基础研究的重镇；2023 年起以 Llama 系列推动开放权重路线，多数版本可商用但采用自定义社区许可；2025 年成立超级智能实验室 (MSL) 重组团队。

美国与欧洲（二）：差异化路线

xAI | 成立 2023 年 ▪ 美国

由 Elon Musk 创立，与社交平台 X 深度整合；代表作 Grok 系列；自建 Colossus 训练集群，以“最快扩算力”为竞争策略；开放策略以闭源为主，历史版本曾部分开源。

Mistral AI | 成立 2023 年 ▪ 巴黎

创始团队来自 Meta 与 DeepMind，是欧洲最有影响力的大模型公司；以“开放权重 + 商业 API”双轨著称，代表模型 Mistral、Mixtral (MoE)；被视作欧洲“数字主权”的代表。

Cohere | 成立 2019 年 ▪ 多伦多

创始人之一 Aidan Gomez 是 Transformer 论文作者之一；不走消费级聊天路线，专注企业级检索增强生成 (RAG)、嵌入与重排模型；强调私有化部署与数据不出境。

Amazon 与 Microsoft | 云厂商自研

Amazon 推出 Nova 系列自研模型，同时通过 Bedrock 托管多家第三方模型；Microsoft 推出 Phi 系列小模型与自研 MAI 系列，同时是 OpenAI 最大外部股东与云合作方。云厂商的定位是“既卖水也造水”。

中国阵营（一）：开放权重与技术突围

DeepSeek 深度求索 | 成立 2023 年 ▪ 杭州

由量化基金幻方量化孵化，创始人梁文锋；以极高的训练与推理效率著称，代表模型 V 系列（MoE + 多头潜在注意力 MLA）与 R 系列推理模型；长期采取开放权重策略，对全球开源生态影响显著。

阿里巴巴通义千问 Qwen | 2023 年起

国内开源最彻底的模型家族之一，覆盖从 0.5B 到超大规模的完整参数档位，多数版本采用 Apache-2.0 许可；衍生微调模型数量在全球社区中位居前列，是许多开源应用的实际基座。

字节跳动 Seed / 豆包 Doubao | 2023 年起

字节跳动的大模型团队与产品品牌，依托火山引擎对外提供 API；以激进的定价策略推动国内大模型调用量增长，产品线覆盖文本、语音、图像与视频生成。

月之暗面 Moonshot AI | 成立 2023 年 ▪ 北京

创始人杨植麟，以长上下文为早期差异化标签（Kimi 助手）；后续推出的 K 系列采用超大规模 MoE 架构并开放权重，主打 Agent 与工具调用能力。

中国阵营（二）：场景与产业侧

智谱 AI (Z.ai) | 成立 2019 年

源自清华大学知识工程实验室成果转化，代表模型 GLM 系列；长期坚持“开源 + 商业”双轨，在智能体 (Agent) 与国产算力适配方面投入较多。

百度文心 ERNIE | 2023 年起

国内最早发布对标 ChatGPT 产品的厂商之一，依托百度智能云与搜索生态；强调产业落地与行业大模型定制。

腾讯混元 Hunyuan | 2023 年起

依托腾讯云与社交、游戏、办公生态落地；同时开放部分模型权重，覆盖文本、图像、视频与 3D 生成。

MiniMax、科大讯飞与新兴力量

MiniMax 以语音与长上下文见长并开放权重；科大讯飞星火依托语音技术积累；阶跃星辰、零一万物等构成第二梯队，在多模态与端侧方向寻找差异化。

生态层：不造模型，但决定模型怎么被用

Hugging Face | 成立 2016 年 ▪ 纽约

全球最大的模型与数据集托管社区，Transformers 等开源库是事实标准；开放权重模型的“发行渠道”，也是社区评测与复现的主要阵地。

OpenRouter 等聚合平台

把多家模型统一为一套 API 与计费，支持按价格、延迟或能力自动路由；对使用者降低多模型比对与切换成本，对厂商则是新增的分发渠道。

Together AI、Fireworks AI 等推理托管商

专门托管开源权重模型，按词元计费，价格通常低于一线实验室；也可提供微调、批量推理与私有部署，是“开放权重”商业化的重要一环。


Groq、Cerebras 等专用推理硬件

以专用芯片（LPU / 晶圆级引擎）追求极低延迟与极高吞吐，适合实时语音、交互式 Agent 等对延迟敏感的场景，价格与通用云 GPU 形成差异化。

三条组织路线的分野：闭源前沿实验室 / 开放权重阵营 / 云厂商自研

维度	闭源前沿实验室	开放权重阵营	云厂商自研
代表	OpenAI、Anthropic、Google DeepMind	Meta (Llama)、Mistral、DeepSeek、阿里 (Qwen)	Amazon (Nova)、Microsoft (MAI)、阿里、腾讯、百度
盈利方式	按量 API + 订阅	开放权重引流 + 托管/企业服务	云资源捆绑销售, 模型用于拉动算力消费
开放动机	保护技术领先与定价权	换取生态、人才与事实标准	补齐云上的模型供给, 避免被单一供应商卡住
使用者收益	能力通常最前沿, 开箱即用	可自托管、可微调、无数据出境	与已有云账单、权限和合规体系打通
使用者风险	供应商锁定、价格调整、停服	需要自建工程与运维能力	跨云迁移成本高, 模型能力常非第一梯队

云与模型的绑定关系：选模型常常等于选云



同一模型在不同云上可能价格、限流、可用区域与数据驻留策略不同

四种商业模式：模型公司靠什么赚钱

按量计费 (Pay-as-you-go)

按输入/输出词元计价，用多少付多少；适合用量不确定或需要弹性扩缩的场景。缺点是成本随用量线性增长，且单价可能随时调整。

订阅制 (Subscription)

固定月费换取额度与更完整的产品功能（文件、代码执行、Agent 等）；适合个人与中小团队快速上手，但通常不适用于大规模自动化调用，也常附带使用条款限制。

企业协议与私有化部署

按席位或按年签约，提供数据隔离、专属容量、合规承诺与技术支持；条件是可谈判的，包括价格、限流与数据条款，常见于金融、医疗与政务场景。

开放权重 + 托管服务

权重免费下载，收入来自托管推理、微调、技术支持与企业版许可；使用者获得可控性与议价能力，代价是自建工程、运维与安全责任。

开放权重不等于“免费且随便使用”

权重可以下载，但许可证条款差异很大，必须逐条确认。

- ▶ 宽松许可（如 Apache-2.0、MIT）：可商用、可修改、可再分发，限制最少。
- ▶ 自定义社区许可：常附带月活用户门槛、命名要求、禁止用于训练竞争模型等条款。
- ▶ 有些“开源”仅开放权重而不开放训练数据与代码，复现性有限。
- ▶ 使用前必须确认：能否商用、能否改名、是否需要标注来源、是否有规模门槛。

关键术语 Key Terms

开放权重 Open Weights

开源许可 Open-source License

可商用 Commercial Use

再分发 Redistribution

💡 例 Example | 宽松许可（Apache-2.0、MIT）可自由商用与再分发；自定义社区许可常附带月活门槛、命名要求或“不得用于训练竞争模型”等条款。同叫“开源”，权利完全不同。

公司背景总表：成立时间、资本、开放策略与代表模型

机构	成立	主要资本/绑定	开放策略	代表模型家族	选型关注点
OpenAI	2015	微软、多家基金	闭源	GPT 系列	能力前沿、生态成熟、锁定风险
Anthropic	2021	谷歌、亚马逊	闭源	Claude 系列	长文本与 Agent、企业合规
Google DeepMind	2010	Alphabet 全资	闭源 + 部分开源	Gemini 系列	自研芯片、多模态与超长上下文
Meta AI	2013	Meta 全资	开放权重	Llama 系列	可自托管、许可需逐版确认
xAI	2023	自有资金与外部融资	闭源为主	Grok 系列	扩算力激进、生态较新
Mistral AI	2023	欧洲资本与产业方	开放权重 + API	Mistral、Mixtral	欧洲数据主权、MoE 效率
Cohere	2019	企业与云资本	闭源 + 部分开放	Command、Embed	企业 RAG 与嵌入模型
DeepSeek	2023	幻方量化孵化	开放权重	V 系列、R 系列	高性价比、可自托管
阿里巴巴	—	阿里云	开放权重为主	通义千问 Qwen	参数档位齐全、Apache-2.0
字节跳动	—	火山引擎	闭源 + 部分开放	豆包 Doubao	低价、语音与视频生成
月之暗面	2023	风险投资	部分开放权重	Kimi K 系列	长上下文与 Agent 工具调用
智谱 AI	2019	国资与产业资本	双轨	GLM 系列	国产算力适配、Agent

来源：厂商公开信息概括整理；成立时间与资本结构请以官网披露为准，本表不含未经证实的融资与估值数据。

公司背景为什么会直接影响你的选型

■ 技术指标之外，供应连续性与条款风险才是长期成本。

- ▶ 资本结构决定路线稳定性：依赖单一投资方的公司，战略转向可能改变模型开放程度。
- ▶ 云绑定决定迁移成本：模型与云深度耦合时，“换模型”往往意味着“换云”。
- ▶ 开放策略决定议价能力：有权重可下载，才有停服时的兜底方案。
- ▶ 监管与合规：不同法域的诉讼、出口管制与数据法规会影响服务可用性。

关键术语 Key Terms

供应商锁定 Vendor Lock-in

供应连续性 Supply Continuity

议价能力 Bargaining Power

合规风险 Compliance Risk

📊 公式 Formula | 切换成本 $C_{sw} = C_{prompt} + C_{eval} + C_{tool} + C_{compliance}$ ：提示改写、评测重建、工具适配与合规重审都要计入。它常常大于模型单价差异。

本节要记住的三个判断

■ 产业格局的判断力，比记住模型版本号更重要。

- ▶ 能力最前沿的模型通常最不开放——开放是一种商业策略，不是技术阶段。
- ▶ 中国厂商在开放权重与性价比上贡献显著，全球开源生态已形成相互依赖。
- ▶ 生态层（托管、聚合、工具）正在成为新的、不可忽视的议价环节。

关键术语 Key Terms

开放权重阵营 Open-weights
Camp

垂直整合 Vertical Integration

分发渠道 Distribution Channel


事实标准 De Facto Standard

 图示 Diagram | 判断顺序：先看开放策略（能否自托管）→ 再看资本绑定（路线是否稳定）→ 再看云依赖（迁移成本）→ 最后看合规法域（能否使用）。

03

从 Transformer 到推理模型：三条主线

发展史时间轴 (2017-2025): 从注意力机制到推理模型



注：本节只呈现已公开、可核实的里程碑；2026 年的具体版本情况需按官方发布信息更新。


真实数据：前沿模型智能指数随时间的变化

Frontier Language Model Intelligence, Over Time

Artificial Analysis Intelligence Index v4.3.2 incorporates 10 evaluations: AA-Briefcase v1.1, GDPval-AA v2.1, AutomationBench-AA, Terminal-Bench 4.0, SciCode, Humanity's Last Exam, GDP.pdf, CritPt, AA-Omniscience, AA-LCR v1.1



15 of 59 model creators



同一机构口径下，前沿模型的智能指数逐年上升；曲线变缓处，正对应“同等提升需要更多成本”的阶段。

来源：Artificial Analysis: Frontier Language Model Intelligence, Over Time。截图快照 2026-09；图为该机构榜单原始标注，引用时请注明机构与日期。

第一阶段：注意力机制的统一

Transformer 用注意力替换循环结构，使大规模并行训练成为可能。

- ▶ 2017 年《Attention Is All You Need》提出 Transformer 架构。
- ▶ 2018 年出现两条支线：GPT 系列走“解码器 + 生成”，BERT 走“编码器 + 理解”。
- ▶ 关键改变是训练可以并行：模型规模不再被序列计算方式卡住。
- ▶ 今天绝大多数大语言模型仍建立在这一架构之上。

关键术语 Key Terms

注意力机制 Attention

自注意力 Self-attention

并行训练 Parallel Training

编码器/解码器 Encoder/Decoder

 **公式 Formula** | 注意力机制： $\text{softmax}(QK^T/\sqrt{d_k})V$ 。每个词都能直接“看到”句子里其他词，而不必逐步传递信息——这是并行训练的前提。

第二阶段：规模定律与预训练红利

■ 参数量、数据量与算力按比例增长，能力可预测地提升。

- ▶ 2020 年 GPT-3 (1750 亿参数) 证明“少样本提示”可用。
- ▶ 规模定律 (Scaling Law) 让预算分配从经验变成可估算的工程问题。
- ▶ 这一阶段的共识是：先把通用能力做大，再考虑具体任务。
- ▶ 局限也逐渐显现——训练成本极高，且不会自动学会“听话”和“安全”。

关键术语 Key Terms

规模定律 Scaling Law

预训练 Pre-training

少样本学习 Few-shot Learning

涌现能力 Emergent Ability

 **公式 Formula** | 规模定律 (Scaling Law): 损失 $L(N, D)$ 随参数量 N 与数据量 D 近似按幂律下降。它把“要不要加大投入”从直觉问题变成了可以估算的工程问题。

第三阶段：对齐，让模型“听话且安全”

■ 对齐解决的是“有能力但不按人类意图行事”的问题。

- ▶ 指令微调 (Instruction Tuning): 用“指令—理想回答”数据教模型完成任务。
- ▶ 人类反馈强化学习 (RLHF): 用人类偏好排序训练奖励模型，再优化策略。
- ▶ 2022 年 InstructGPT 与 ChatGPT 证明：对齐带来的体验提升，比单纯加大规模更直接。
- ▶ 对齐同时带来副作用：迎合 (sycophancy)、过度拒答与“看起来更自信”。

关键术语 Key Terms

指令微调 Instruction Tuning

人类反馈强化学习 RLHF

偏好对齐 Preference Alignment

迎合偏差 Sycophancy

💡 例 Example | 同一个问题：“我不知道”与“编造一个看起来很合理的答案”，训练目标上前者并不天然更优——这正是必须做对齐 (Alignment) 的原因。

第四阶段：从“更大”转向“想更久”

■ 测试时计算把训练规模竞赛转向推理阶段的计算分配。

- ▶ 推理模型 (Reasoning Model) 在输出前进行更长的内部计算，再给出答案。
- ▶ 核心思想：用推理阶段的计算量，换取数学、代码、规划等高难度任务的准确率。
- ▶ 代价是延迟与成本上升——推理词元 (reasoning tokens) 同样计入账单。
- ▶ 由此产生“思考预算”这一新的可调参数：越难的任务给越多预算。

关键术语 Key Terms

推理模型 Reasoning Model

测试时计算 Test-time Compute

思维链 Chain-of-Thought

思考预算 Thinking Budget

📊 公式 Formula | 总成本 $\approx$ 思考词元数 $\times$ 输出单价。思考预算翻倍，成本近似翻倍，而准确率往往只提升几个百分点——收益递减是推理模型的常态。

第五阶段：从生成文字到使用工具

模型开始具备“调用外部世界”的接口能力。

- ▶ 工具调用 (Tool Calling) 让模型输出结构化调用，而不是只输出自然语言。
- ▶ Agent 把“模型 + 上下文 + 工具”组合成可完成任务的循环。
- ▶ 编码、检索、浏览器与计算机操作成为最先成熟的场景。
- ▶ 这一阶段的核心竞争力，从模型参数转向外壳工程 (Harness Engineering)。

关键术语 Key Terms

工具调用 Tool Calling

智能体 Agent

外壳工程 Harness Engineering

函数调用 Function Calling

模型给出计划 → 调用外部工具 → 读取真实结果 → 据此修正或结束

五个范式阶段对照表：每一阶段解决了什么瓶颈

阶段	代表里程碑	解决的核心瓶颈	遗留问题
架构统一	Transformer (2017)	序列建模无法大规模并行	需要海量数据与算力
规模扩张	GPT-3 (2020) 与规模定律	任务专用模型难以泛化	不会遵循人类意图，成本高
对齐微调	InstructGPT / ChatGPT (2022)	有能力但不听指令、不安全	迎合、幻觉、过度拒答
推理计算	o 系列等推理模型	多步推理任务准确率不足	延迟与成本显著上升
工具与智能体	工具调用、MCP、编码 Agent	只能输出文本，无法行动	权限、可靠性与评测困难

中文大模型的独立发展线

中国厂商在开放权重与工程效率上走出了一条不同的路。

- ▶ 早期以对话产品切入（文心一言等），随后进入“百模大战”的密集发布期。
- ▶ 开源成为重要策略：通义千问、GLM、DeepSeek、Kimi 等先后开放权重。
- ▶ 效率路线突出：在算力受限的条件下，工程优化（稀疏化、量化、推理调度）权重更高。
- ▶ 结果：全球开源社区中，中文模型成为大量衍生模型的实际基座。

关键术语 Key Terms

开放权重 Open Weights

模型蒸馏 Distillation

量化 Quantization

衍生模型 Derivative Model

💡 例 Example | 中文的成语、公文语体、中英混排与标点规范，是国际模型与国产模型最常出现差异的地方；评测时应按目标语言分别取样，而非只看总分。

架构演进：从稠密模型到混合专家

I 同样的算力预算下，稀疏化让“大而快”成为可能。

- ▶ 稠密模型 (Dense): 每个词元都激活全部参数，简单但推理成本随规模线性上升。
- ▶ 混合专家 (MoE): 每个词元只激活少数专家，总参数很大而单次计算量较小。
- ▶ 关键指标是“总参数 / 激活参数”两个数字，不能只看总量。
- ▶ 代价是显存占用高、路由训练复杂，部署门槛并未同比下降。

关键术语 Key Terms

稠密模型 Dense Model

混合专家 Mixture-of-Experts, MoE

激活参数 Active Parameters

路由 Routing

📊 公式 Formula | 混合专家 (MoE): 激活参数 $\ll$ 总参数。公开披露的一种典型配置是“总参数约 671B / 激活约 37B”——容量大而单次计算量小 (口径以官方技术报告为准)。

上下文窗口的军备竞赛

I 从 4K 到百万级词元，“能看多少”与“能用好多少”是两件事。

- ▶ 早期模型上下文仅数千词元，长文档必须切分处理。
- ▶ 长上下文技术（位置编码外推、注意力近似等）把窗口推高数个量级。
- ▶ 窗口扩大不等于有效利用：中段信息易被忽略（“迷失在中间”现象）。
- ▶ 工程结论：超长输入仍需分段、检索与结构化摘要配合。

关键术语 Key Terms

上下文窗口 Context Window


位置编码 Positional Encoding

迷失在中间 Lost in the Middle

检索增强生成 RAG

💡 例 Example | “迷失在中间” (Lost in the Middle): 把关键条款放在超长输入中段，模型更容易漏读。分段、重排与结构化摘要，比单纯加长上下文窗口更有效。

价格史示意：同等能力档位的单位成本在快速下降（方法论示意）



本节要记住的三条主线

■ 规模、对齐、测试时计算——今天所有进展都可以归入其中。

- ▶ 规模主线：架构可并行 + 数据与算力充足 通用能力可预测地提升。
- ▶ 对齐主线：能力必须与人类意图匹配，否则“更聪明”反而更危险。
- ▶ 计算主线：把算力从训练搬到推理，是近年能力提升最快的路径。
- ▶ 三条主线之外，成本下降才是大模型得以普及的真正原因。

关键术语 Key Terms

范式 Paradigm

可预测扩展 Predictable Scaling

推理成本 Inference Cost

能力平价化 Capability Commoditization



图示 Diagram | 历史主线：架构可并行 → 规模红利 → 对齐听话 → 测试时计算 → 工具使用。每一步都在解决上一步暴露出的瓶颈。

04

从“会说话”到“会干活”：智能体的三十年

智能体的最小公式

■ **Agent = 模型 + 上下文 + 工具，三者缺一不可。**

- ▶ 模型 (Model) 负责理解目标、规划步骤、选择下一步行动。
- ▶ 上下文 (Context) 承载任务、历史、知识、观察结果与当前状态。
- ▶ 工具 (Tools) 提供真实世界的读写能力：搜索、计算、文件、数据库与业务接口。
- ▶ 只有模型没有工具，是聊天机器人；只有工具没有模型，是传统自动化脚本。

关键术语 Key Terms

智能体 Agent


上下文 Context

工具调用 Tool Calling

循环 Loop

📌 公式 Formula | $\text{Agent} = \text{LLM} + \text{Context} + \text{Tools}$ 。三者任一缺失，任务都会卡在某个环节：没有上下文就不知道现状，没有工具就无法改变世界。

智能体发展史时间轴：从符号推理到工具使用



史前史：智能体不是新概念

“自主行动”这件事，人工智能研究了三十年，只是“大脑”换了。

- ▶ 1990 年代的多智能体系统（Multi-agent System）研究协商、协作与竞争。
- ▶ BDI 架构用信念（Belief）、愿望（Desire）、意图（Intention）描述智能体。
- ▶ 经典强化学习智能体在游戏与机器人中学习策略，但难以处理开放语言任务。
- ▶ 共同瓶颈始终是同一个：如何把开放世界的知识表示为可计算的决策。

关键术语 Key Terms

多智能体系统 Multi-agent System

BDI 架构 Belief-Desire-Intention

强化学习 Reinforcement Learning

符号推理 Symbolic Reasoning

💡 例 Example | BDI 架构的“信念—愿望—意图”，与今天智能体的“状态—目标—计划”是同一种思路的不同表达，只是“推理引擎”从逻辑规则换成了语言模型。

2022: ReAct, 推理与行动交替

ReAct 把“想”和“做”编成交替的循环，是当代智能体的雏形。

- ▶ 核心形式是“思考—行动—观察”（Thought—Action—Observation）不断重复。
- ▶ 推理让模型决定下一步查什么；行动调用搜索或计算工具；观察把真实结果写回上下文。
- ▶ 相比只推理，ReAct 让模型能借助外部信息纠正自己的错误。
- ▶ 局限也已显现：循环可能空转，工具失败后容易反复重试。

关键术语 Key Terms

推理—行动循环 ReAct

观察 Observation

工具调用 Tool Use

空转循环 Looping

思考 Thought → 行动 Action → 观察 Observation → 再思考或结束

■ 这一年同时出现了“过度自主”的教训和“标准化接口”的答案。

- ▶ 自主智能体项目 (AutoGPT、BabyAGI 等) 让模型自行拆解并执行长任务, 引发广泛关注。
- ▶ 实测暴露问题: 容易陷入循环、成本失控、错误累积、结果难以验证。
- ▶ 同年出现函数调用 (Function Calling): 模型按结构化格式输出调用请求, 由程序执行。
- ▶ 结论沉淀为共识——先做可靠的接口与边界, 再谈自主性。

关键术语 Key Terms

自主智能体 Autonomous Agent

函数调用 Function Calling

结构化输出 Structured Output

成本失控 Runaway Cost

💡 例 Example | 自主智能体的典型失败: 没有轮次上限与预算上限时, 它会反复重试同一个失败动作, 把预算消耗在无效循环上——这是最早一批项目的共同教训。

■ 从“调用函数”扩展到“操作整个软件界面”。

- ▶ 多智能体框架（如 AutoGen、CrewAI）用角色分工与消息传递编排协作。
- ▶ 计算机操作（Computer Use）让模型直接看屏幕、点鼠标、敲键盘。
- ▶ 浏览器智能体（Web Agent）把网页操作变成可编程任务。
- ▶ 收益是覆盖面扩大；代价是错误路径变多、验证与权限问题更尖锐。

关键术语 Key Terms

多智能体编排 Multi-agent
Orchestration

计算机操作 Computer Use

浏览器智能体 Web Agent

角色分工 Role Assignment

💡 例 Example | “帮我订一张最便宜的机票”这类任务需要读邮件、开浏览器、比价、下单，任何一步失败都会中断；因此计算机操作类智能体必须配套重试策略与人工接管。

2024 年末：MCP 让工具接口标准化

I 工具接入从“每家自己写”变成“按协议接一次”。

- ▶ 模型上下文协议（Model Context Protocol, MCP）由 Anthropic 于 2024 年 11 月提出并开源。
- ▶ 目标是统一“模型如何发现并调用外部工具与数据源”的接口。
- ▶ 价值类似 USB-C：工具方实现一次，多个模型与客户端都能复用。
- ▶ 随后被多家厂商与工具链采纳，成为事实标准；安全边界（权限、注入）随之成为重点。

关键术语 Key Terms

模型上下文协议 MCP

服务端/客户端 Server/Client

事实标准 De Facto Standard

提示注入 Prompt Injection

📐 公式 Formula | 适配成本从 $N \times M$ 降到 $N + M$ ： N 个模型各自对接 M 个工具是乘法关系，有了统一协议后变成加法关系。这就是协议层的经济价值。

2025：编码智能体与深度研究

■ 最高价值的场景最先跑通，因为它们有客观的验收标准。

- ▶ 编码智能体 (Coding Agent) 能读仓库、改代码、跑测试、提交修改。
- ▶ 之所以先跑通：有编译器、测试与版本控制提供客观反馈，可自动验证。
- ▶ 深度研究 (Deep Research) 类产品把多轮检索、阅读与综合编排成一次任务。
- ▶ 共同点是把“完成任务”作为目标，而不是“生成一段文本”。

关键术语 Key Terms

编码智能体 Coding Agent

可验证反馈 Verifiable Feedback

深度研究 Deep Research

任务完成率 Task Success Rate

💡 例 Example | 编码智能体率先跑通，是因为编译器与测试用例提供了客观的“对与错”信号：它可以在无人干预的情况下判断自己是否成功——可验证性是一切自动化的前提。

协议与框架层：MCP 与其他互操作协议的分工

层次	代表	解决的问题	类比
模型 工具 智能体 智能体 应用 模型 编排框架	MCP (2024.11 提出) A2A 等互操作协议 各家 API 规范 LangChain、AutoGen、 CrewAI 等	统一工具与数据源的发现、描述与调用 不同厂商的智能体之间如何委派与协作 提示、工具、流式返回的统一调用格式 把多步骤、多角色流程写成可维护的程 序	设备与配件的通用接口 公司之间的对接流程 不同电源插头 项目管理的流程模板

协议竞争仍在进行，具体版本与采纳范围请以官方规范为准。

工具调用的四步闭环



失败也可能被返回：模型需要区分“调用失败”与“结果为空”

上下文工程：比提示词更重要的工程

提示词 (Prompt) 只是上下文里很小的一部分。

- ▶ 上下文工程 (Context Engineering) 负责安排：指令、示例、检索证据、工具结果、历史与状态。
- ▶ 记忆 (Memory) 分短期 (当前任务) 与长期 (跨会话偏好与事实)。
- ▶ 上下文越长，噪声越多，模型越容易忽略中段信息。
- ▶ 常见手段：摘要压缩、结构化状态表、检索后再注入、丢弃已失效的观察结果。

关键术语 Key Terms

上下文工程 Context Engineering

记忆 Memory

状态表 State Table

压缩摘要 Compaction

 图示 Diagram | 上下文的构成：系统指令 + 当前任务 + 检索证据 + 工具返回结果 + 对话历史 + 结构化状态。上下文工程就是决定这六项的取舍与顺序。

沙箱与权限：智能体落地的前提

■ 给模型多大权限，取决于你能多快发现并撤销错误。

- ▶ 沙箱 (Sandbox) 把执行限制在隔离环境：文件系统、网络与进程都可约束。
- ▶ 最小权限原则 (Least Privilege)：只授予完成任务所必需的能力。
- ▶ 不可逆动作 (付款、发送、删除、发布) 应设置人工审批或双人复核。
- ▶ 关键设计：最大轮次、预算上限、失败阈值与回滚方案。

关键术语 Key Terms

沙箱 Sandbox

最小权限 Least Privilege

人工审批 Human Approval

熔断 Circuit Breaker

💡 例 Example | 不可逆动作清单：付款、对外发送、删除数据、公开发布、作出承诺。这些动作必须人工审批——因为错误一旦发生，重试无法挽回。

智能体能力六级阶梯：先看清自己在哪一级

级别	形态	能力	典型风险
L1	对话问答	单轮或多轮文本交互，无外部数据	幻觉、信息过期
L2	检索增强	结合知识库回答问题，可给出来源	检索失败、引用错误
L3	工具调用	能调用搜索、计算、API 获取与计算	参数错误、越权调用
L4	workflows	固定路径的多步骤自动化，节点内用模型	例外分支未覆盖
L5	自主智能体	路径由模型动态决定，可循环试错	成本失控、错误累积
L6	多智能体协作	多角色分工、互相检查与委派	责任不清、传递失真

阶梯越高不等于越好：能从 L1/L2 满足需求的任务，不应上 L5。

为什么智能体评测特别难

■ 多步任务的成功率，会把单步的微小错误放大成灾难。

- ▶ 单步准确率 95% 的模型，走 20 步的成功率约为 $0.95^{20} \approx 36\%$ 。
- ▶ 环境有状态：同一任务重跑结果可能不同，难以复现。
- ▶ 评分困难：最终答案对，过程可能违规；过程对，结果可能失败。
- ▶ 因此评测要同时看通过率、成本、步数与违规次数。

关键术语 Key Terms

复合错误 Error Compounding

可复现性 Reproducibility

可验证环境 Verifiable Environment

步数预算 Step Budget

 **公式 Formula** | 复合错误：单步准确率 95% 的模型，走 20 步的成功率约为 $0.95^{20} \approx 36\%$ 。步数越多，对单步可靠性的要求越苛刻。

05

分类先于选型：七个分类维度

为什么必须先分类

■ 分类不是学术游戏，而是把“上千个模型”收敛成“几个候选”。

- ▶ 模型数量增长速度远超人的记忆能力，逐一会比较不可能。
- ▶ 分类维度对应真实约束：模态、能力、部署、许可、成本。
- ▶ 先按维度收敛候选集，再在候选集内做性能比较，效率最高。
- ▶ 每一步分类都要回答：“这个约束是硬性的，还是可以商量的？”

关键术语 Key Terms

分类学 Taxonomy

候选集 Candidate Set

硬约束 Hard Constraint

收敛 Narrowing

💡 例 Example | “识别商品图片”属于多模态方向，“写周报”属于文本方向，“做向量检索”属于嵌入方向——分类错了，后面的比较全都无效。

维度一：按模态分类（Modality）

模态类型	能力	典型用途与代表方向
纯文本	理解与生成文字	摘要、问答、抽取、写作、代码
多模态理解	同时读文字与图像/音频/视频	单据识别、图表理解、画面描述、屏幕操作
图像生成	文生图、图生图、编辑	素材制作、商品图、设计草图
视频生成	文生视频、图生视频	短视频素材、动态演示
语音	识别、合成、实时对话	会议记录、语音助手、配音
嵌入与重排	把文本映射为向量并排序	语义检索、推荐、聚类、去重
世界模型与动作	预测环境状态并输出动作	机器人、自动驾驶、游戏智能体

一个“多模态模型”通常只在部分模态上达到可用水平，需按具体方向分别评测。

维度二：按能力定位

■ 同样叫“大模型”，设计目标可能完全不同。

- ▶ 通用对话模型：均衡、响应快，适合日常交互与内容生成。
- ▶ 推理模型：在输出前进行更长内部计算，适合数学、代码与复杂规划。
- ▶ 代码模型：针对编程任务优化，常与仓库、终端和测试环境深度集成。
- ▶ 检索问答与嵌入模型：为知识库检索服务，决定 RAG 的上限。

关键术语 Key Terms

通用模型 General-purpose

推理模型 Reasoning Model

代码模型 Code Model

嵌入模型 Embedding Model

💡 例 Example | 同被称为“大模型”的三个东西：聊天产品底座（均衡、响应快）、竞赛级解题引擎（慢、贵、准）、代码补全内核（专、省）。它们的优化目标完全不同。

维度三：按架构与效率

看两个数字：总参数 (Total) 与激活参数 (Active)。

- ▶ 稠密 (Dense)：每个词元激活全部参数，行为可预测，显存需求与规模同增。
- ▶ 混合专家 (MoE)：只激活部分专家，总参数巨大但单次计算量相对小。
- ▶ 例如“总参数 671B / 激活参数 37B”表示容量大而单次开销小。
- ▶ 稀疏化不降低显存门槛：全部专家权重仍需装载，部署成本依然高。

关键术语 Key Terms

稠密模型 Dense

混合专家 MoE

激活参数 Active Parameters

显存占用 VRAM Footprint

📊 公式 Formula | 显存需求 $\approx$ 参数量 $\times$ 每参数字节数 (FP16 约 2 字节, 4-bit 量化约 0.5 字节) + 激活与缓存开销。
显存常比算力更早成为瓶颈。

维度四：按开放程度

■ 开放程度决定你的议价能力与兜底方案。

- ▶ 闭源 API：只能用服务，不能拿到权重；能力通常最强，控制力最弱。
- ▶ 开放权重：可下载、可自托管、可微调，但许可证条款差异很大。
- ▶ 开源（含代码与数据）：可复现、可审计，但完整开源的前沿模型很少。
- ▶ 私有化部署：在自有环境运行，满足数据不出域要求，但需要运维能力。

关键术语 Key Terms

闭源 Closed-source

开放权重 Open Weights

自托管 Self-hosting

私有化部署 On-premise Deployment

💡 例 Example | 要满足“数据不出境”就得选开放权重并自建；要拿到最前沿能力就往往只能用闭源 API。这两条路在多数情况下无法同时满足，必须排序。

维度五：按规模与部署位置

同样的任务，端侧小模型与云端大模型的取舍完全不同。

- ▶ 前沿大模型：能力最强，必须联网调用，单位成本最高。
- ▶ 中型模型：能力与成本的平衡点，适合大批量处理。
- ▶ 小模型（SLM）：可在单卡甚至端侧运行，适合分类、抽取、改写等窄任务。
- ▶ 端侧模型：数据不出设备，隐私最好，但能力与上下文明显受限。

关键术语 Key Terms

小模型 Small Language Model

端侧推理 On-device Inference

云边协同 Cloud-Edge

蒸馏 Distillation

💡 例 Example | 端侧 3B 级模型做分类、抽取、改写通常够用，做多步推理与长文档理解则明显不足——“能跑起来”和“能放心用”是两件事。

维度六与七：交互形态与价格层级

形态决定怎么用，层级决定花多少钱。

- ▶ 交互形态：聊天界面、API 调用、副驾驶（Copilot）、智能体（Agentic）、多智能体。
- ▶ 价格层级：旗舰、主流、轻量、免费额度层，四档对应完全不同的使用策略。
- ▶ 同一厂商常在多档同时布局，用“能力梯度”做价格歧视。
- ▶ 选型常见错误：用旗舰模型做分类，或用轻量模型做复杂推理。

关键术语 Key Terms

副驾驶 Copilot


智能体 Agentic

价格歧视 Price Discrimination


能力梯度 Capability Ladder

 图示 Diagram | 四档价格对应四种策略：免费额度用于试错，轻量档用于批量，主流档用于生产主力，旗舰与推理档只用于高价值难题。

四档价格层级的相对单价（示意，用于理解梯度而非报价）



分类决策树：从任务反推应该选哪一类模型



分类维度全景矩阵：七个维度与对应的选型含义

维度	常见取值	对选型的直接含义
模态	文本 / 多模态理解 / 图像 / 视频 / 语音 / 嵌入	决定能否处理你的输入输出形态，通常无法用提示词弥补
能力定位	通用 / 推理 / 代码 / 检索	决定是否需要为“想更久”付溢价
架构	稠密 / 混合专家	决定显存需求、部署方式与推理吞吐
开放程度	闭源 / 开放权重 / 开源 / 私有化	决定议价能力、合规路径与停服兜底
规模与位置	前沿 / 中型 / 小模型 / 端侧	决定单位成本与隐私边界
交互形态	聊天 / API / 副驾驶 / 智能体	决定集成工作量与验证方式
价格层级	免费 / 轻量 / 主流 / 旗舰	决定使用策略：能否批量、能否试错

用法：自上而下逐维度收敛，每个维度只保留仍然可选项，通常三轮即可把候选集缩到 3-5 个。

分类的三个常见误区

❗ 分类出错，后面的性能比较再精确也没有意义。

- ▶ 误区一：把“参数更大”当作“能力更强”——稀疏化后总参数与有效能力并非线性关系。
- ▶ 误区二：把“开源”当作“免费”——自托管的显卡、电力与人力成本必须计入。
- ▶ 误区三：把“多模态”当作“全能”——多数模型只在 1-2 个模态上表现良好。
- ▶ 正确做法：用任务需求反推分类，而不是用模型标签反推任务。

关键术语 Key Terms

参数迷信 Parameter Fallacy

隐性成本 Hidden Cost

能力边界 Capability Boundary

任务反推 Task-driven Selection

💡 例 Example | 把三个误区反过来问：这个任务真正需要什么能力？哪一类模型能满足？满足条件的候选中哪个最划算？——顺序反过来，结论通常完全不同。

06

谁在评测：机构、机制与结果的正确读法

为什么必须有第三方评测

I 厂商自己报的分数，与真实水平之间隔着一层利益。

- ▶ 厂商自评测 (Vendor Benchmark) 存在选择性报告：只报有利的基准与配置。
- ▶ 评测条件不透明时，同一模型可以被“调”出完全不同的成绩。
- ▶ 第三方机构的价值在于：统一题面、统一配置、可交叉验证。
- ▶ 但第三方也有立场：资金来自谁、是否售卖评测服务、是否公开原始数据。

关键术语 Key Terms

厂商自评测 Vendor Benchmark

利益冲突 Conflict of Interest

可交叉验证 Cross-validation

方法透明度 Methodological
Transparency

⚠ 提示 Tip | 看到“某某基准第一”时先问四句：这是谁做的评测？测试集是否公开？什么配置下取得的？样本量与置信区间是多少？

评测机构全景地图：七种类型与各自的代表

类型	代表机构	覆盖什么	计分方式	回答什么问题
竞技场型	LMArena、AA 生成竞技场	人类偏好的两两对战	Elo / Bradley-Terry	人更喜欢哪个回答？
综合指数型	Artificial Analysis、SEAL	多项基准加权 + 速度价格	加权指数 / 分榜	综合能力与性价比如何？
学术基准型	HELM、LiveBench、Epoch AI	标准化题集与趋势追踪	准确率 / 效率计分	学术意义上的能力边界在哪？
领域专项型	Vals AI、MedHELM	法律、金融、医疗等专业	领域内准确率	专业场景能不能用？
智能体专项型	SWE-bench、Terminal-Bench、 τ^2 -bench、GAIA	多步任务与工具使用	任务通过率	能不能真的把事做完？
中文与区域型	OpenCompass、SuperCLUE、FlagEval	中文语境与国产模型	综合分 / 多维雷达	中文表现到底怎么样？
企业服务型	Galileo、Patronus、Arize、RAGAS	幻觉、安全、可观测	自定义指标	上线后怎么持续监控？

来源：类型划分为教学归纳；同一机构常跨类（如 Artificial Analysis 同时提供指数与竞技场）。

LMarena：人类偏好对战的开创者

机构背景 Background

起源于加州大学伯克利分校的 LMSYS 项目，是最早把“匿名两两对战 + 真人投票”做成公开排行榜的机构；现为独立运营，并扩展出文本、视觉、图像、视频等多个竞技场。

评测机制 Mechanism

模型匿名配对、用户投票选更优回答；用 Bradley-Terry 模型把胜负关系拟合为 Elo 分数；提供风格控制（Style Control）变体以削弱“回答更长更好看”的偏差；可查看分领域榜单与置信区间。

结果读取方式 How to Read

官方入口：<https://lmarena.ai/>。看三件事：是否勾选风格控制；模型的置信区间是否与相邻名次重叠；分领域榜（编码、数学、创意写作、长难提示）与你关注的方向是否一致。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：真实用户偏好、样本量大、持续更新、有置信区间。局限：反映“讨人喜欢”多于“正确”；受投票人群构成影响；长任务与工具使用能力无法体现。

Artificial Analysis: 独立实测与“智能指数”

机构背景 Background

独立分析机构，直接调用各厂商 API 做实测，不依赖厂商自报数据；同时测量智能水平、输出速度、首字延迟与价格，并提供图像、视频、语音竞技场。

评测机制 Mechanism

综合智能指数 (Intelligence Index) 把多项公开基准加权合成一个分数，例如知识推理、数学、科学、编码、长上下文、指令遵循与智能体任务；速度指标为每秒输出词元数与首字延迟；价格按其自己的计费口径折算为“每千次任务成本”。

结果读取方式 How to Read

官方入口：<https://artificialanalysis.ai/>。要点：指数有版本号，跨版本不可直接比较；注意是否开启推理模式，推理模型的成本与延迟差异极大；该站同时给“性价比”视图，可直接看每美元能力。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：速度与价格实测，是少见的“三维同测”；图表可直接用于决策。局限：加权方式由机构设定，改变权重会改变排名；部分基准题集公开，存在被针对性优化（刷榜）的可能。

Stanford HELM: 学术透明度的标杆

机构背景 Background

斯坦福大学基础模型研究中心 (CRFM) 出品, 全称 Holistic Evaluation of Language Models (语言模型整体评估); 是“全场景、多指标、可复现”评测范式的代表。

评测机制 Mechanism

对每个场景同时报告多个指标 (准确率、校准、鲁棒性、公平性、偏差、效率等), 强调提示标准化与结果可复现; 衍生系列覆盖能力 (Capabilities)、安全 (Safety)、长上下文 (HELMET)、医疗 (MedHELM)、视觉语言 (VHELM) 等。

结果读取方式 How to Read

官方入口: <https://crfm.stanford.edu/helm/>。要点: HELM 的价值在“分解维度”而非单一排名; 适合用来回答“这个模型在哪类能力上有系统性短板”; 版本问题集有调整, 需看发布日期。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点: 方法学公开、指标多元、学术中立性强; 适合教学与审计。局限: 更新频率低于商业榜; 题集偏学术, 与产品体验有距离; 分数不易直接换算为商业价值。

Epoch AI: 能力趋势与专家级数学

机构背景 Background

由研究机构 Epoch AI 运营，专注用数据刻画 AI 能力与算力的长期趋势；其“基准测试中心”聚合多个榜单，并提供自己的高难度数学基准。

评测机制 Mechanism

核心特点：用专家编写、常年不公开的私有题集评测前沿数学能力，降低数据污染；用能力指数 (Capability Index) 把多个基准映射到统一尺度，便于跨时间比较；同时追踪训练算力、数据量与模型规模等输入侧趋势。

结果读取方式 How to Read

官方入口：<https://epoch.ai/>。要点：关注“趋势线”而非单点分数；私有题集使其对刷榜不敏感，适合观察真实前沿水平；注意题目难度定位远高于日常任务，不能外推到普通业务。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：抗污染、长期可比、兼具输入与输出视角。局限：难度过高导致区分度在尾部拥挤；题目不公开，外部难以复核细节；更新节奏偏研究型。

LiveBench：以防污染为设计目标

机构背景 Background

由多所高校与机构研究者共同维护的基准，明确以“避免数据污染”为第一设计原则，按月滚动更新题目。

评测机制 Mechanism

题目来源持续更新：近期新闻、最新论文、新发布的数据集与竞赛题，确保题目晚于模型训练截止日期；覆盖数学、推理、编码、数据分析、语言理解与指令遵循六大类，并要求模型给出可判定的客观答案。

结果读取方式 How to Read

官方入口：<https://livebench.ai/>。要点：每月更新，跨月比较需看题目是否变化；分类别分数比总分更有信息量，尤其编码与推理两类；主观类任务（如写作）不纳入，需另找评测。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：抗污染设计清晰、更新频繁、客观可判定。局限：题目偏短、偏客观，难以覆盖长任务；高频更新使历史趋势线不便解读。

ARC Prize 与 ARC-AGI: 抽象推理与效率计分

机构背景 Background

由 ARC Prize 基金会推动, 围绕抽象与推理语料库 (Abstraction and Reasoning Corpus) 设立, 目标是衡量模型在全新规则下的泛化推理能力。

评测机制 Mechanism

任务是最少示例下推断视觉网格的变换规则并输出结果, 测试集长期保密以防污染; 新版基准同时引入“效率计分”, 把每题的成本纳入评价, 鼓励用更少算力解决问题。

结果读取方式 How to Read

官方入口: <https://arcprize.org/>。要点: 这道题人类易、模型难, 是“泛化能力”的探针; 效率计分让“堆算力”不再是无条件有效策略; 分数低不代表模型无用, 而是说明它依赖模式记忆。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点: 污染风险低、直指泛化本质、引入成本维度。局限: 任务形态特殊, 与语言和业务任务相关性有限; 通过率长期偏低, 区分度集中在少数模型。

SEAL (Scale AI): 专家出题的私有评测

机构背景 Background

由数据与评测公司 Scale AI 运营，主打“专家编写、私有持有”的评测集，覆盖编码、智能体、推理、数学、多语言、指令遵循、长上下文与安全等领域。

评测机制 Mechanism

每个分榜由领域专家命题并保密，避免训练数据泄漏；结果以排行榜形式发布，并对竞争者给出置信区间 (Confidence Interval)，用以判断名次差异是否真实存在。

结果读取方式 How to Read

官方入口：<https://scale.com/leaderboard>。要点：优先看置信区间是否重叠——重叠意味着“名次差异不显著”；分榜比总榜更可信；题目不公开，无法自行复核，只能信任其专家流程。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：私有题集抗污染、分领域细、给出统计不确定性。局限：企业运营，方法细节公开程度有限；覆盖面随专家投入变化；外部无法独立复现。

Vals AI: 专业领域的“能不能干活”

机构背景 Background

专注专业领域评测的机构，围绕法律、金融、医疗、税务等职业场景构建基准，题目由持证专业人士编写与判分。

评测机制 Mechanism

以“职业任务”为单位设计：法律文书审阅、金融建模、会计处理、医疗问答等；部分分榜使用专家评分或与标准答案比对，强调任务完成度而不是语言流畅度。

结果读取方式 How to Read

官方入口：<https://www.vals.ai/>。要点：这是“领域适配度”评测，通用旗舰不一定领先；看评测任务是否与你所在行业一致，不要跨领域外推；询问其评分是否由专业人士完成。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：贴近真实工作产出，专业判分质量高。局限：领域窄、更新依赖专家产能；不同分榜难度不可比；题目与评分细节不完全公开。

OpenCompass 司南：中文综合评测体系

机构背景 Background

由上海人工智能实验室主导的开源评测体系，面向中文与多语言场景，是国内影响力最大的综合评测平台之一。

评测机制 Mechanism

以“学科—知识—推理—语言—长文本—安全—智能体”等多维度组织评测集，提供综合性榜单（CompassRank）与细分榜单；工具链开源，允许机构自建与复现评测。

结果读取方式 How to Read

官方入口：<https://opencompass.org.cn/>。要点：综合榜与细分榜要一起看；中文与国产模型覆盖面较好，适合做中文场景初筛；关注其评测版本与题集更新时间。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：开源可复现、中文覆盖好、维度完整。局限：部分子集为公开题，存在被优化空间；不同版本分数不可直接横比。

SuperCLUE: 中文通用能力的定期基准

机构背景 Background

面向中文大模型的第三方评测体系，定期发布中文通用能力基准报告，覆盖语义理解、逻辑推理、生成、安全等方向。

评测机制 Mechanism

以中文原生任务为主，采用多维度打分并发布总分与分项；部分分榜区分闭源与开源模型，便于观察国内模型的相对位置。

结果读取方式 How to Read

官方入口：<https://www.superclueai.com/>。要点：关注评测月份与题集版本；区分“总榜”与“开源子榜”——两者不可混用；部分分数来源于厂商提交，需看是否标注“实测”。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：中文语料原生、更新频繁、对国产模型覆盖全。局限：评测细节公开程度不及学术基准；总分权重由机构设定；历史分数口径调整需谨慎比较。

FlagEval 与中文学术基准 (C-Eval、CMMLU)

机构背景 Background

FlagEval 由智源研究院 (BAAI) 推出, 定位为多维度、多模态的评测平台; C-Eval 与 CMMLU 是学术社区广泛使用的中文学科知识基准。

评测机制 Mechanism

FlagEval 采用“能力—任务—指标”三层结构, 支持模型提交与自动评测; C-Eval 与 CMMLU 以选择题形式覆盖数十个学科, 考察中文知识广度, 题目公开。

结果读取方式 How to Read

官方入口: <https://flageval.baai.ac.cn/>; C-Eval 与 CMMLU 见其官方论文与开源仓库。要点: 选择题基准易受污染, 高分不等于强; 适合做“中文基础知识”体检, 不适合评价智能体能力。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点: 结构清晰、覆盖中文学科广、可复现。局限: 选择题形式单一, 难以反映生成质量与多步推理; 公开题目存在训练泄漏风险。

Hugging Face 开源模型榜与 MTEB 嵌入榜

机构背景 Background

Hugging Face 是全球最大的模型社区。“开放大语言模型排行榜”曾是开源模型最常被引用的榜单；嵌入模型则由 MTEB/MMTEB 系列主导。

评测机制 Mechanism

开放模型榜基于若干公开基准自动评测社区提交的模型，按参数规模分组；MTEB 覆盖检索、分类、聚类、重排、语义相似度等多类任务并支持多语言，是 RAG 选型的常用依据。

结果读取方式 How to Read

官方入口：<https://huggingface.co/>。要点：开放模型榜历经版本更迭与归档，引用时必须写清版本与日期；MTEB 应看“中文/多语言子榜”而非总榜；社区榜易被小模型针对性优化，需看分组。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：免费、可复现、对开源生态覆盖最广。局限：题集公开导致污染风险高；榜单维护状态会变化，历史引用容易失效。

SWE-bench: 编码智能体的黄金标准

机构背景 Background

由普林斯顿等机构研究者提出，用真实开源仓库的问题报告 (issue) 与对应修复提交构建任务，是编码智能体最被认可的评测之一。

评测机制 Mechanism

模型需要阅读仓库、定位缺陷并生成补丁，最终以仓库自带测试用例是否通过作为判定标准；由于原始任务难度与噪声问题，社区衍生出人工校验过的子集 (Verified)。

结果读取方式 How to Read

官方入口：<https://www.swebench.com/>。要点：必须确认是原始集还是 Verified 子集，两者不可比；关注是否允许“测试文件可见”，这会影响得分含金量；成本与步数同样值得记录。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：客观可判定、贴近真实工程、有明确通过标准。局限：只覆盖 Python 生态偏多；题目来自公开仓库，存在训练泄漏风险；高分不等于能处理私有代码库。

LiveCodeBench 与 Terminal-Bench：防污染编程与终端任务

机构背景 Background

LiveCodeBench 以“按时间切片”的竞赛题评测编码能力；Terminal-Bench 由斯坦福与劳伦斯伯克利实验室等合作推出，评测智能体在真实终端环境中的任务完成能力。

评测机制 Mechanism

LiveCodeBench 只使用模型训练截止之后发布的竞赛题，天然降低污染；Terminal-Bench 提供容器化终端环境与任务清单，以任务是否成功完成判定，并按模型版本迭代发布新版本。

结果读取方式 How to Read

官方入口：LiveCodeBench <https://livecodebench.github.io/>；Terminal-Bench <https://www.tbench.ai/>。要点：LiveCodeBench 的分数要与“时间窗”一起看；Terminal-Bench 有多个版本，跨版本不可比；两者都需关注单任务成本与超时设置。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：抗污染设计明确、任务可复现、贴近真实操作。局限：依赖排行榜方维护的题目卫生；环境配置复杂；分数对提示与脚手架敏感。

τ^2 -bench 与 BFCL：工具调用能力怎么量

机构背景 Background

τ^2 -bench 关注“智能体—用户—工具”三者交互下的任务完成；BFCL（伯克利函数调用排行榜）专注函数调用的正确性，是最早的工具调用专项评测之一。

评测机制 Mechanism

τ^2 -bench 在带领域规则的模拟环境中运行多轮对话，要求智能体既遵守业务规则又完成用户目标，可直接测量“规则违规率”；BFCL 提供大量函数定义与用户请求，检验模型能否生成语法正确、参数正确、可执行的调用。

结果读取方式 How to Read

官方入口： τ^2 -bench <https://github.com/sierra-research/tau2-bench>；BFCL <https://gorilla.cs.berkeley.edu/leaderboard.html>。要点：工具调用评测对“函数描述写法”高度敏感，跨榜单不可直接比；应同时看“调用正确率”与“多余调用率”；多轮任务还要看违规次数。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：直击智能体核心能力、可量化违规、任务可复现。局限：模拟环境与真实系统存在差距；函数集合由评测方定义，覆盖面有限；结果对脚手架敏感。

GAIA、OSWorld 与 WebArena：端到端智能体环境

机构背景 Background

GAIA 由 Meta 等机构提出，设计“对人类简单、对 AI 困难”的多步真实任务；OSWorld 与 WebArena 提供真实的操作系统与网站环境作为智能体试验场。

评测机制 Mechanism

GAIA 要求答案唯一且可判定，任务需要组合浏览、检索与推理；OSWorld 在虚拟机中操作真实软件（含办公套件）；WebArena 复刻典型网站功能，要求完成端到端操作目标。三者均以任务成功率计分。

结果读取方式 How to Read

官方入口：GAIA <https://huggingface.co/spaces/gaia-benchmark/leaderboard>；OSWorld <https://os-world.github.io/>；WebArena <https://webarena.dev/>。要点：环境有状态，需注意是否允许重试与最大步数；成功率随脚手架变化很大，必须看实现细节；关注“失败模式”分布，不只是总分。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：最接近真实使用、能暴露长链路弱点。局限：运行成本高、复现难度大；公开环境存在被针对性适配的可能；结果对工具集合高度敏感。

多模态与语音专项：MMMU-Pro、Video-MME、DocVQA、Open ASR

机构背景 Background

多模态评测来自多个学术与社区机构：MMMU 系列考察大学水平的多学科图文理解，Video-MME 考察视频理解，DocVQA 与 OCRBench 考察文档与文字识别；语音侧以 Hugging Face 开放语音识别榜与 TTS Arena 为代表。

评测机制 Mechanism

MMMU-Pro 通过更难的问题设置减少“靠文本线索猜答案”；视频基准按时长与领域分层；文档基准以字段级准确率判定；语音识别榜以词错误率（WER）为主指标，并报告实时率（RTFx）衡量速度。

结果读取方式 How to Read

官方入口：MMMU <https://mmmu-benchmark.github.io/>；
开放语音榜 https://huggingface.co/spaces/hf-audio/open_asr_leaderboard。要点：文档类任务必须看“字段级”准确率而非整体相似度；语音要看 WER 与实时率的权衡；
视频理解分数对采样帧数很敏感。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：指标明确、贴近具体功能模块。局限：单项高分不代表端到端可用；真实文档的版式噪声远超题集；语音在口音与噪声下的表现差异大。

图像与视频生成榜、企业级评测服务

机构背景 Background

生成侧以 Artificial Analysis 的图像与视频竞技场、LMArena 的文生图竞技场为主要公共榜；企业侧则出现一批专注幻觉检测与可观测的服务商。

评测机制 Mechanism

生成榜单以人类偏好投票产生 Elo 排名，并辅以自动指标（提示遵循、美学、文字渲染等）；企业服务提供幻觉检测、检索质量评分（如 RAG 的忠实度与相关性指标）、提示回归测试与线上监控。

结果读取方式 How to Read

官方入口：文生图竞技场 <https://artificialanalysis.ai/text-to-image/arena>；视频竞技场 <https://artificialanalysis.ai/video/arena>。要点：生成内容的质量高度主观，务必看“提示遵循”与“文字渲染”等硬指标；企业服务适合做上线后的持续监控，而非一次性选型；自建黄金样本仍是最贴近自身需求的方案。本讲不使用未核实的具体分数。

优点与局限 Pros & Limits

优点：覆盖生成质量与线上风险两端，能补上静态榜单的空白。局限：主观性强、不同竞技场题面差异大；商业服务的评分口径不公开，难以横向比较。

评测门户速查表（一）：综合指数与竞技场类

机构/榜单	官方入口（完整网址）	打开后先看什么
LMArena	https://lmarena.ai/	是否开启风格控制；置信区间是否重叠
Artificial Analysis	https://artificialanalysis.ai/	指数版本号；推理模式；每美元能力视图
Stanford HELM	https://crfm.stanford.edu/helm/	分维度指标，而非单一总分
Epoch AI	https://epoch.ai/	趋势曲线与私有题集说明
LiveBench	https://livebench.ai/	更新月份；分类别分数
ARC Prize	https://arcprize.org/	准确率与每题成本的双重计分
Scale AI (SEAL)	https://scale.com/leaderboard	分榜置信区间；专家命题说明
Vals AI	https://www.vals.ai/	领域是否与自身行业一致
OpenCompass 司南	https://opencompass.org.cn/	综合榜与细分榜对照
SuperCLUE	https://www.superclueai.com/	评测月份；总榜与开源子榜区分

来源：网址以官方站点为准，建议每学期开课前核对一次并截图存档。

评测门户速查表（二）：编程、智能体与专项基准

机构/榜单	官方入口（完整网址）
FlagEval（智源研究院）	https://flageval.baai.ac.cn/
SWE-bench（仓库级修复）	https://www.swebench.com/
LiveCodeBench（防污染编程）	https://livecodebench.github.io/
Terminal-Bench（终端任务）	https://www.tbench.ai/
τ^2 -bench（多轮工具调用）	https://github.com/sierra-research/tau2-bench
BFCL（函数调用）	https://gorilla.cs.berkeley.edu/leaderboard.html
GAIA（多步真实任务）	https://huggingface.co/spaces/gaia-benchmark/leaderboard
OSWorld（操作系统操作）	https://os-world.github.io/
WebArena（网页操作）	https://webarena.dev/
MMMU（多模态理解）	https://mmmu-benchmark.github.io/
MTEB（嵌入与检索）	https://huggingface.co/spaces/mteb/leaderboard
Open ASR（语音识别）	https://huggingface.co/spaces/hf-audio/open_asr_leaderboard
AA 文生图竞技场	https://artificialanalysis.ai/text-to-image/arena
AA 视频竞技场	https://artificialanalysis.ai/video/arena

来源：表中网址均为官方入口；部分站点在校园网环境下可能需要代理访问（如 Hugging Face）。

机构可信度评估框架

判断一个榜单能不能用，先问六个问题。

- ▶ 独立性 (Independence): 资金来自谁? 是否向被评对象收费?
- ▶ 方法透明度 (Transparency): 题目、提示、参数是否公开?
- ▶ 可复现性 (Reproducibility): 外部能否重跑得到相近结果?
- ▶ 更新频率 (Cadence): 多久更新一次? 题集是否滚动更新?
- ▶ 覆盖与偏差 (Coverage): 覆盖哪些语言、领域与任务形态?
- ▶ 统计严谨性 (Statistical Rigor): 是否给出置信区间与样本量?

关键术语 Key Terms

独立性 Independence

透明度 Transparency

可复现性 Reproducibility

置信区间 Confidence Interval



图示 Diagram | 可信度六问：独立性·方法透明度·可复现性·更新频率·覆盖与偏差·统计严谨性。六项中缺三项以上，该榜单只宜作参考。

同一模型为何在各榜排名不同

■ 排名差异大多不是“谁在说谎”，而是口径不同。

- ▶ 题集不同：有的偏学术知识，有的偏真实任务。
- ▶ 配置不同：是否开启推理模式、思考预算多大、是否允许工具。
- ▶ 判定方式不同：人工投票偏好、自动判分、还是测试用例通过。
- ▶ 时间不同：模型更新与榜单快照存在时差，且新版模型常处于“待测”状态。

关键术语 Key Terms

口径差异 Methodology Gap

快照时差 Snapshot Lag

配置敏感性 Config Sensitivity

评测生态 Evaluation Ecosystem

💡 例 Example | 同一个模型可以同时是：A 榜第一（人类偏好）、B 榜第五（客观题）、C 榜未收录（评测时未开启推理模式）。三个结果都真实，只是口径不同。

课堂填录表：把官方榜单读成一张自己的对比表

模型家族	综合能力	单价档位	输出速度	上下文	证据来源与日期
GPT 系列					
Claude 系列					
Gemini 系列					
Qwen 系列					
DeepSeek 系列					
Llama 系列					
Mistral 系列					

使用方式：上课前从官方榜单抄录当周数据填入；每格必须写清“来源 + 日期”，否则该数据不得用于决策。

07

怎样读榜才不会被误导

评测的三个层次

能力基准、人类偏好、业务验收回答的是三个不同问题。

- ▶ 能力基准 (Capability Benchmark): 在标准题集上“能不能做对”, 可复现、可比。
- ▶ 人类偏好 (Human Preference): 用户“更喜欢哪个”, 反映体验, 不保证正确。
- ▶ 业务验收 (Business Acceptance): 在自建黄金样本上“能不能用”, 最贴近需求但不可跨组织比较。
- ▶ 三者缺一不可: 用基准筛候选, 用偏好评体验, 用自建评测做最终决定。

关键术语 Key Terms

能力基准 Capability Benchmark

人类偏好 Human Preference

黄金样本 Golden Set

验收标准 Acceptance Criteria

 图示 Diagram | 评测三层次: 能力基准回答“能不能做对”, 人类偏好回答“喜不喜欢”, 业务验收回答“能不能用”。三者不可互相替代。

常见计分机制解剖：五种分数背后的含义

计分方式	怎么算	它的弱点
准确率 / 通过率	答对或任务完成的百分比	题目难度决定区分度；公开题易被污染
Elo / Bradley-Terry	由两两胜负关系拟合相对实力	只反映相对偏好，不反映绝对正确；受投票人群影响
加权综合指数	多个基准按权重合成一个分数	权重由机构设定，换一组权重可能换一个冠军
效率计分	把成本或算力纳入分母	成本口径（是否含重试、缓存）常不一致
LLM 评审	用另一个模型当裁判打分	存在位置偏差、长度偏差与自我偏好
专家评分	由持证专业人士判定	成本高、样本量小、评分者间一致性需检验

来源：机制说明为通用方法学归纳；具体机构的一次评测可能同时使用多种计分方式。

陷阱一：数据污染与刷榜

■ 题目在训练数据里出现过，分数就不再代表能力。

- ▶ 数据污染 (Data Contamination)：测试题或其近似文本进入训练语料。
- ▶ 表现为分数异常高、但换个说法就答错；对题目措辞极度敏感。
- ▶ 缓解方式：私有题集、时间切片（只用训练截止后的新题）、滚动更新。
- ▶ 判断线索：该模型在其他独立基准上是否表现出同等的水平。

关键术语 Key Terms

数据污染 Data Contamination

时间切片 Time-sliced

私有题集 Private Held-out Set

刷榜 Benchmark Gaming

💡 例 Example | 数据污染的典型信号：在榜单上分数异常高，但换个问法就答错；对题目措辞、选项顺序异常敏感。此时高分不再代表能力。

陷阱二：Prompt 与配置敏感性

同一个模型，换个提示就能差出十几个百分点。

- ▶ 提示措辞、示例数量、是否要求分步推理都会影响成绩。
- ▶ 推理模式（Reasoning）开与不开，是两个不同的成本与能力档位。
- ▶ 是否允许使用工具、允许多少步、超时多久，都会改变结果。
- ▶ 读榜动作：先找“配置说明”，没有配置说明的分数不可比。

关键术语 Key Terms

提示敏感性 Prompt Sensitivity

配置说明 Configuration Disclosure

思考预算 Thinking Budget

可比性 Comparability

💡 例 Example | 同一个模型、同一个问题：普通提示可能得 68 分，加一句“请分步推理”变 79 分，开启推理模式变 84 分——三个数字都是真的，但不可混用。

陷阱三：平均分掩盖分布

■ 总分相等的两个模型，可能在不同任务上完全互补。

- ▶ 综合分数是加权平均，会掩盖极端值：某些类别可能接近不可用。
- ▶ 应看分项雷达图或分榜，寻找系统性短板（如多语言、长文本、工具调用）。
- ▶ 对具体任务而言，“平均分高”不如“该项分高且稳定”。
- ▶ 实例：写作强但结构化抽取弱的模型，不适合做单证处理。

关键术语 Key Terms

分项得分 Sub-score

雷达图 Radar Chart

系统性短板 Systematic Weakness

任务适配 Task Fit

💡 例 Example | 总分 80：编程 92 分、多语言 55 分。如果你的任务是多语言，这个总分具有误导性——应看分项得分与最短的那块板。

陷阱四：统计显著性与置信区间

■ 名次相差一名，可能只是随机波动。

- ▶ 竞技场类榜单给出置信区间，重叠时不能断言“更强”。
- ▶ 样本量、题目数量、随机种子都会带来方差。
- ▶ 报告中位数与多次运行结果，比报告单次最好成绩更诚实。
- ▶ 课堂判据：“如果重跑一次会不会翻转？会翻转的结论不要写进报告。”

关键术语 Key Terms

置信区间 Confidence Interval
统计显著性 Statistical Significance

方差 Variance
可重复性 Repeatability

📌 统计 Statistical | 名次相差一名且置信区间重叠时，正确表述是“统计上不可区分”，而不是“模型 A 强于模型 B”。报告里写错这一句，整份结论的可信度都会下降。

陷阱五：成本口径不统一

“每百万词元单价”与“每次任务成本”是两个数字。

- ▶ 单价便宜但输出啰嗦、重试多的模型，总成本可能更高。
- ▶ 推理模型的思考词元同样计费，且不可见地放大成本。
- ▶ 缓存命中、批处理折扣、免费额度都会显著改变实际支出。
- ▶ 公平比较的方式：固定任务、固定验收标准，测量“每完成一次任务的成本”。

关键术语 Key Terms

词元效率 Token Efficiency

任务成本 Cost per Task

缓存命中 Cache Hit

批处理折扣 Batch Discount

 **公式 Formula** | 每任务成本 = $T_{in}P_{in} + T_{out}P_{out} + C_{think} + C_{tool} + C_{retry}$ 。把单价换算成这个数字之后，不同档位才真正可比。

陷阱六：把排行榜当结论

■ 排行榜是筛选工具，不是决策依据。

- ▶ 榜单衡量的是“平均水平”，而你的需求有具体约束与失败代价。
- ▶ 榜单更新滞后于模型发布，新模型常缺少可比数据。
- ▶ 榜单不衡量：数据合规、供应稳定性、服务条款、延迟与限流。
- ▶ 正确流程：榜单筛出 3-5 个候选 → 自建黄金样本评测 → 小流量试运行 → 定期回归。

关键术语 Key Terms

候选集 Shortlist

小流量试运行 Shadow Deployment

回归测试 Regression Test

决策依据 Decision Basis

💡 例 Example | 可复制的引用：“据〈机构〉〈日期〉榜单（配置：开启推理、未使用工具），该系列模型位于前列；实际效果以自建黄金样本评测为准。”

自建评测的最小可行方案

■ 不需要很大的工程量，就能得到比公开榜单更可靠的结论。

- ▶ 黄金样本 (Golden Set): 20–50 条真实任务，覆盖典型与极端情况。
- ▶ 双盲评审: 生成者与评审者分离，隐藏模型身份，减少确认偏差。
- ▶ 评分卡 (Rubric): 把“好”拆成可判定的维度，如事实、完整性、格式、风险。
- ▶ 回归测试: 每次换模型或改提示后重跑同一套样本，观察是否倒退。

关键术语 Key Terms

黄金样本 Golden Set


双盲评审 Blind Review

评分卡 Rubric

回归测试 Regression Test

💡 例 Example | 20 条黄金样本 + 双盲评审 + 一张评分卡，通常一个下午就能完成，却比读十份公开榜单更能回答“能不能用”这个问题。

能力—价格帕累托前沿：如何选“拐点”上的模型（示意）



真实数据：按发布时间看”能力平价化“

Intelligence Index vs. Cost per Intelligence Index Task, by Model Release ↗

All reasoning and effort variants of each selected release · Weighted average cost (USD) per Artificial Analysis Intelligence Index task

↶


🔍

📄

10 of 496 releases

↕

☰



同一坐标系，按模型发布时间着色：新版本在同一能力水平上不断向左移动，即同等能力的每任务成本持续下降。

来源：Artificial Analysis: Intelligence Index vs. Cost per Intelligence Index Task by model release。截图快照 2026-09；图为该机构榜单原始标注，引用时请注明机构与日期。

08

每百万词元单价如何变成每次任务的成本

计费要素拆解：账单上到底有什么

■ 单价只是账单的第一行，远不是全部。

- ▶ 输入词元 (Input Tokens)：你送进模型的全部内容，含系统提示、检索证据与历史。
- ▶ 输出词元 (Output Tokens)：模型生成的文字，通常单价是输入的 3-5 倍。
- ▶ 思考词元 (Reasoning Tokens)：推理模型在输出前产生的内部计算，同样计费。
- ▶ 附加项：缓存读写、批处理、图像与音频 token 化、工具调用、检索与重排。

关键术语 Key Terms

输入词元 Input Tokens

输出词元 Output Tokens

思考词元 Reasoning Tokens

词元化 Tokenization



图示 Diagram | 账单构成：输入词元·输出词元·思考词元·缓存读写·工具与检索·失败重试。多数人的预算只估了前两项。

计费要素与常见陷阱对照表

计费要素	通常的计价方式	容易踩的坑
输入词元	按每百万词元计价，输入价低于输出价	长系统提示与整篇检索结果每次都重复计费
输出词元	单价约为输入的数倍	模型“话多”会直接放大成本；格式冗余也是成本
思考词元	按输出价或专门档位计价	不可见、不可控，任务越难越贵，且难以预估
缓存（Cache）	写入贵、读取便宜（通常为输入价的极小比例）	缓存有存活时间，过期后重算；前缀变动会使缓存失效
批处理（Batch）	异步任务给折扣，通常为同步价的50%左右	延迟高，只适合离线任务；部分厂商有独立配额
多模态输入	图像按图幅与分辨率折算词元，音频按时长折算	高分辨率图片可能折算成上千词元，成本被低估
工具与检索	按次或按量计费，或折算为额外词元	智能体多轮调用会让成本呈倍数增长

来源：计费口径与折扣比例按厂商而异，具体以各厂商官方定价页为准；本表只说明结构，不含具体报价。

成本公式：把单价换成任务成本

一次任务的成本，等于所有词元与所有调用之和。

- ▶ 词元成本： $C_{\text{tok}} = T_{\text{in}}P_{\text{in}} + T_{\text{out}}P_{\text{out}}$ 。
- ▶ 完整成本： $C = C_{\text{tok}} + C_{\text{cache}} + C_{\text{tool}} + C_{\text{retry}} + C_{\text{human}}$ 。
- ▶ 词元效率 (Token Efficiency)：同一任务用更少词元完成，等于直接降价。
- ▶ 关键推论：优化提示与上下文结构，往往比换更便宜的模型更有效。

关键术语 Key Terms

词元成本 Token Cost


重试成本 Retry Cost

人工复核成本 Human Review Cost

词元效率 Token Efficiency

 **公式 Formula** | $C = T_{\text{in}}P_{\text{in}} + T_{\text{out}}P_{\text{out}}$ 。举例：输入 3,000 词元、输出 800 词元，分别乘以各自单价后相加——输出单价通常是输入的 3-5 倍。

一次任务成本的结构分解（示意，用于理解占比而非报价）



缓存与批处理：两个最容易被忽略的降价手段

同样的模型，用对策略可以让账单下降数倍。

- ▶ 提示缓存 (Prompt Caching)：把不变的前缀（系统提示、长文档、产品手册）缓存，重复调用只付低价。
- ▶ 缓存的关键是“前缀稳定”：在提示前部插入变化内容，会让缓存全部失效。
- ▶ 批处理 (Batch API)：把非实时任务改为异步提交，通常可享显著折扣。
- ▶ 选择原则：实时交互用同步 + 缓存，离线批量用批处理。

关键术语 Key Terms

提示缓存 Prompt Caching

前缀稳定 Stable Prefix

异步批处理 Asynchronous
Batch

缓存存活时间 TTL

💡 例 Example | 把系统提示与长文档放在提示最前部并保持不变，就能命中缓存；只要在中间插入一句每次都变的内容，整段缓存都会失效。

推理模型的成本弹性

思考预算是新的成本旋钮，也是最难预估的一项。

- ▶ 推理模型会在输出前进行更长的思考，思考词元按输出价计费。
- ▶ 同一问题、“低/中/高”思考档位的成本可能相差数倍。
- ▶ 成本弹性 (Cost Elasticity)：简单问题也开最高档，是常见的浪费。
- ▶ 实践策略：先按难度路由，简单任务用轻量档，只对复杂任务开高预算。

关键术语 Key Terms

成本弹性 Cost Elasticity

思考预算 Thinking Budget

模型路由 Model Routing

难度路由 Difficulty Routing

💡 例 Example | 同一个难题：低预算档 2 秒完成、成本低；最高预算档耗时 20 秒、成本数倍，而准确率提升可能只有几个百分点。预算该给谁，取决于错误的代价。

总拥有成本 (TCO) 三种形态

■ 按量付费、自托管、混合部署，三者的成本曲线形状完全不同。

- ▶ 按量付费 (Pay-per-use): 边际成本线性增长, 起步成本几乎为零, 适合不确定的用量。
- ▶ 自托管 (Self-hosting): 以固定成本为主 (显卡、机房、电力、运维), 适合稳定且大规模的负载。
- ▶ 混合部署 (Hybrid): 常规流量用便宜的自托管或轻量档, 峰值与复杂任务走 API。
- ▶ 判断依据不是“哪个便宜”, 而是“用量是否稳定、数据是否敏感、团队是否具备运维能力”。

关键术语 Key Terms

总拥有成本 Total Cost of Ownership


边际成本 Marginal Cost

固定成本 Fixed Cost

混合部署 Hybrid Deployment

 图示 Diagram | 成本曲线: 自托管以固定成本为主 (斜率小、起点高), API 以边际成本为主 (起点近零、斜率大)。两条线的交点就是盈亏平衡点。

自托管与按量付费的盈亏平衡（示意）



自托管成本要素清单：不要只算显卡

成本项	说明	常被低估的程度
加速卡	采购或云上按小时租用；推理需要足够显存容纳权重与缓存	高：显存而非算力常常是瓶颈
服务器与机房	整机、网络、机柜、散热、冗余电源	中：常被算作“已有资源”而不计入
电力与冷却	高负载下电费与制冷成本不可忽略	高：长期运行占比可观
运维人力	部署、监控、升级、故障响应、安全补丁	极高：隐性但持续
利用率损失	负载波动导致算力闲置，实际单位成本被抬高	高：按峰值配置最不经济
工程改造	推理框架、量化、批处理调度、模型更新流程	中高：一次性但影响交付周期

判断口诀：用量稳定、数据敏感、团队有运维能力——三者同时满足才考虑自托管。

隐性成本：账单之外的部分

真正的成本差异，常常不在单价上。

- ▶ 延迟成本 (Latency Cost): 慢 3 秒可能直接降低使用意愿与转化。
- ▶ 错误成本 (Error Cost): 错误率每上升 1%，人工复核与返工成本可能成倍增加。
- ▶ 切换成本 (Switching Cost): 提示、评测、工具链与流程绑定后，迁移代价高昂。
- ▶ 合规成本 (Compliance Cost): 数据出境评估、审计与合同谈判都需要投入。

关键术语 Key Terms

延迟成本 Latency Cost

错误成本 Error Cost

切换成本 Switching Cost

合规成本 Compliance Cost

💡 例 Example | 慢 3 秒、错误率上升 1 个百分点、一次迁移改造——这三项加起来，通常比模型之间的单价差异贵得多。

降本六法：按投入产出排序

■ 先做不花钱的优化，再考虑换模型。

- ▶ 一、上下文裁剪：去掉冗余历史与无关检索结果，直接降低输入词元。
- ▶ 二、提示缓存：固定前缀稳定化，让重复部分走缓存价。
- ▶ 三、模型路由：简单任务走轻量档，复杂任务才用旗舰。
- ▶ 四、语义缓存：相同或近义请求直接返回历史答案，完全不调用模型。
- ▶ 五、结构化输出：约束格式与长度，减少无效输出词元。
- ▶ 六、批处理与量化：离线任务用批处理，自托管用低比特量化降显存。

关键术语 Key Terms

语义缓存 Semantic Cache

模型路由 Model Routing

量化 Quantization

输出约束 Output Constraint

上下文裁剪 → 提示缓存 → 模型路由 → 语义缓存与批处理

价格表的三种误读

■ 报价单上的数字，最容易看错的三件事。

- ▶ 误读一：只比输入价——输出价常是输入的数倍，而输出量由任务决定。
- ▶ 误读二：忽略思考词元——推理模型的实际单价可远高于标称输出价。
- ▶ 误读三：拿不同币种与不同单位比较——USD 与 CNY、每百万与每千词元必须统一后再比。
- ▶ 正确做法：把价格表换算成“完成一次本任务的成本”，再横向比较。

关键术语 Key Terms

单位统一 Unit Normalization
标称价与有效价 List Price vs Effective Price

汇率 Exchange Rate
任务成本 Cost per Task

💡 例 Example | 输入价 0.1、输出价 0.4 看似便宜，但当输出量是输入量的 5 倍时，实际成本由输出价主导。比价必须先估算自己任务的输入输出比例。

课堂填录表：把价格表换算成任务成本

模型档位	输入价	输出价	预估词元量	单次成本	备注（缓存/批处理/思考词元）
旗舰档					
主流档					
轻量档					
推理型旗舰					
开放权重自托管					

填写要求：价格须写明币种与单位（如 USD / 每百万词元）与来源日期；单次成本按 $C = T_{in}P_{in} + T_{out}P_{out}$ 计算。

09

十三个细分方向：各自的最优区间在哪里

横向评测总框架：每个方向该看什么指标

细分方向	首要能力指标	首要成本口径	主要参考榜单类型
旗舰通用模型	综合指数、竞技场 Elo	每百万词元、每次任务	综合指数型 + 竞技场型
推理模型	数学与竞赛级推理	思考词元带来的成本弹性	学术基准型 + 综合指数型
轻量模型	单位成本能力（每美元）	单价与吞吐	综合指数型的性价比视图
开放权重模型	同规模内相对能力	自托管 TCO	社区榜 + 独立实测
代码与编码智能体	任务通过率、仓库级修复	每任务成本与步数	智能体专项型
多模态与文档理解	字段级准确率、图表理解	按图折算的词元成本	多模态专项型
语音	词错误率、主观偏好	每小时音频成本	语音专项型
图像生成	提示遵循、文字渲染	每张图成本	生成竞技场型
视频生成	时序一致性、时长	每秒视频成本	生成竞技场型
嵌入与重排	检索命中率（Recall）	每百万词元（极低）	嵌入专项型
中文与多语种	中文理解与生成质量	同通用口径	中文区域型
端侧与隐私部署	量化后能力保持度	一次性硬件 + 电耗	社区实测 + 自测
聚合平台与服务商	可用性、路由与限流	加价率与最低消费	平台公示 + 自测

用法：先定位方向，再看该方向对应的指标与榜单类型，最后用自建黄金样本确认。

方向一：旗舰通用模型

比什么 Metrics

综合智能指数、竞技场偏好 Elo、分领域（编码、数学、写作、长难提示）得分；上下文窗口与实际可用长度；多语言覆盖。

成本怎么算 Cost

输入与输出单价、思考词元是否另计、缓存折扣、批处理折扣；把“每百万词元”换算为“每完成一次本任务的成本”。

官方入口 Where

LMarena（人类偏好）与 Artificial Analysis（实测指数、速度、价格）是这一方向的两条主线；两者结论可能不同，需同时看。

选型要点与边界 Selection

旗舰优势集中在复杂推理与长链条任务；对短分类、简单抽取等任务，旗舰与轻量档的差距常小于价格差距。旗舰也是“能力上限”的参照物，适合做基准而非默认选择。

方向二：推理模型

比什么 Metrics

数学与竞赛级题目、科学推理、复杂代码、规划类任务；重点看高分背后的“思考预算”是多少。

成本怎么算 Cost

思考词元按输出价或专门档位计费；问题不同思考档位的成本差异可达数倍，必须按档位分别报价。

官方入口 Where

学术基准（专家级数学、竞赛题）与综合指数型榜单；注意区分是否开启推理模式，以及是否允许工具。

选型要点与边界 Selection

适合多步、可验证、值得等待的任务；不适合高频简单问答。收益递减明显：思考预算翻倍带来的准确率提升通常远小于成本增幅。务必设置思考预算上限。

方向三：轻量模型与低成本档

比什么 Metrics

单位成本能力（每美元能买到多少有效能力）、吞吐量、稳定性；分类与抽取类任务的准确率。

成本怎么算 Cost

单价低是表象：要看在小样本提示下的准确率是否够用，以及是否需要更多重试。

官方入口 Where

综合指数型榜单的性价比视图，以及独立实测平台的“每美元能力”排序；社区榜可看同规模模型对比。

选型要点与边界 Selection

高价值用法：批量预处理（分类、打标签、粗筛、翻译初稿）、模型路由中的第一跳、以及隐私要求不高的边缘任务。风险在于复杂指令遵循与长上下文能力弱，容易在边界样本上失手。

方向四：开放权重模型

比什么 Metrics

同规模内的相对能力、量化后的能力保持度、推理吞吐与显存占用；微调生态的成熟度。

成本怎么算 Cost

自托管 TCO：加速卡、机房、电力、运维与利用率损失；对照按量付费求盈亏平衡点。

官方入口 Where


社区开放模型榜（注意版本与日期）、独立实测平台的开放权重分组、以及参数规模分组榜。

选型要点与边界 Selection

核心价值是可控与议价能力：可私有化、可微调、可脱离外部服务运行。代价是工程投入与运维责任。务必逐版确认许可证条款（商用、命名、规模门槛）。

真实数据：开放度指数 vs 智能指数

Artificial Analysis Openness Index vs. Artificial Analysis Intelligence Index



纵轴为开放度指数，横轴为智能指数。开放权重模型（DeepSeek、GLM、Kimi 等）已进入高智能区间，但开放度与能力并不天然同步。

来源：Artificial Analysis: Openness Index vs. Intelligence Index。截图快照 2026-09；图为该机构榜单原始标注，引用时请注明机构与日期。

方向五：代码与编码智能体

比什么 Metrics

仓库级修复通过率、终端任务完成率、竞赛题通过率；同时记录步数与成本。

成本怎么算 Cost

按“每完成一个任务”计费更公平：含多次尝试、测试运行与失败重试；上下文越长成本越高。

官方入口 Where

智能体专项榜：仓库级修复基准、终端任务基准、按时间切片的竞赛题基准；均需注意数据集版本。


选型要点与边界 Selection

这是目前验证最充分的方向，因为有测试用例提供客观反馈。边界在于：私有代码库、非主流语言与遗留系统的表现需要自行评测。

真实数据：编码智能体指数 vs 每任务成本

Artificial Analysis Coding Agent Index vs. Cost per Task

Artificial Analysis Coding Agent Index vs. average pay-per-token API cost per task (USD)



编码智能体必须同时看两项：任务完成质量与每任务成本。只看指数，会忽略掉可能相差一个数量级的成本。

来源：Artificial Analysis: Coding Agent Index vs. Cost per Task. 截图快照 2026-09；图为该机构榜单原始标注，引用时请注明机构与日期。

方向六：多模态与文档理解

比什么 Metrics

字段级准确率（而非整体相似度）、复杂版式鲁棒性、图表与表格理解、屏幕操作能力。

成本怎么算 Cost

图像按分辨率折算词元，高分辨率大图可能折算成上千词元；视频与音频按时长折算。

官方入口 Where

多模态专项基准（大学水平图文理解、长视频理解、文档问答、文字识别）与综合指数型的视觉分榜。

选型要点与边界 Selection

通用视觉能力强的模型，未必在票据、手写体与低质量扫描件上可靠。关键字段必须结合规则校验或人工复核；不要把“认出了大部分文字”当作“抽取正确”。

方向七：语音（识别、合成与实时对话）

比什么 Metrics

识别看词错误率 (WER) 与实时率 (RTF_x)；合成与对话看主观偏好、自然度与响应延迟。

成本怎么算 Cost

按音频时长计费（每分钟或每小时）；实时语音对话因双向流式传输，成本结构不同于离线转写。

官方入口 Where

Hugging Face 开放语音识别榜（多数据集宏平均 + 实时率）；语音合成竞技场；综合指数型的语音分项。

选型要点与边界 Selection

务必在自身场景（口音、噪声、专业术语、多人对话）上自测：公开榜的干净语音成绩通常显著优于真实通话。实时对话还要评估打断处理与端到端延迟。

方向八：图像生成

比什么 Metrics

人类偏好 Elo、提示遵循度、文字渲染正确率、构图与一致性；批量生成的稳定性。

成本怎么算 Cost

按张计费，不同分辨率与质量档位价格不同；重绘与迭代会成倍增加成本。

官方入口 Where

生成竞技场型榜单（人类偏好）与自动指标（提示遵循、美学、文字渲染）。

选型要点与边界 Selection

偏好类排名主观性最强，且不同竞技场的题面与投票人群不同，结论不宜跨场比较。商用场景要额外确认训练数据与版权条款、以及是否支持商用授权。


真实数据：文生图排行榜

Text to Image Leaderboard

Elo scores from blind preference votes in our Image Arena. [See the full leaderboard here.](#)

15 of 161 models

Artificial Analysis



图像生成以人类偏好投票形成排名，主观性最强；商用前仍需确认训练数据与版权条款。

来源：Artificial Analysis：Text to Image Leaderboard。截图快照 2026-09；图为该机构榜单原始标注，引用时请注明机构与日期。

方向九：视频生成

比什么 Metrics

时长与分辨率、时序一致性（是否抖动或变形）、物理合理性、镜头控制能力。

成本怎么算 Cost

按秒或按次计费，成本显著高于图像；重生成代价大，需先做低分辨率草稿。

官方入口 Where

视频生成竞技场（人类偏好）与自动评测基准（时序一致性与语义对齐）。

选型要点与边界 Selection

当前主要瓶颈是时序一致性与可控性，而非单帧画质。适合短镜头素材与概念演示；长视频叙事仍需人工剪辑与拼接。

方向十：嵌入与重排模型

比什么 Metrics

检索命中率 (Recall@k)、排序质量 (nDCG)、多语言与长文本支持、向量维度与存储成本。

成本怎么算 Cost

单价极低但不是零：向量化整个知识库是一次性成本，之后每次查询也要嵌入。

官方入口 Where

大规模文本嵌入基准 (MTEB/MMTEB) 的检索与重排子榜，务必看中文或多语言分榜而非总榜。

选型要点与边界 Selection

嵌入模型决定检索上限，是检索增强系统中最容易被忽视却最影响效果的一环。嵌入与重排必须成对选型：重排能显著提升精度，但会增加延迟。

方向十一：中文与多语种能力

比什么 Metrics

中文理解与生成质量、专业术语与文体恰当性、小语种的覆盖与稳定性；中英混排处理。

成本怎么算 Cost

中文词元化效率影响成本：同一段文字在不同分词方案下的词元数可能差异明显。

官方入口 Where

中文区域型榜单（综合榜 + 细分榜）、中文学术基准、以及多语言分榜。

选型要点与边界 Selection

国际模型的中文能力近年提升很快，但方言、成语、公文语体与中文长文本仍是差异点。多语种场景要按目标语言分别评测，不能用“中英表现好”外推到小语种。

方向十二：端侧与隐私部署

比什么 Metrics

量化后的能力保持度、首字延迟与吐字速度、内存占用与功耗、离线可用性。

成本怎么算 Cost

以一次性硬件投入与电耗为主，边际成本接近零；代价是能力上限与更新频率受限。

官方入口 Where

社区小模型榜（按参数量分组）、端侧推理框架的官方基准、以及自建任务测试。

选型要点与边界 Selection

适合固定窄任务（分类、抽取、改写、离线转写）与数据不得外传的场景。切勿用端侧小模型承担复杂推理与长上下文任务；量化到低比特后能力下降需要逐档验证。

方向十三：聚合平台与推理服务商

比什么 Metrics

可用性与限流策略、模型覆盖广度、故障切换能力、数据留存政策、结算与发票合规。

成本怎么算 Cost

存在加价率、最低消费或套餐额度；同时要算“省下的集成成本”与“多一层依赖的风险”。

官方入口 Where

平台自身的状态页与定价页（作为代理信息需标注）、独立实测平台的平台对比、以及自建压测。

选型要点与边界 Selection

聚合平台的价值在于降低多模型比对与切换成本；风险是形成新的中间层依赖，并可能引入额外的数据留存条款。生产环境建议保留直连通道作为兜底。

填录表一：通用与推理档位横向对比

模型家族	综合指数	竞技场 Elo	输出速度	输入/输出价	证据来源与日期
旗舰通用（家族一）					
旗舰通用（家族二）					
推理型旗舰					
主流档					
轻量档					

填录表二：开放权重、编码与多模态横向对比

模型家族	仓库级修复	文档抽取	量化后能力	自托管成本	证据来源与日期
开放权重（家族一）					
开放权重（家族二）					
编码专用					
多模态旗舰					
语音模型					

填录表三：生成、嵌入与中文能力横向对比

模型家族	生成偏好	提示遵循	检索命中率	中文质量	证据来源与日期
图像生成（家族一）					
视频生成（家族一）					
嵌入模型					
重排模型					
中文优化模型					

横向对比的三条纪律

■ 做到这三点，结论才站得住。

- ▶ 同一次对比必须固定：任务、提示、验收标准与时间窗口。
- ▶ 每个数字都要能追溯到“哪个机构、哪一天、什么配置”。
- ▶ 结论要声明边界：适用于什么任务、不适用于什么任务、样本量多少。

关键术语 Key Terms

控制变量 Controlled Variables

可追溯 Traceability

结论边界 Scope of Validity

样本量 Sample Size

💡 例 Example | 三条纪律的反面：换了模型却不换提示、数据不写来源日期、结论不写适用边界——这样的对比任何人都无法复核，也就没有决策价值。

10

从榜单到决策：一套可复核的流程

选型七步法

■ 把“哪个模型好”这个无法回答的问题，改造成一系列可以回答的问题。

- ▶ 一、定义任务与验收证据：什么算完成？谁来判定？
- ▶ 二、列出约束：成本上限、延迟要求、数据合规、部署位置。
- ▶ 三、用榜单与分类收敛候选集（3-5 个）。
- ▶ 四、设计 PoC：黄金样本、评分卡、双盲评测。
- ▶ 五、结算成本：按每完成一次任务计算，而非只看单价。
- ▶ 六、小流量试运行，观察真实分布下的表现。
- ▶ 七、上线后建立回归测试与监控，定期重新评估。

关键术语 Key Terms

验收证据 Acceptance Evidence


概念验证 Proof of Concept

小流量试运行 Shadow Deployment

持续评估 Continuous Evaluation

定义任务与验收 → 列出硬软约束 → 收敛候选集 → PoC 与成本结算

选型流程：每一步都有明确的产出物



四类约束：先写下来，再讨论模型

■ 约束是可谈判的，但必须先明确哪些不可谈。

- ▶ 硬约束 (Hard Constraint)：数据不得出境、必须私有化部署、必须支持某语言。
- ▶ 软约束 (Soft Constraint)：希望在多少延迟内返回、期望的成本区间。
- ▶ 隐性约束 (Implicit Constraint)：团队能否运维、是否已有云协议、采购流程周期。
- ▶ 写清约束的收益：候选集通常能从几十个直接收敛到三五个。

关键术语 Key Terms

硬约束 Hard Constraint

软约束 Soft Constraint

隐性约束 Implicit Constraint

采购周期 Procurement Cycle

💡 例 Example | “数据不得出境”是一条硬约束，它会一次性排除全部海外闭源云 API。先把约束写下来，能省掉大量无效的模型比较。

加权评分卡模板：把主观判断变成可复核的打分

评分维度	权重	候选 A	候选 B	候选 C	判定依据（必须可查证）
任务准确率	30%				黄金样本通过率
事实可靠性	20%				幻觉率、引用可查证比例
每任务成本	15%				按公式结算，含重试
延迟与吞吐	10%				首字延迟、每秒输出词元
格式遵循	10%				结构化输出合法率
合规与部署	10%				数据驻留、私有化能力
供应与条款	5%				开放策略、SLA、退出方案
合计	100%				一票否决项：隐私泄露、越权承诺、无法审计

权重必须由业务方确定，不能由模型或供应商推荐；同一权重体系下才可横向比较。

概念验证 (PoC) 应该怎么做

■ PoC 的目标不是“证明它行”，而是“找出它会怎么失败”。

- ▶ 样本设计：覆盖典型样本、边界样本与已知困难样本，各占一定比例。
- ▶ 评测方式：双盲、多方独立评分，避免“自己测自己的方案”。
- ▶ 记录内容：不只看正确与否，还要记录失败类型、耗时、成本与人工返工量。
- ▶ 通过标准要事先写定：例如“准确率不低于 X 且单次成本不超过 Y”。

关键术语 Key Terms

边界样本	Edge Case
失败模式	Failure Mode
通过标准	Pass Criteria
人工返工	Rework

💡 例 Example | PoC 的价值在于发现失败方式：20 条样本里有 3 条因“输出格式不合法”失败，说明该优先解决的是结构化输出，而不是更换模型。

■ 模型选错的成本，往往小于供应商关系破裂的成本。

- ▶ 服务条款：数据是否被用于训练、留存多久、能否用于敏感数据。
- ▶ 可用性：限流策略、容量保障、故障历史与状态页透明度。
- ▶ 退出策略：权重能否下载、数据能否导出、切换需要多少工作量。
- ▶ 合规：跨境数据传输、行业监管要求、审计与留痕能力。

关键术语 Key Terms

服务等级协议 SLA

数据留存 Data Retention

退出策略 Exit Strategy

可审计性 Auditability

💡 例 Example | 合同里一句“客户数据可用于改进服务”，可能直接决定这套方案能否通过合规审查——这类条款要在选型早期确认，而不是上线前。

十个常见反模式

■ 这些做法看起来省事，实际会在半年后付出代价。

- ▶ 一、用旗舰模型做所有事；二、只比单价不比任务成本。
- ▶ 三、只看一个榜单就做决定；四、忽略延迟对体验的破坏。
- ▶ 五、把评测集与提示一起“调”到过拟合；六、没有回归测试就换模型。
- ▶ 七、把关键规则只写在提示里；八、没有成本与轮次上限。
- ▶ 九、忽视许可证与数据条款；十、没有退出方案就深度绑定。

关键术语 Key Terms

反模式 Anti-pattern

过拟合评测集 Overfitting the
Test Set

轮次上限 Turn Limit

质量门禁 Quality Gate

追旗舰做全部任务 → 无回归测试换模型 → 无退出方案深度绑定 → (结果：成本与风险双高)

决策矩阵：不同约束下的推荐档位

场景约束	推荐档位	理由与注意事项
高频、任务简单、可批量	轻量档 + 批处理	单位成本最优；需用黄金样本确认准确率达标
低频、任务复杂、可等待	推理型旗舰	用思考预算换准确率；务必设预算上限
数据不得出境	开放权重 + 私有化	先确认许可证与显存需求，再评估运维投入
延迟敏感、交互频繁	主流档 + 缓存	首字延迟比总分更重要的场景
多模态输入、字段级精度	多模态旗舰 + 规则校验	关键字段必须二次校验，不能只靠模型
知识库问答	主流档 + 检索 + 重排	效果上限由检索质量决定，而非模型规模
探索与快速验证	聚合平台 + 免费额度	降低试错成本；生产环境保留直连兜底

本节小结：把决策变成可复核的证据链

好的选型报告，任何人都能沿着证据链复核你的结论。

- ▶ 每个结论都要能回答：“依据哪份榜单、哪一天、什么配置、多少样本？”
- ▶ 每个成本数字都要写明币种、单位与计算方式。
- ▶ 每个推荐都要写清适用边界与已知失效场景。
- ▶ 最终交付物不是“推荐某个模型”，而是“一套可持续更新的评估流程”。

关键术语 Key Terms

证据链 Evidence Chain

适用边界 Scope

可复核 Auditable

可持续评估 Sustainable Evaluation

榜单证据（机构 + 日期）

→ 自建样本结论

→ 每任务成本结算

→ 适用边界与风险

11

动手比较一次，并知道结论的边界

实训一：多模型同任务盲测

任务设计

- ▶ 选一个可客观判定的任务（如结构化抽取或分类），准备 10–20 条样本。
- ▶ 把同一提示分别送给至少 3 个不同档位的模型（隐藏模型身份）。
- ▶ 由同学互换评审，按评分卡打分。
- ▶ 记录：准确率、失败类型、耗时、成本、人工返工量。

记录项	A	B	C	备注
准确率				
失败类型				
单次成本				
平均耗时				
返工量				

讨论问题：准确率最高的模型，是否也是“最划算”的？在什么条件下结论会反转？

实训二：成本估算与盈亏平衡

任务设计

- ▶ 估算一条业务流一天/一月的词元量（输入、输出、思考分别估）。
- ▶ 按 $C = T_{\text{in}} P_{\text{in}} + T_{\text{out}} P_{\text{out}}$ 计算三个档位的月度成本。
- ▶ 估算自托管的固定成本（显卡、电力、运维），求盈亏平衡点。
- ▶ 讨论：哪些假设最脆弱？如果用量减半结论是否改变？

提示：价格必须写明币种、单位与来源日期；没有来源的数字不得用于结论。

项目	轻量	主流	旗舰	备注
输入词元/月				
输出词元/月				
月度成本				
自托管成本				
平衡点				

实训三：读榜找茬——指出三个可能的误导点

任务设计

- ▶ 打开任意一个第三方榜单，用第 7 节的六个陷阱逐条检查。
- ▶ 找出至少三处可能导致误读的地方，并写出理由。
- ▶ 写出一段“正确的引用方式”（含机构、日期、配置与限制条件）。
- ▶ 交换检查：同学之间互相质疑对方的结论。

编号	发现的误导点与理由
1	
2	
3	

风险清单：比能力更值得关注的四件事

■ 模型会变，风险不会自己消失。

- ▶ 时效性风险 (Freshness)：榜单与价格随时变动，任何数据都必须标注日期。
- ▶ 污染风险 (Contamination)：公开题集可能进入训练数据，高分未必代表能力。
- ▶ 供应风险 (Supply)：模型下线、改价、限流、条款变更都会影响既有系统。
- ▶ 合规风险 (Compliance)：数据出境、行业监管与版权问题需要专业判断。

关键术语 Key Terms

时效性风险 Freshness Risk

污染风险 Contamination Risk

供应风险 Supply Risk

合规风险 Compliance Risk

💡 例 Example | 榜单每月在变、价格随时在调、条款随时在改。因此真正值得投入的，是“每学期更新一次”的流程，而不是某一天的结论。

总结：本讲的三件套

■ 一张地图、一张表、一个公式。

- ▶ 一张地图：产业五层结构与三条组织路线（闭源 / 开放权重 / 云厂商自研）。
- ▶ 一张表：分方向的“指标—成本—入口”对照表，加上你自己的黄金样本结论。
- ▶ 一个公式： $C = T_{in}P_{in} + T_{out}P_{out} + C_{cache} + C_{tool} + C_{retry}$ ，把单价变成任务成本。
- ▶ 一句提醒：方法比结论耐用——榜单会变，读榜的方法不会。

关键术语 Key Terms

证据链 Evidence Chain

任务成本 Cost per Task

方法耐久性 Durability of Method

持续更新 Continuous Update

📌 公式 Formula | 只需要背下来的一个公式： $C = T_{in}P_{in} + T_{out}P_{out} + C_{cache} + C_{tool} + C_{retry}$ 。它把“每百万词元单价”翻译成“每完成一次业务的成本”。

用一个可以复核的流程，完成一次真正的比较。

- ▶ 一、选定一个可客观判定的任务，准备 20 条黄金样本。
- ▶ 二、选择三个不同档位的模型，完成盲测并填写评分卡。
- ▶ 三、估算三者的“每完成一次任务”的成本，画出能力—成本散点图。
- ▶ 四、写一页《模型选型说明》：包括约束、证据、结论、适用边界与风险控制。

关键术语 Key Terms

黄金样本 Golden Set

评分卡 Rubric

选型说明 Selection Memo

适用边界 Scope

💡 例 Example | 作业交付模板：约束一页（硬软约束清单）、证据一页（榜单与自测数据，含日期）、结论半页、风险与边界半页。

类别	代表资料	用途
架构奠基	《Attention Is All You Need》(2017)	理解注意力与 Transformer 的原始动机
规模范式	GPT-3 论文 (2020)、规模定律相关研究	理解“为什么要把模型做大”
对齐方法	InstructGPT 论文 (2022)	理解指令微调与人类反馈
智能体范式	ReAct 论文 (2022)、Toolformer (2023)	理解推理—行动循环与工具学习
协议规范	模型上下文协议 (MCP) 官方规范	理解工具接口标准化的设计
评测方法	各机构的方法说明页与年度报告	理解分数是怎么算出来的
价格与规格	各厂商官方定价页与模型文档	获取可追溯的价格与上下文参数

引用纪律：论文引用版本与年份；榜单引用机构、日期与配置；价格引用币种、单位与抓取日期。

附录

术语总表与使用说明

附录 A：术语总表（一）中英对照

中文	English	中文	English
大语言模型	Large Language Model (LLM)	智能体	Agent
基础模型	Foundation Model	工具调用	Tool Calling
词元	Token	函数调用	Function Calling
上下文窗口	Context Window	模型上下文协议	Model Context Protocol (MCP)
提示	Prompt	外壳	Harness
上下文工程	Context Engineering	沙箱	Sandbox
检索增强生成	Retrieval-Augmented Generation	人在回路	Human-in-the-Loop
嵌入	Embedding	提示注入	Prompt Injection
重排	Reranking	智能体编排	Agent Orchestration
微调	Fine-tuning	多智能体	Multi-agent
指令微调	Instruction Tuning	计算机操作	Computer Use
人类反馈强化学习	RLHF	代码智能体	Coding Agent
蒸馏	Distillation	任务完成率	Task Success Rate
量化	Quantization	复合错误	Error Compounding
混合专家	Mixture-of-Experts (MoE)	基准测试	Benchmark
激活参数	Active Parameters	排行榜	Leaderboard
稠密模型	Dense Model	数据污染	Data Contamination
推理	Inference	置信区间	Confidence Interval

附录 B：术语总表（二）中英对照

中文	English	中文	English
推理模型	Reasoning Model	帕累托前沿	Pareto Frontier
测试时计算	Test-time Compute	总拥有成本	Total Cost of Ownership
思维链	Chain-of-Thought	边际成本	Marginal Cost
思考预算	Thinking Budget	提示缓存	Prompt Caching
成本弹性	Cost Elasticity	批处理	Batch Processing
幻觉	Hallucination	词元效率	Token Efficiency
人类偏好	Human Preference	模型路由	Model Routing
竞技场	Arena	语义缓存	Semantic Cache
布拉德利-特里模型	Bradley-Terry Model	供应商锁定	Vendor Lock-in
黄金样本	Golden Set	开放权重	Open Weights
评分卡	Rubric	自托管	Self-hosting
回归测试	Regression Test	私有化部署	On-premise Deployment
双盲评审	Blind Review	小模型	Small Language Model (SLM)
控制变量	Controlled Variables	端侧推理	On-device Inference
方法透明度	Methodological Transparency	多模态	Multimodal
可复现性	Reproducibility	词错误率	Word Error Rate (WER)
统计显著性	Statistical Significance	实时率	Real-Time Factor (RTFx)
供应商自评测	Vendor Benchmark	服务等级协议	Service Level Agreement

附录 C：使用说明与更新约定

本讲的数据处理方式

- ▶ 标注为“示意”的图表只说明形状与趋势；未标注“示意”的图表为官方榜单截图，引用时须注明机构与快照日期。
- ▶ 所有涉及“最新结果”的页面，均提供官方入口与读取要点。
- ▶ 涉及“最新结果”的页面均给出官方入口链接，便于课前用当周数据核对更新。
- ▶ 模型一律以“系列”称谓，避免版本迭代导致课件过期。

更新原则：宁可留白并标注“待核实”，也不填入无法追溯来源的数字。

每学期更新清单

- ▶ 从各机构官方榜单抄录当周数据，填入三张填录表。
- ▶ 核对厂商官方定价页，更新币种、单位与日期。
- ▶ 复核开放权重模型的许可证条款是否有变更。
- ▶ 检查课件中引用的榜单是否改版或归档，并更新入口。

谢谢

下一步：用同一任务、同一评分卡，亲手比较三个不同档位的模型。

模块二 | 第二讲 | AI 工具及大模型的性能比较