



海外市场调研智能化

从宏观信息、竞争情报到客户画像：AI 辅助下的市场机会识别

模块三 | 第一讲 | 面向非计算机专业学生

学习目标 (Learning Objectives)

1. 说清海外市场调研在贸易流程中的位置，以及 AI 改变与没有改变的部分。
2. 建立五层数据源体系，能按问题选择数据源，并识别常见的统计口径陷阱。
3. 用机器学习方法做 ** 产品横向竞争情报分析 **：聚类、降维、主题模型、分类与异常检测。
4. 用时间序列方法做 ** 产品趋势识别 **：分解、平滑、ARIMA、变点检测与预测评估。
5. 用 API 与代码批量获取海关数据、电商热销数据与地理信息客户名单（三项实操）。
6. 建立目标市场筛选评分卡，把长名单收敛为短名单。
7. 掌握 AI 调研输出的验证方法（证据链五要素与三重验证），并能写出可信的调研结论。

本讲路线图：十二节，从数据到决策

节	主题	回答的问题
1	调研的位置	为什么先调研，AI 改变了什么？
2	数据源体系	数据从哪里来，口径怎么对齐？
3	检索式与工具协同	搜索、平台与 AI 如何分工？
4	实操一：海关数据 API	怎样用代码批量拉取多国多年贸易数据？
5	实操二：电商热销数据	怎样合法获得并分析竞品价格与口碑？
6	实操三：地图找进口商	怎样按地区批量获取候选客户名单？
7	横向竞争情报	用机器学习把竞品看清：聚类·降维·主题·分类
8	纵向趋势与选市场	用时间序列判断趋势，用评分卡筛选市场
9	客户画像与 ICP	谁才是值得投入的客户？
10	可信度与可用性	怎样保证 AI 输出能用于决策？
11	案例教学	深圳消费电子目标市场调研怎么做？
12	总结	一张流程图与一份数据源清单。

01

为什么先调研：三个问题与三种去向

调研要回答的三个问题

■ 市场有多大、竞争什么样、客户要什么——顺序不能颠倒。

- ▶ 市场规模 (Market Size): 值不值得进? 天花板在哪里?
- ▶ 竞争格局 (Competitive Landscape): 现有玩家怎么打? 空隙在哪里?
- ▶ 客户需求 (Customer Needs): 愿意为什么付费? 决策链上有谁?

关键术语 Key Terms

市场规模 Market Size

竞争格局 Competitive Landscape

客户需求 Customer Needs

决策链 Decision Chain



图示 Diagram | 三问的顺序: 先确认天花板 (否则后面全是白做) → 再看竞争强度 (决定进入方式) → 最后落到具体客户 (决定打法)。

TAM、SAM、SOM：把“市场很大”拆成三层

同一个市场，三种口径，混用就会做出错误的投入决策。

- ▶ TAM (总体潜在市场)：该品类在全球或全区域的全部需求。
- ▶ SAM (可服务市场)：你的产品与渠道能覆盖到的那部分。
- ▶ SOM (可获得市场)：短期内凭现有资源真正能拿到的份额。

关键术语 Key Terms

总体潜在市场 TAM

可服务市场 SAM

可获得市场 SOM

自下而上估算 Bottom-up

📊 公式 Formula | $SOM \approx SAM \times \text{可获得份额}$ ；课堂经验值：新进入者第一年通常只取 SAM 的 0.5%–2%，把它当作投入上限而不是目标。

传统海外调研的三个痛点

I 周期长、成本高、信息滞后——这正是 AI 能帮上忙的地方。

- ▶ 周期：委托调研机构从立项到交付常以月计，错过销售窗口。
- ▶ 成本：一份定制的国别行业报告价格不低，中小企业难以承受。
- ▶ 滞后：公开报告的统计年份往往落后一到两年，与当下竞争态势脱节。

关键术语 Key Terms

一手调研 Primary Research

二手调研 Secondary Research

销售窗口 Sales Window

信息滞后 Information Lag

💡 例 Example | 典型场景：展会前两周才决定要开拓某个市场，委托报告来不及——这时需要的是“能在 48 小时内给出可用线索”的快速调研。

AI 改变了什么、没改变什么

AI 压缩的是检索与归纳的时间，不是判断与验证的责任。

- ▶ 改变：多语种检索、海量文本归纳、初筛与去重、结构化输出，效率提升显著。
- ▶ 没变：数据的真实性仍要靠来源核对，商业判断仍要靠人做。
- ▶ 没变：AI 不产生新的一手数据——它只能处理已经公开或你提供的资料。

关键术语 Key Terms

二手资料处理 Secondary-data Processing


一手数据 Primary Data

责任主体 Accountability


人机分工 Human-AI Division

提示 Tip | 把 AI 定位成“研究助理”而不是“调研机构”：它可以帮你读完 200 条评论并归纳，但不能替你确认这些评论是不是刷出来的。

调研成果的三种去向



一次完整调研的工作流



本节小结：把调研当工程而不是当写作

■ 工程的特征是可复现、可追溯、可反驳。

- ▶ 先定义问题与验收标准，再决定采什么数据。
- ▶ 每一个数字都要能回答“来自哪里、什么时候、什么口径”。
- ▶ 结论要写成可被反驳的形式：给出条件、边界与不确定性。

关键术语 Key Terms

可复现 Reproducible

可追溯 Traceable

可反驳 Falsifiable

证据链 Evidence Chain

 提示 Tip | 反面教材：“根据 AI 分析，东南亚市场潜力巨大。”——这句话无法被验证，也无法指导任何决策。

02

数据从哪里来：五层数据源与三个口径陷阱

数据源的五层金字塔

■ 越往上越权威、越免费、颗粒度越粗；越往下越贵、越细、越贴近当下。

- ▶ 第一层：国际组织与多边机构——口径统一，适合做国别与品类的横向比较。
- ▶ 第二层：政府与海关统计——贸易流向的权威来源，但需要理解统计口径。
- ▶ 第三层：行业协会、展会与标准机构——细分行业的真实情报与门槛信息。
- ▶ 第四层：平台数据——最贴近当下竞争态势，但需注意其估算性质。
- ▶ 第五层：商业数据库与海关数据服务商——花钱买时间，来源合法性要确认。

关键术语 Key Terms

公开数据 Public Data

贸易统计 Trade Statistics

颗粒度 Granularity

数据可得性 Data Availability

🗺️ 图示 Diagram | 选层原则：能用第一、二层解决的问题，不要花钱买第五层；第五层的价值在于“别人还没有的信息”与“省下的时间”。

第一层：国际组织与多边机构

■ 免费、权威、口径可比——但通常只到“国家 × 品类”这一层。

- ▶ 世界银行 (World Bank): 国别宏观指标、营商与物流绩效指数。
- ▶ 联合国商品贸易统计数据库 (UN Comtrade): 按 HS 编码的进出口流向, 可查“谁在买、买了多少”。
- ▶ 国际贸易中心 (ITC Trade Map): 把 Comtrade 做成更易读的国别与品类分析。
- ▶ WTO、OECD、UNCTAD: 多用于规则、关税与投资环境背景。

关键术语 Key Terms

商品名称及编码协调制度 HS
Code

贸易流向 Trade Flow

关税数据 Tariff Data

营商环境 Doing Business

 图示 Diagram | 典型用法: 先用 Comtrade 找到“近三年进口额持续增长、且进口来源分散”的国家——这类市场对新供应商的门槛通常更低。

国际组织与多边机构：官方入口一览

机构	官方入口（完整网址）	主要用途
World Bank Data	https://data.worldbank.org/	国别宏观指标、物流绩效指数
UN Comtrade	https://comtradeplus.un.org/	按 HS 编码的进出口流向与金额
ITC Trade Map	https://www.trademap.org/	Comtrade 的易读版：国别与品类分析
WTO Statistics	https://www.wto.org/english/res_e/statis_e/statis_e.htm	关税、贸易规则与争端背景
UNCTADstat	https://unctadstat.unctad.org/	投资、海运与贸易便利化数据
IMF Data	https://www.imf.org/en/Data	汇率、国际收支与宏观预测
OECD Data	https://data.oecd.org/	发达经济体的可比指标
OEC 观察经济复杂性	https://oec.world/	贸易数据的可视化探索

来源：入口地址以官方站点为准。部分站点在校园网环境下可能需代理访问；建议课前核对一次并截图存档。

第二层：政府与海关统计

■ 最权威的贸易流向数据，也是最容易误读的数据。

- ▶ 中国海关总署：本国出口数据、报关政策与统计月报。
- ▶ 美国国际贸易委员会 DataWeb：可按 HS 编码与国别查询美国进口明细，颗粒度细。
- ▶ 欧盟 Eurostat、各国统计局：目标市场的进口规模与本地消费结构。
- ▶ 商务部与贸促会：国别指南、出口管制与展会信息。

关键术语 Key Terms

海关统计 Customs Statistics

统计月报 Monthly Bulletin

国别指南 Country Guide

报关 Customs Declaration

 **实战 Practice** | 实战提醒：查“某国从中国进口某品类”时，用对方国家的进口统计比用中国的出口统计更可靠——口径在本国，且能同时看到其他供应国的份额。

政府与海关数据源：官方入口一览

机构	官方入口（完整网址）	主要用途
中国海关总署	http://www.customs.gov.cn/	报关政策、统计月报与进出口数据
中国商务部	http://www.mofcom.gov.cn/	国别贸易指南、政策与合规提示
美国 USITC DataWeb	https://dataweb.usitc.gov/	美国进口明细：HS 编码 × 国别 × 金额
美国贸易数据门户	https://www.trade.gov/data-visualization	出口市场与行业数据可视化
美国普查局外贸数据	https://www.census.gov/foreign-trade/	美国进出口月度统计原始口径
欧盟 Eurostat	https://ec.europa.eu/eurostat	欧盟成员国贸易与消费统计
日本总务省统计局	https://www.stat.go.jp/english/	日本消费与人口结构数据
新加坡统计局	https://www.singstat.gov.sg/	东南亚标杆市场的贸易与消费

来源：上述站点多为政府网站，部分对自动访问做了限制；建议用浏览器直接打开并截图存档。

第三层：行业协会、展会与标准机构

■ 细分行业最真实的情报，常常藏在这些“不性感”的地方。

- ▶ 行业协会：会员名录本身可能就是一份潜在客户或竞品清单。
- ▶ 展会：官网的参展商名单与展位图，是获取真实公司名的高质量来源。
- ▶ 标准与认证机构：决定“能不能卖”的硬门槛（CE、FCC、UL、RoHS、REACH）。
- ▶ 行业研究机构：提供出货量与份额（如消费电子的 Canalsys、IDC、Counterpoint）。

关键术语 Key Terms

行业协会 Trade Association

参展商名录 Exhibitor List

合格评定 Conformity Assessment

市场份额 Market Share

 **实战 Practice** | 实战做法：把目标展会近三届的参展商名单合并去重，按国家与产品线分组——这通常比任何“AI 生成的客户名单”都更可靠，因为每个名字都能在官方名单里查到。

第四层：平台数据

■ 最贴近当下的竞争态势，最需要理解其“估算”性质。

- ▶ 平台榜单与销量标识：体现近期热度，但排序算法不公开、且可被运营手段影响。
- ▶ 评价与问答：真实的痛点来源，适合做主题与情感分析。
- ▶ 搜索与趋势工具：相对热度而非绝对销量，适合看方向不看规模。
- ▶ 网站流量工具：可估算独立站流量与来源结构，用于判断竞争对手的渠道打法。

关键术语 Key Terms

畅销排名 Best Sellers Rank

相对热度 Relative Interest

流量估算 Traffic Estimate

用户生成内容 UGC

⚠ 提示 Tip | 把平台数据当“信号”而不是“事实”：它适合回答“谁在动、往哪个方向动”，不适合直接当作市场规模写进报告。

第五层：商业数据库与海关数据服务商

❗ 花钱买时间与颗粒度，但必须确认数据来源的合法性。

- ▶ 付费数据库：行业报告、市场规模与份额，省去自己拼装的时间。
- ▶ 海关提单数据服务商：按 HS 编码查到具体买卖双方与交易记录，颗粒度最细。
- ▶ 采购前必问三件事：数据来自哪里？更新到什么时候？是否允许用于商业开发？
- ▶ 合规要点：涉及个人数据时受个人信息保护法与 GDPR 约束；平台条款也常禁止抓取。

关键术语 Key Terms

提单数据 Bill of Lading Data

数据订阅 Data Subscription

合法来源 Lawful Source

个人信息保护 Personal Data Protection

⚠ 提示 Tip | 底线提醒：以“购买”方式获得的客户名单，仍需确认其来源合法性；来源不明的名单一旦用于群发，风险由使用者承担。

一手数据与二手数据

■ 能用二手解决的不要做一手；必须一手时，先想清楚要回答什么。

- ▶ 二手数据 (Secondary): 已公开的报告、统计与平台数据, 快、便宜、但可能不匹配你的具体问题。
- ▶ 一手数据 (Primary): 自己做的问卷、访谈、小批量试单、样品测试, 慢、贵、但直接回答你的问题。
- ▶ 判断标准: 这个结论会带来多大的投入? 投入越大, 越需要一手验证。

关键术语 Key Terms

一手数据 Primary Data

二手数据 Secondary Data

验证成本 Verification Cost

决策影响度 Decision Impact

💡 例 Example | 消费电子的常见组合: 用二手数据选国家 (快), 用一手数据验证”这个价位在这个市场能不能卖动” (小批量试单 + 本地渠道访谈)。

免费与付费：按决策影响度分配预算

不是“能省就省”，而是把钱花在会改变决策的地方。

- ▶ 免费来源足够回答“要不要做”这类方向性问题。
- ▶ 付费来源用于回答“怎么做”这类精确问题（具体客户、具体价格带、具体规格）。
- ▶ 一个可用的预算原则：尽调阶段用免费来源，进入执行阶段再购买细颗粒度数据。
- ▶ 警惕“数据越多越好”——多买一份用不上的数据，等于挤占了试单与展会的预算。

关键术语 Key Terms

尽调阶段 Due Diligence

执行阶段 Execution

边际价值 Marginal Value

预算分配 Budget Allocation

 **公式 Formula** | 判断公式： $V_{\text{data}} = \Delta P(\text{决策改变}) \times \text{决策金额}$ ——如果这份数据无论结果如何都不会改变你的决定，它的价值就是零。

宏观指标（一）：规模与增长

■ 先确认”这个市场够不够大”，再谈其他。

- ▶ 人口与人均可支配收入：决定消费能力与价格带上限。
- ▶ 品类进口额与增速：直接反映需求规模与增长趋势（用目标国进口口径）。
- ▶ 进口来源集中度：来源越分散，新供应商越容易切入。
- ▶ 电商渗透率与线上消费占比：决定你能不能走跨境电商这条路。

关键术语 Key Terms

人均可支配收入 Disposable Income

进口增速 Import Growth

来源集中度 Import Concentration

电商渗透率 E-commerce Penetration

💡 例 Example | 判断逻辑示例：某国该品类进口额三年 CAGR 约 12%、前三大来源国合计占比不到 45%——增长快且不集中，属于典型的”值得进一步调研”的市场画像。

宏观指标（二）：成本与门槛

「规模决定」值不值得，成本与门槛决定「能不能赚到」。

- ▶ 关税与增值税：直接影响终端定价与毛利空间。
- ▶ 物流与仓储成本：海运时效、清关效率、最后一公里成本。
- ▶ 认证与检测费用：一次性投入，但会抬高小批量试单的门槛。
- ▶ 最低起订量与付款条件：决定现金流压力与试错成本。

关键术语 Key Terms

关税 Tariff

增值税 VAT

到岸成本 Landed Cost

最低起订量 MOQ

📊 公式 Formula | 到岸成本快速估算： $Landed = P_{\text{货值}} + F_{\text{运费}} + I_{\text{保险}} + D_{\text{关税}} + T_{\text{税费}}$ 。任何一项漏算，毛利率都可能被吃掉几个点。

认证与合规门槛：消费电子的硬约束

■ 这一项不通过，前面的市场规模分析全部作废。

- ▶ 欧盟：CE 标志 (含 LVD、EMC、RED 等指令)、RoHS、REACH、WEEE。
- ▶ 美国：FCC (含无线设备的 FCC ID)、UL 等安全认证、加州 Prop 65。
- ▶ 日本：PSE (电气用品安全法)、无线电法认证。
- ▶ 其他：电池运输 (UN38.3)、能效标签、包装与回收责任。

关键术语 Key Terms

CE 标志 CE Marking

电磁兼容 EMC

有害物质限制 RoHS

能效标签 Energy Label

⚠ 提示 Tip | 常见误区：认为“有 CE 证书就能进欧盟”。实际上不同产品适用不同指令，且需有欧盟境内的授权代表与技术文件留存——这些都要提前确认。

■ 报价、成本与利润分属不同时点，汇率必须写明。

- ▶ 报价时明确币种（USD / EUR / 本币）与汇率基准日。
- ▶ 长单要约定汇率波动条款或使用远期结汇锁定成本。
- ▶ 做市场规模测算时，统一换算到同一年份与同一币种。
- ▶ 注意“名义汇率”与“实际有效汇率”的区别：前者影响报价，后者影响购买力。

关键术语 Key Terms

汇率基准日 Rate Date

远期结汇 Forward Contract

币种风险 Currency Risk

实际有效汇率 Real Effective
Exchange Rate

💡 例 Example | 课堂算例：一份 12 个月的长单，若本币对美元升值 5% 而价格以美元固定，则本币收入减少约 5%——相当于毛利直接少 5 个点。

口径陷阱一：HS 编码选错

I 同一个产品可以有多个编码，选错就查到错误的市场。

- ▶ HS 编码有 6 位国际通用，之后各国会扩展到 8-10 位用于本国细分。
- ▶ 同一产品可能因用途、材质或功率不同而归入不同编码。
- ▶ 选错的后果：市场规模偏差数倍，竞争对手名单完全错位。
- ▶ 校验方法：用自己的编码查到已知的同业出口记录，看是否吻合。

关键术语 Key Terms

协调制度 Harmonized System
本国细分码 National Tariff Line
归类争议 Classification Dispute
交叉校验 Cross-check

⚠ 提示 Tip | 最实用的校验：拿 2-3 家已知同行企业的出口记录去反查编码，比对是否落在同一编码下；若分散在多个编码，说明该品类本身就需要多编码合并统计。

口径陷阱二：统计口径差异

I 同样叫“进口额”，含义可能完全不同。

- ▶ 原产国口径 vs 出口国口径：经第三国转口时两者差异明显。
- ▶ 计价口径：FOB（离岸价）与 CIF（到岸价）之间差着运费与保险。
- ▶ 统计时点：报关日期、装运日期与到货日期的差异会造成月度错位。
- ▶ 复出口与保税区流转：可能被计入进口，但并非真实消费。

关键术语 Key Terms

原产国 Country of Origin

离岸价 FOB

到岸价 CIF

转口贸易 Re-export

💡 例 Example | 现象解释：某国从中国进口某品类的金额，与该品类在中国出口统计中的对应金额不一致——差额常来自转口、保税区流转与计价口径，而不是数据造假。

口径陷阱三：单位、年份与货币

把不同口径的数字放进同一张表，是最常见也最致命的错误。

- ▶ 单位：台 / 件 / 千克 / 美元，不同单位不能直接比较。
- ▶ 年份：财年与自然年、统计年份与发布年份要分清。
- ▶ 货币：统一到同一年份的同一币种，并注明汇率来源。
- ▶ 表格规范：每个数字后面都要能追到“来源 + 年份 + 单位 + 口径”。

关键术语 Key Terms

财年 Fiscal Year

名义值 Nominal

不变价 Constant Price

数据字典 Data Dictionary

⚠ 提示 Tip | 一张自检清单：这张表里所有数字是不是同一年？同一币种？同一单位？同一统计口径？四个问题有一个答不上来，这张表就不能用于决策。

从问题到数据源的映射

规模有多大

Comtrade·Trade Map

成本多高

关税库·物流商

谁在竞争

平台·展会名单

门槛多高

认证机构·标准

客户是谁

提单数据·平台买家

先写问题，再找数据源——不要反过来” 有什么数据就分析什么”

把 AI 当检索代理

■ AI 在数据获取环节最有价值的用法，是把模糊问题拆成可检索的子问题。

- ▶ 拆解：把“泰国小家电市场怎么样”拆成 8-10 个可检索、可验证的子问题。
- ▶ 生成检索式：给出精确关键词组合与限定条件，而不是笼统的“帮我查一下”。
- ▶ 批量归纳：把几十条检索结果压缩成对照表，再由人工核对来源。
- ▶ 明确禁止：不要让 AI 生成它无法核实的具体数字。

关键术语 Key Terms

检索代理 Retrieval Agent

子问题拆解 Sub-question
Decomposition

检索式 Search Query

来源核对 Source Verification

⚠ 提示 Tip | 一条硬规则：凡是准备写进报告的 ** 具体数字 **，都必须点开原始来源确认；AI 汇总出来的数字只能用于“找线索”。

检索式拆解示例

同一个问题，拆法不同，得到的信息质量差距巨大。

- ▶ 拆国家与品类：市场规模、进口额、增速、主要来源国。
- ▶ 拆成本与门槛：关税税率、认证要求、能效法规。
- ▶ 拆竞争：主流品牌、价格带、平台畅销款、展会参展商。
- ▶ 拆客户：进口商名录、分销渠道结构、采购角色。

关键术语 Key Terms

检索词组合 Query Combination

限定条件 Search Operator

信息需求 Information Need

可验证性 Verifiability

💡 例 Example | 拆解示例：“泰国小家电市场”→ 泰国 HS 8516 进口额三年趋势 泰国小家电主要进口来源国 泰国电器能效认证要求 泰国主流电商平台畅销小家电价格带 泰国家电进口商名录 曼谷家电展参展商名单。

数据源可信度分级

A 级

官方统计

B 级

行业机构

C 级

平台数据

D 级

媒体报道

E 级

AI 生成

结论的等级，取决于其中最弱的那一环——用 E 级数据支撑的 A 级结论不存在

本节小结：数据源选择的四条原则

I 把“找数据”变成一件有方法、可复现的事。

- ▶ 先写问题，再选数据源；能免费解决的不用付费，能二手解决的不做一手。
- ▶ 优先用目标国的统计口径，而不是用本国出口数据反推。
- ▶ 每个数字都要带上来源、年份、单位与口径四件套。
- ▶ 数据源分级：官方 > 行业 > 平台 > 媒体 > AI 生成，结论强度取最弱一环。

关键术语 Key Terms

口径四件套 Four Metadata Items

数据分级 Source Tiering

可复现 Reproducible

最弱一环 Weakest Link

⚠ 提示 Tip | 课前准备：本讲第 4-6 节是三项带代码的实操教程，请携带笔记本电脑，并预先装好 Python 与 requests、pandas 两个库（命令：pip install requests pandas）。完整脚本与说明已上传课程主页“实操教程”栏目。

03

三方分工：搜索负责发现，平台负责验证，AI 负责归纳

三类工具的分工

I 用错工具，不是慢一点，而是得到错误结论。

- ▶ 搜索引擎：负责“发现”——找到你还不知道的公司、报告、政策与名单。
- ▶ 平台数据：负责“验证”——在真实成交场景中确认需求量级、价格带与竞争强度。
- ▶ AI 分析工具：负责“归纳”——把几十页资料压缩成对照表，把上千条评论归纳成主题。
- ▶ 三者的关系是串联的：搜索先给候选，平台给证据，AI 给结构。

关键术语 Key Terms

发现 Discovery

验证 Validation

归纳 Synthesis

工具分工 Tool Division

 图示 Diagram | 常见误区：用 AI 直接“生成市场分析”。正确的用法是用 AI 归纳 ** 你已经收集到的 ** 资料——资料来源这一步，AI 代替不了搜索与平台。

高级检索式（一）：限定站点与文件类型

学会三个算子，检索效率立刻提升。

- ▶ **site:** 限定在某个站点内搜索，例如只搜政府或协会网站。
- ▶ **filetype:** 限定文件格式，常用于找 PDF 报告、Excel 名单与 PPT 资料。
- ▶ **-** 排除不需要的词，例如排除招聘、教程与新闻稿。
- ▶ **组合使用：** `site:gov.cn filetype:pdf` 家电进口报告。

关键术语 Key Terms

检索算子 Search Operator

站点限定 Site Restriction

文件类型限定 Filetype Restriction

排除词 Exclusion

💡 **例 Example** | 可直接使用的检索式：`site:.de filetype:pdf Elektronik Importeur Liste` ——在德国域名下找 PDF 格式的电子产品进口商名单。

高级检索式（二）：标题与精确匹配

■ 把关键词限定在标题里，能大幅提高结果质量。

- ▶ `intitle:` 要求关键词出现在网页标题中，过滤掉正文顺带提及的页面。
- ▶ 引号精确匹配：`"consumer electronics distributor"` 只返回连续出现的短语。
- ▶ OR 组合同义词：`(distributor OR wholesaler OR importer)`。
- ▶ 组合示例：`intitle:"distributor" "consumer electronics" (Germany OR Deutschland)`。

关键术语 Key Terms

标题限定 Intitle

精确匹配 Exact Match

布尔逻辑 Boolean Logic

同义词扩展 Synonym Expansion

⚠ 提示 Tip | 小技巧：不同国家的行业用词不同 (`importer/distributor/wholesaler/trader/agent`)。把同义词用 OR 全部列上，比逐个试更省时间。

高级检索式 (三): 时间与地区限定

信息有时效性，检索也要限定时间。

- ▶ 时间限定：部分引擎支持 `after:2025-01-01`，或用界面上的时间筛选。
- ▶ 地区限定：使用目标国的域名后缀（.de、.fr、.jp、.sg）找本地视角的资料。
- ▶ 语言限定：用当地语言搜索，往往能发现英文资料里没有的中小企业与协会名单。
- ▶ 存档验证：重要页面变动频繁，用网页存档服务保存快照作为引用依据。

关键词 Key Terms

时效筛选 Recency Filter

域名后缀 Country Code TLD

本地语言检索 Native-language

Search

网页存档 Web Archive

 **实战 Practice** | 实战价值：用当地语言搜索“进口商名录”，得到的结果往往比英文搜索更贴近真实渠道结构——因为本地中小企业大多不做英文站。

检索算子速查表

算子	写法	用途与示例
站点限定	site:	只搜某站点或某国域名: site:.de
文件类型	filetype:pdf	找报告与名录: filetype:xlsx 名录
标题限定	intitle:	提高相关性: intitle:distributor
精确短语	"..."	避免拆词: "consumer electronics"
排除	-	去掉噪音: -招聘 -教程
同义扩展	OR	覆盖当地用词: (importer OR wholesaler)
时间限定	after:	只看近期: after:2025-01-01

不同搜索引擎支持的算子略有差异，使用前先确认当前引擎的语法。

三类检索式实例：找进口商

I 把前面的算子组合成可以直接用的检索式。

- ▶ 找名录: `site:.de filetype:pdf (Importeur OR Distributor) Elektronik Liste`。
- ▶ 找公司官网: `intitle:"consumer electronics" (import OR wholesale) -招聘 -jobs`。
- ▶ 找协会会员名单: `site:.org "member list" electronics association`。
- ▶ 使用纪律: 检索式只是开始, 名单必须逐条打开官网确认产品线与规模。

关键术语 Key Terms

名录检索 Directory Search

会员名单 Member List

逐条核实 Manual Verification

检索式迭代 Query Iteration

 **实战 Practice** | 效率提示: 先写 5 条检索式、各跑一遍, 比较结果质量, 再决定把哪一条扩写成 10 个变体——比一开始就穷举所有组合高效得多。

平台数据能验证什么、不能验证什么

I 分清边界，才不会把估算当事实。

- ▶ 能验证：价格带分布、畅销款的规格特征、评论中的真实痛点、上新节奏。
- ▶ 不能验证：整个市场的绝对规模、线下渠道的销量、未被电商覆盖的需求。
- ▶ 能验证：某价格段的竞争激烈程度（同类商品数量与评价增速）。
- ▶ 不能验证：竞争对手的真实利润率与成本结构。

关键术语 Key Terms

价格带分布 Price Band Distribution


绝对规模 Absolute Size

线下渠道 Offline Channel

估算性质 Estimative Nature

⚠ 提示 Tip | 写法提醒：报告中凡是用平台数据推算出的规模，必须写成“据平台可见销量估算，约为……”，并在脚注说明估算方法与局限。

搜索、平台与 AI 的协同 workflow



可以交给 AI 的任务清单

■ 把重复的、结构化的、不需要商业判断的活交出去。

- ▶ 归纳：把 20 篇公开资料压缩成一页对照表。
- ▶ 翻译与本地化：把产品资料译为当地语言并调整语气。
- ▶ 抽取：从公司介绍中抽取产品线、渠道与规模字段。
- ▶ 分类：把评论按主题归类，统计各主题占比。
- ▶ 生成初稿：检索式候选、邮件初稿、画像卡初稿——都只是初稿。

关键术语 Key Terms

任务外包 Task Delegation

归纳 Synthesis

本地化 Localization

初稿 Draft

 **实战 Practice** | 判断标准：如果一项工作“做错了也不影响商业判断，只是浪费时间”，可以交给 AI；如果“做错了会导致错误决策”，必须人工确认。

不能让 AI 做的事

■ 这几条是硬边界。

- ▶ 不能生成你没有提供、也无法核实的市场数字。
- ▶ 不能代替你访问需要登录或明确禁止自动访问的平台。
- ▶ 不能替你决定权重、取舍与风险偏好。
- ▶ 不能作为最终交付物——所有对外报告都必须有人署名负责。

关键术语 Key Terms

硬边界 Hard Boundary

署名责任 Accountability

商业判断 Business Judgment

授权数据 Licensed Data

⚠ 提示 Tip | 一句话标准：AI 的输出要经过你的核实才能署名；你不愿意为它背书的结论，就不要写进报告。

结构化输出的提示模板

要求固定字段，结果才能被程序继续处理。

- ▶ 明确字段：公司名、国家、产品线、渠道类型、规模区间、来源链接。
- ▶ 明确空值策略：资料中没有的信息一律写“未提及”，禁止推测。
- ▶ 明确格式：Markdown 表格或 JSON，便于直接粘贴到 Excel 或 CRM。
- ▶ 明确校验要求：每个字段后附一句原文摘录，便于人工核对。

关键术语 Key Terms

结构化输出 Structured Output

字段模板 Field Template

空值策略 Null Policy

可核验 Auditable

💡 例 Example | 模板片段：「请输出 Markdown 表格，列为：公司名 | 国家 | 产品线 | 渠道类型 | 规模区间 | 来源链接 | 原文摘录。资料未提及的字段填“未提及”，不要根据常识推测，不要合并多家公司。」

成本与效率的权衡

不是所有活都值得调用大模型。

- ▶ 大批量、规则明确的抽取（如从 500 页里抽字段）：优先用脚本或小模型。
- ▶ 需要理解语义、跨语言、判断语境的任务：用能力更强的模型，值得多花成本。
- ▶ 重复性任务：先做 10 条样本验证流程，再决定是否批量执行。
- ▶ 成本核算：把“模型调用成本”与“人工核对时间”一起算，往往人工时间才是大头。

关键术语 Key Terms

成本效益 Cost-effectiveness

批处理 Batch Processing

样本验证 Pilot Validation

人工核对 Human Verification

 **公式 Formula** | 简化判据：当“人工做一遍的时间成本”大于“模型调用成本 + 核对成本”时，才值得自动化。对一次性任务，手工通常更快。

本节小结：工具协同的三条纪律

I 工具越强，纪律越重要。

- ▶ 分工纪律：搜索发现、平台验证、AI 归纳，不要让 AI 同时扮演三个角色。
- ▶ 核实纪律：所有具体数字必须回到原始来源确认一次。
- ▶ 责任纪律：对外交付物必须有人署名，AI 只是过程工具。

关键术语 Key Terms

分工 Division of Labor

核实 Verification

署名责任 Accountability

可复现 Reproducible

 **实战 Practice** | 衔接下一节：接下来专门解决“如何保证 AI 输出在真实业务中可信、可用”——这是本讲的教学难点，也是最容易在实务中翻车的地方。

04

把查询变成程序：从手工点网页到批量拉数据

为什么用 API 而不是手工查

I 手工查十次可以，查一千次就必须写程序。

- ▶ 可重复：同样的参数换一个国家、换一年，程序改一个参数就能重跑。
- ▶ 可批量：多国 × 多年 × 多 HS 编码，人工要几小时，程序几分钟。
- ▶ 可留痕：每次调用都保存原始返回，便于复核与追溯来源。
- ▶ 可复用：脚本一次写好，本学期所有作业与后续课程都能用。
- ▶ 前提：先搞清楚数据源的授权、配额与使用条款。

关键术语 Key Terms

应用编程接口 API

批量拉取 Batch Fetch

可复现 Reproducible

原始返回留档 Raw Response
Archive

📦 实战 Practice | 学习路径建议：先用浏览器手动查 2-3 次，把 URL 参数看懂；再把同样的请求写成代码——直接抄代码而不理解参数，遇到报错就无法排查。

海关数据 API 的三种来源

I 免费的最权威，付费的最细，官方的最合规。

- ▶ 官方机构 API: 联合国 Comtrade、美国普查局、欧盟 Eurostat、WTO——免费或低成本，口径权威，但颗粒度到“国家 × 品类”。
- ▶ 商业数据服务商 API: 提单数据（能看到具体买卖双方），颗粒度最细，按量或按年收费。
- ▶ 平台与开放数据: 部分国家提供开放数据接口（如美国 Data.gov 系列），可下载 CSV 自行处理。
- ▶ 选择逻辑: 先确认你需要“国家层面”还是“公司层面”的数据，再决定用哪一类。

关键术语 Key Terms

官方统计接口 Official Statistics API

提单数据 Bill of Lading

开放数据 Open Data

颗粒度 Granularity

 图示 Diagram | 决策要点: 如果目标是判断“这个市场值不值得进”，官方 API 足够了；如果需要“具体找哪几家客户”，才需要提单数据服务商。

常用海关与贸易数据 API 一览

数据源	官方入口 (完整网址)	特点与限制
UN Comtrade	https://comtradeapi.un.org/	免费；覆盖全球；需注册获取订阅密钥
UN Comtrade 主站	https://comtradeplus.un.org/	界面查询入口；与 API 数据同源，便于交叉验证
ITC Trade Map	https://www.trademap.org/	界面友好；有 API 但需申请
美国普查局外贸	https://www.census.gov/foreign-trade/	美国进出口明细；有开放接口
欧盟 Eurostat	https://ec.europa.eu/eurostat	欧盟成员国贸易数据；提供 API
联合国数据门户	https://data.un.org/	多主题数据下载

各平台的配额、鉴权方式与使用条款不同，正式使用前请阅读其官方文档与条款；本页仅作入口指引。

UN Comtrade API: 最通用的免费入口

先用预览接口试跑，再申请密钥提升配额。

- ▶ 两条路径：预览接口（免密钥、功能受限、适合试跑）与正式接口（需订阅密钥、配额更高）。
- ▶ 鉴权方式：在请求头里带上订阅密钥（不同平台字段名不同，需查文档）。
- ▶ 配额意识：免费配额通常按小时/按天计算，批量脚本必须加限速与重试。
- ▶ 请求结构：数据路径 + 查询参数（报告国、年份、商品编码、贸易流向）。
- ▶ 返回格式：JSON，主体在 data 字段里，是一行一条记录的列表。

关键术语 Key Terms

预览接口 Preview Endpoint

订阅密钥 Subscription Key

请求头 Request Header

配额 Quota

提示 Tip | 学习建议：先用浏览器打开预览接口地址，把参数直接写在地址栏里看返回结果——看懂返回结构再写代码，能省掉大量调试时间。

五个关键参数

■ 看懂这五个参数，就能查任意国家、任意品类、任意年份。

- ▶ 报告国 (reporterCode): 数据的发布方, 用三位国家代码, 如 276 是德国、392 是日本。
- ▶ 年份 (period): 可写单年, 也可用逗号写多年, 如 2022,2023,2024。
- ▶ 商品编码 (cmdCode): HS 编码, 前期先用 4 位或 6 位, 确认口径后再细化。
- ▶ 贸易流向 (flowCode): M 为进口、X 为出口——查目标市场需求要用 M (对方进口)。
- ▶ 伙伴国 (partnerCode): 查“从中国进口”时填中国代码 156, 填 0 表示全球合计。

关键术语 Key Terms

报告国代码 Reporter Code

贸易流向 Trade Flow

伙伴国 Partner Country

商品编码 Commodity Code

 **公式 Formula** | 查询设计示例: 要判断“德国家电配件市场的中国份额”, 参数应为 reporterCode=276、flowCode=M、cmdCode=8518、partnerCode=156、period=2022,2023,2024。

代码一：最小可用的一次调用

先用最少代码跑通一次请求，确认鉴权与返回结构都正常。

```
1 import requests, json
2
3 API = "https://comtradeapi.un.org/public/v1/preview/C/A/HS"
4 HEAD = {"Ocp-Apim-Subscription-Key": "你的订阅密钥"} # 预览接口可留空
5
6 params = {
7     "reporterCode": "276",      # 德国
8     "period":       "2023",     # 年份
9     "cmdCode":      "8518",     # HS 编码：音频设备
10    "flowCode":      "M",        # 进口
11    "partnerCode":   "0",        # 0 = 全球合计
12 }
13
14 r = requests.get(API, params=params, headers=HEAD, timeout=30)
15 print(r.status_code)           # 200 表示成功；403 多为密钥问题
16 data = r.json().get("data", [])
17 print(len(data), "条记录")
18 print(json.dumps(data[0], ensure_ascii=False, indent=2)[:400])
```

 提示 Tip | 先打印一条原始记录再解析：字段名以实际返回为准，不同版本接口的字段名可能不同，不要照抄网上过时的教程。

返回值怎么读

四个字段决定你的分析是否站得住。

- ▶ primaryValue: 贸易金额，注意单位与币种（通常是美元）。
- ▶ netWgt: 净重（千克），用于交叉验证金额是否合理。
- ▶ refYear: 统计年份——必须与你写进报告的年份一致。
- ▶ cmdCode 与 partnerCode: 确认返回的编码与你请求的一致，避免被自动匹配到别的品类。
- ▶ 常见坑：同一年可能有“月度合计”与“年度”两套记录，重复合计会翻倍。

关键术语 Key Terms

贸易金额 Trade Value

净重 Net Weight

统计年份 Reference Year

重复合计 Double Counting

⚠ 提示 Tip | 必做的一步：把程序返回的金额，与官网页面手工查询的结果比对一次。数值一致，才说明参数口径没有理解错。

代码二：把返回结果转成表格

用 pandas 把 JSON 列表拍平成表格，只保留分析需要的字段。

```
1 import pandas as pd
2
3 def to_table(records):
4     df = pd.json_normalize(records)          # 拍平嵌套结构
5     cols = ["refYear", "reporterDesc", "cmdCode",
6             "partnerDesc", "flowDesc", "primaryValue", "netWgt"]
7     cols = [c for c in cols if c in df.columns] # 兼容字段差异
8     return df[cols]
9
10 df = to_table(data)
11 print(df.head())
12 print("合计金额（美元）:", df["primaryValue"].sum())
13 df.to_csv("comtrade_raw.csv", index=False, encoding="utf-8-sig")
```

📖 算法 Algorithm | 编码兼容性：官方字段名会随接口版本变化，代码里先判断字段是否存在再取用，脚本才不会因为一个小改动就整段崩溃。

代码三：批量拉取多国 × 多年

把参数变成循环，同时加上限速与异常处理——这是批量脚本与单次调用的关键差别。

```
1 import time, requests, pandas as pd
2
3 API = "https://comtradeapi.un.org/public/v1/preview/C/A/HS"
4 REPORTERS = {"276": "德国", "392": "日本", "410": "韩国"}
5 years, codes = ["2022", "2023", "2024"], ["8518", "8504"]
6
7 rows, fail = [], []
8 for code_r in REPORTERS:
9     for yr in years:
10         for hsc in codes:
11             p = {"reporterCode": code_r, "period": yr, "cmdCode": hsc,
12                 "flowCode": "M", "partnerCode": "0"}
13             try:
14                 r = requests.get(API, params=p, timeout=30)
15                 r.raise_for_status() # 4xx/5xx 直接抛错
16                 rows += r.json().get("data", [])
17             except Exception as e:
18                 fail.append((code_r, yr, hsc, str(e)[:40]))
19                 time.sleep(1.2) # 限速：避免 429
20 print("成功", len(rows), "条；失败", len(fail), "次")
```

 提示 Tip | 三条生产习惯：每次请求后 sleep 限速；失败记录到单独列表而不是直接崩溃；断点续跑——把已完成的参数组合存下来，避免重跑全部。

代码四：清洗、存盘与断点续跑

把原始数据落盘、去重、再生成可直接分析的表。

```
1 import os, json, pandas as pd
2
3 # 1) 原始返回先原样存一份，便于日后复核
4 os.makedirs("raw", exist_ok=True)
5 with open("raw/comtrade_all.json", "w", encoding="utf-8") as f:
6     json.dump(rows, f, ensure_ascii=False)
7
8 # 2) 拍平成表并按年份去重（避免月度与年度记录重复合计）
9 df = pd.json_normalize(rows)
10 df = (df.sort_values("refYear")
11        .drop_duplicates(subset=["refYear", "reporterCode", "cmdCode"], keep="last"))
12
13 # 3) 输出分析用表
14 out = df[["refYear", "reporterDesc", "cmdCode", "primaryValue", "netWgt"]]
15 out.to_csv("imports_clean.csv", index=False, encoding="utf-8-sig")
16 print(out.groupby("reporterDesc")["primaryValue"].sum().round(0))
```

 **实战 Practice** | 交付标准：一个可复用的脚本应当包含三个文件——原始返回（raw）、清洗后数据（clean）、以及参数与运行日志。三者齐全，结论才能被复核。

数据校验：三处必查

程序跑通不等于数据正确。

- ▶ 第一查：抽一个国家的某一年，与官网手工查询结果比对，金额应完全一致。
- ▶ 第二查：看量级是否合理——用金额除以净重得到单价，看是否落在该品类的常识范围内。
- ▶ 第三查：看是否有异常年份的空值或跳变，往往是编码或口径问题。
- ▶ 记录校验过程：把校验用的查询参数与结果截图存档，作为报告的证据。
- ▶ 若三处对不上，先怀疑自己的参数，再怀疑数据源。

关键术语 Key Terms

交叉验证 Cross-validation

单价合理性 Unit-price Sanity

异常跳变 Abnormal Jump

校验留档 Validation Record

📊 统计 Statistical | 量级检查示例：某国音频设备进口额 3 亿美元、净重 1 万吨，则单价约 30 美元/公斤。若明显偏离该品类的常见单价，说明编码或单位可能选错了。

■ 这几类问题占实际调试时间的八成。

- ▶ 403 / 401：密钥无效、未加入请求头、或未订阅该接口。
- ▶ 429：超过配额，降低频率或申请更高配额；脚本必须能识别并等待重试。
- ▶ 返回 0 条：参数组合本身无数据，或编码与年份不匹配（如该年尚未发布）。
- ▶ 数值异常大：同时取到了月度与年度记录，需要按年份去重。
- ▶ 编码错误：贸易数据里的国家代码与商品编码必须用官方代码表，不能凭印象写。

关键术语 Key Terms

状态码 Status Code

配额超限 Rate Limit Exceeded

空返回 Empty Result

代码表 Code List

⚠ 提示 Tip | 调试顺序：先打印完整请求 URL 与状态码，再用浏览器打开同一个 URL 验证——能把“代码问题”与“数据问题”快速分开。

商业提单数据 API 的用法与边界

■ 颗粒度最细，也最需要注意合规。

- ▶ 典型字段：收货人、发货人、品名、数量、港口、日期——可以直接得到公司名单。
- ▶ 计费方式：按年订阅或按查询量计费，价格差异大，采购前先申请样例数据。
- ▶ 使用边界：多数服务商限制转售与公开披露；用于内部客户开发通常可以，对外发布需授权。
- ▶ 数据质量：收货人名称常有拼写差异，需要做实体去重与标准化。
- ▶ 落地建议：先用样例数据验证“能不能找到我需要的公司”，再决定是否采购。

关键术语 Key Terms

收货人 Consignee

实体标准化 Entity Normalization

授权范围 License Scope

样例数据 Sample Data

⚠ 提示 Tip | 采购前的三个问题：数据覆盖哪些国家与年份？更新频率如何？是否允许用于商业客户开发？这三个问题问清楚，能避免大部分后续纠纷。

本节小结：API 实操三件产出

从“会查”到“会批量查”，是一次能力升级。

- ▶ 一个可复用脚本：参数化国家、年份与编码，带限速、重试与断点续跑。
- ▶ 一份数据文件：原始返回 + 清洗后表格，字段与口径齐全。
- ▶ 一份校验记录：与官网比对的参数与结果，作为报告证据。
- ▶ 验收标准：换一个国家与品类，只改参数就能跑出结果，且结果可被复核。

关键术语 Key Terms

参数化 Parameterized

可复用脚本 Reusable Script

数据落盘 Data Persistence

可复核 Verifiable

 **实战 Practice** | 配套资源：完整可运行脚本（含注释、限速与断点续跑）已随本讲上传至课程主页“实操教程”栏目，可直接下载使用。

05

合法拿数据：三条路径、离线解析与 pandas 分析

先明确合法边界，再谈技术

■ 电商数据是价值最高的数据，也是合规要求最严的数据。

- ▶ 平台的服务条款通常明确禁止未经授权的自动化抓取与批量导出。
- ▶ 违反条款的后果：账号封禁、法律追责，且会失去整个销售渠道。
- ▶ 因此本节的路线是：** 优先走官方或授权渠道，把代码用在“已合法获得的数据”上**。
- ▶ 具体三条路径：平台官方 API、授权数据服务商、公开页面的低频人工核对。
- ▶ 结论先讲：本节所有代码演示，输入都是“你已经合法拿到的数据文件”。

关键术语 Key Terms

服务条款 Terms of Service

授权数据 Licensed Data

官方接口 Official API

合规优先 Compliance First

⚠ 提示 Tip | 课堂立场：本讲不提供绕过反爬、伪造请求头或破解接口的方法。这类做法在实务中风险极高，且一旦账号被封，损失远大于节省的时间。

路径一：平台官方 API

■ 最合规、最稳定的方式，代价是需要申请与学习成本。

- ▶ 典型形态：电商平台面向卖家开放的数据接口，可获取自己的订单、库存、竞品类目数据等。
- ▶ 常见能力：类目搜索、商品详情、价格与库存、销售报告（部分需品牌备案）。
- ▶ 申请门槛：需要卖家账号、开发者账号，并同意其数据使用条款。
- ▶ 限制：调用频率、可获取字段、可查询的类目范围都有明确边界。
- ▶ 使用纪律：只取你被授权访问的数据，不越权查询他人店铺的敏感信息。

关键术语 Key Terms

平台接口 Marketplace API

品牌备案 Brand Registry

访问令牌 Access Token

调用频率 Rate Limit

 **实战 Practice** | 学习路径：先读平台的 API 文档，用官方提供的调试工具发一次请求，成功后再写脚本——比直接写代码调试快得多。

路径二：授权数据服务商

花钱买合规与效率。

- ▶ 典型服务：第三方电商数据平台，提供销量估算、价格监控、评论分析等。
- ▶ 交付方式：网页看板、导出 CSV、或 API 调用。
- ▶ 优势：数据已清洗、字段规范、可直接用于分析；合规责任由服务商承担一部分。
- ▶ 注意：其数据多为“估算值”，用于趋势判断可靠，用于精确规模需谨慎。
- ▶ 采购前：申请试用，用一份样例数据验证是否覆盖你的目标类目。

关键术语 Key Terms

第三方数据源 Third-party Data

销量估算 Sales Estimation

数据看板 Dashboard

试用验证 Trial Validation

提示 Tip | 字段确认清单：价格是当前价还是均价？销量是排名推算还是实测？更新频率如何？这三个问题决定了数据能不能用。

路径三：公开页面的低频人工核对

■ 数量小但完全可控，适合验证与抽样。

- ▶ 适用场景：验证榜单前 20 名的价格与规格，或抽查某一款竞品的评价主题。
- ▶ 做法：人工打开页面，把关键字段录入表格——数量控制在几十条以内。
- ▶ 优点：不存在合规风险，且人工核对能发现数据背后的异常（如刷评）。
- ▶ 缺点：无法规模化，不适合做价格带分布这类统计分析。
- ▶ 定位：把人工核对当作“校准工具”，用来验证另外两条路径的数据质量。

关键术语 Key Terms

人工抽样 Manual Sampling
校准样本 Calibration Sample
数据质量 Data Quality
规模化限制 Scaling Limit

 **实战 Practice** | 实用组合：用授权数据做全量分析，用人工抽样 20 条做校验——若两者差异明显，先怀疑授权数据的口径，再下结论。

三条路径对比：合规、成本与适用场景

路径	合规性	成本	数据量	适用场景与注意事项
平台官方 API	高	低	中	有账号即可申请；字段与频率受限
授权数据服务商	高	中高	大	覆盖广、字段规范；注意估算口径
人工低频核对	最高	时间成本	小	抽样校验、异常确认，无法规模化
未授权抓取	违规	—	—	禁止：封号、法律风险、损害渠道

选择顺序：能申请官方 API 就申请；需要全量历史数据就购买授权服务；只需要确认几个事实就人工核对。

为什么不能随意抓取

I 技术可行与合法合规是两回事。

- ▶ 平台条款：多数平台明确禁止自动化访问、批量下载与转售数据。
- ▶ 技术对抗：反爬机制持续升级，维护成本高，今日能用的方法明天可能失效。
- ▶ 法律风险：可能触及计算机信息系统相关法律与不正当竞争条款。
- ▶ 商业风险：账号与店铺被封，等于失去整条销售与数据渠道。
- ▶ 替代思路：把”获取数据”的精力，转为”获取授权”——一次申请，长期使用。

关键术语 Key Terms

反爬机制 Anti-scraping

不正当竞争 Unfair Competition

账号风控 Account Risk Control

授权成本 Licensing Cost

⚠ 提示 Tip | 判断标准：如果这个方法需要你隐藏身份、伪造请求或突破限制，它就一定不是本课程推荐的做法。

交付方式：离线解析已下载数据

■ 这一节开始写代码，输入是你已合法获得的数据文件。

- ▶ 常见输入格式：平台导出的 CSV/Excel、官方 API 返回的 JSON、数据服务商下载的文件。
- ▶ 处理流程：读取 → 清洗（去空值、统一单位）→ 统计（分布与分组）→ 输出对比表。
- ▶ 代码只需要 pandas 与标准库，不需要任何爬虫框架。
- ▶ 关键原则：**** 原始文件不要改动 ****，所有清洗过程写在代码里，保证可复现。
- ▶ 输出物：一张竞品对比表 + 几张分布统计，直接进入第 7 节的横向竞品分析。

关键术语 Key Terms

离线解析 Offline Parsing

数据清洗 Data Cleaning

可复现流程 Reproducible Pipeline

竞品对比表 Competitor Matrix

 **实战 Practice** | 目录建议：raw/（原始文件，只读）、clean/（清洗结果）、code/（脚本）三个目录，任何结论都能沿着这条链路回溯到原始数据。

代码一：读取并解析商品列表

把平台导出的 JSON 或 CSV 读取成一张规范表格——字段名以你的实际文件为准。

```
1 import json, pandas as pd
2
3 # 输入：已合法获得的类目商品列表（JSON 或 CSV 均可）
4 with open("raw/top_products.json", encoding="utf-8") as f:
5     raw = json.load(f)
6
7 rows = []
8 for it in raw["items"]:
9     rows.append({
10         "sku":    it.get("asin") or it.get("id"),
11         "title":  (it.get("title") or "")[:60],
12         "price":  float(it.get("price", {}).get("value") or 0),
13         "rating": float(it.get("rating") or 0),
14         "reviews": int(it.get("reviews") or 0),
15         "rank":   int(it.get("bsr") or 0),
16     })
17
18 df = pd.DataFrame(rows)
19 print(df.shape, "行 列")
20 print(df[["sku", "price", "rating", "reviews"]].head())
```

 提示 Tip | 健壮性写法：所有取值都用.get(...) 加默认值，避免某个商品缺字段导致整个脚本报错——真实数据的缺失值远比示例多。

代码二：清洗与价格带分布统计

按价格分档统计竞品数量与平均评分，这一步直接回答“哪个价格带最拥挤”。

```
1 import numpy as np, pandas as pd
2
3 df = df[(df["price"] > 0) & (df["rating"] > 0)]      # 剔除脏数据
4
5 bins = [0, 20, 40, 60, 100, 200, np.inf]
6 labels = ["<20", "20-40", "40-60", "60-100", "100-200", ">200"]
7 df["band"] = pd.cut(df["price"], bins=bins, labels=labels)
8
9 stat = df.groupby("band", observed=True).agg(
10     竞品数=("sku", "count"),
11     均价=("price", "mean"),
12     平均评分=("rating", "mean"),
13     平均评论数=("reviews", "mean")).round(2)
14 print(stat)
15
16 stat.to_csv("clean/price_band.csv", encoding="utf-8-sig")
```

 **实战 Practice** | 解读方法：竞品数最多且平均评分最低的价格带，往往是最容易切入的区间——供给多说明需求真实，评分低说明现有产品做得不好。

代码三：找出“高口碑低竞争”的位置

用两个指标交叉筛选：评论数（代表市场竞争强度）与评分（代表口碑水平）。

```
1 import pandas as pd
2
3 med_rev = df["reviews"].median()      # 市场中位评论数
4
5 # 低竞争（评论数低于中位数）且高口碑（评分 >= 4.3）
6 niche = df[(df["reviews"] < med_rev) & (df["rating"] >= 4.3)]
7 print("候选机会款: ", len(niche), "个")
8 print(niche[["sku", "price", "rating", "reviews"]
9         .sort_values("rating", ascending=False).head(10)])
10
11 # 对比：高竞争区（评论数前 10%）的价格带
12 hot = df[df["reviews"] >= df["reviews"].quantile(0.9)]
13 print("高竞争区价格带: ", hot["price"].describe()[["min", "50%", "max"]].round(1).to_dict())
```

 提示 Tip | 这只是筛选起点：候选款还需要人工打开页面确认是不是新品、是否刷评、是否属于同一细分——代码负责缩小范围，判断仍然由人做。


代码四：从标题里提取卖点关键词

不需要爬虫，用词频统计就能看出这一品类的“主流卖点”是什么。

```
1 import re
2 from collections import Counter
3
4 STOP = {"with", "for", "and", "the", "a", "of", "to", "in",
5         "pro", "max", "new", "set", "pcs"}
6
7 words = []
8 for t in df["title"]:
9     words += [w.lower() for w in re.findall(r"[A-Za-z]{3,}", t)
10              if w.lower() not in STOP]
11
12 print("这个品类最常出现的卖点词：")
13 for w, c in Counter(words).most_common(15):
14     print(f"    {w:16s} {c:4d} 次")
15
16 # 若要统计中文评论主题，可先用 jieba 分词再做同样的词频统计
```

💡 例 Example | 解读示例：若“waterproof”“battery”出现频次远高于“bass”，说明这个品类的竞争焦点在户外耐用性与续航，而不是音质——你的文案与详情页应据此调整。

价格带竞品分布示意：哪一档最拥挤



代码五：导出竞品对比表

把清洗后的结构化数据导出，直接作为第 7 节横向竞品分析的输入。

```
1 import pandas as pd
2
3 out = df[["sku", "title", "price", "band", "rating", "reviews", "rank"]]
4 out = out.sort_values("reviews", ascending=False)
5
6 out.to_csv("clean/competitor_matrix.csv",
7           index=False, encoding="utf-8-sig")    # Excel 直接打开不乱码
8 print("已导出", len(out), "条竞品记录")
9 print(out.groupby("band", observed=True)["price"].agg(["count", "mean"]).round(1))
```

 **实战 Practice** | 交接标准：这张表要能让同学在不看代码的情况下，直接排序、筛选、算出价格带分布——做到这一点，数据就算是“可交付”了。

评论主题的初步归纳

I 没有爬虫也能做：用你已获得的评论数据做词频与主题归纳。

- ▶ 输入：平台导出的评论文件，或品牌备案后官方后台提供的评论数据。
- ▶ 第一步：中文用 jieba 分词，英文按词切分，去除停用词。
- ▶ 第二步：统计高频词，人工把词归并成主题（续航、防水、做工、客服）。
- ▶ 第三步：按星级分组统计——1-2 星评论的主题就是“痛点清单”。
- ▶ 与第 7 节衔接：词频法是主题模型的轻量替代，数据量小的时候更快更直观。

关键术语 Key Terms

中文分词 Chinese Segmentation

停用词 Stop Words

词频统计 Word Frequency

痛点清单 Pain-point List

 **公式 Formula** | 分组统计思路：把评论按星级分桶（1-2 星、3 星、4-5 星），分别统计高频词——低星评论的词频分布，直接告诉你竞品的弱点在哪里。

合规红线与替代方案

再强调一次边界，避免踩坑。

- ▶ 不做：绕过反爬、伪造请求头、批量下载受保护内容、转售平台数据。
- ▶ 不做：抓取用户个人信息（昵称、头像、联系方式）用于营销。
- ▶ 替代一：申请官方 API——多数平台对卖家开放，只是需要走流程。
- ▶ 替代二：购买授权数据——把合规成本外部化，比自己处理更省心。
- ▶ 替代三：抽样人工核对——数量小但绝对安全，适合验证结论。
- ▶ 记录留存：保存数据来源与授权依据，写进报告的数据来源说明。

关键术语 Key Terms

合规红线 Compliance Red Line

数据来源说明 Source Statement

授权依据 License Basis

个人信息 Personal Data

提示 Tip | 本讲的所有代码都以“已合法获得的数据文件”为输入——这个前提不变，代码就永远是合规的；前提变了，再优雅的代码也不该用。

本节小结：电商数据三件产出

从原始文件到可分析的表，中间是一套可复现的流程。

- ▶ 一个解析脚本：把平台导出或 API 返回的数据转成规范表格。
- ▶ 一份分析结果：价格带分布、高口碑低竞争候选、卖点关键词。
- ▶ 一张竞品对比表：可直接进入第 7 节的聚类与主题分析。
- ▶ 验收标准：换一个类目的数据文件，脚本不改或只改字段名就能跑出结果。

关键术语 Key Terms

可复现流程 Reproducible Pipeline

分布统计 Distribution Analysis

竞品对比表 Competitor Matrix

参数化 Parameterized

 **实战 Practice** | 配套资源：完整脚本（含读取、清洗、分组统计、导出）已上传至课程主页“实操教程”栏目，可直接下载并在自己的数据上运行。

06

按地图找企业：POI 搜索、分页抓取与合规边界

思路：把地图当作企业名录

地图平台上有大量“地点（POI）”数据，其中就包含分销商、零售商与仓库。

- ▶ 地点数据（POI, Point of Interest）包含名称、地址、类别、网站与营业信息。
- ▶ 用关键词搜索，就能按地区批量得到“做某类生意的公司”。
- ▶ 典型用途：找一个城市的电子分销商、连锁店、批发市场里的商户。
- ▶ 优势：数据有地理约束，能按城市、半径、行政区精确圈定范围。
- ▶ 局限：地图数据以“门店/办公地点”为主，未必覆盖纯贸易公司（无实体店）。
- ▶ 因此地图搜索要与其他渠道（协会名录、展会名单、提单数据）交叉使用。

关键术语 Key Terms

兴趣点 Point of Interest, POI

文本搜索 Text Search

地理围栏 Geofencing

渠道交叉 Cross-channel

 图示 Diagram | 互补关系：地图告诉你“哪里有实体”，协会名录告诉你“谁是会员”，提单数据告诉你“谁真的在进口”——三源交叉，名单质量最高。

国际平台覆盖广但受条款限制，开放数据免费但覆盖不均。

- ▶ Google Maps Platform：全球覆盖最好，Places API 支持文本搜索与周边搜索，按请求计费。
- ▶ OpenStreetMap (OSM)：开放数据，完全免费，通过 Overpass API 查询，欧美覆盖较好。
- ▶ Bing Maps / 本地平台：部分地区覆盖更细，需按目标市场选择。
- ▶ 选择依据：目标国家的覆盖质量 + 费用预算 + 条款允许的用途。
- ▶ 重要提醒：不同平台对“数据能否长期保存、能否用于商业开发”的规定差异很大，使用前必须读条款。

关键术语 Key Terms

地图平台接口 Maps Platform API

开放街图 OpenStreetMap

超限查询接口 Overpass API

使用条款 Terms of Use

提示 Tip | 优先级建议：先考虑 OSM（免费、条款宽松），当覆盖不足时再评估 Google Maps Platform——并把条款限制纳入方案设计。

地理信息平台对比

平台	费用	覆盖	接口方式	主要限制与注意事项
Google Maps Platform	按量计费	全球最好	REST API	条款严格限制数据存储；需绑定结算账号
OpenStreetMap	免费	欧美较好	Overpass API	需遵守 ODbL 许可与合理使用要求
Bing Maps	按量计费	全球较好	REST API	条款与配额需查阅官方文档
本地地图平台	多为免费	本地最细	各有接口	条款差异大，商用前须确认

上表为一般性对比；具体配额、计费与条款随平台政策调整，使用前请查阅官方文档。

一次搜索请求包含三件事：搜什么、在哪搜、要哪些字段。

- ▶ 搜索方式：文本搜索（关键词 + 地区）与周边搜索（坐标 + 半径）。
- ▶ 字段掩码（Field Mask）：声明你需要返回哪些字段——只取必要字段既省钱又合规。
- ▶ 分页：单次返回有限条数，通过分页令牌继续取下一页。
- ▶ 常用字段：名称、地址、网站、电话、类别、地点 ID。
- ▶ 计费逻辑：按请求类型与字段组合计价，不同字段档位价格不同。
- ▶ 工程建议：先用最少字段跑通流程，再按需要逐步增加字段。

关键术语 Key Terms

字段掩码 Field Mask

分页令牌 Page Token

文本搜索 Text Search

按请求计费 Per-request Pricing

提示 Tip | 成本控制：只在字段掩码里声明真正需要的字段。多余字段不仅增加费用，也可能触及条款对数据存储的限制。

代码一：一次 Places 文本搜索

用最少的字段跑通一次请求，确认鉴权与返回结构。

```
1 import requests
2
3 URL = "https://places.googleapis.com/v1/places:searchText"
4 HEAD = {"Content-Type": "application/json",
5         "X-Goog-API-Key": "你的 API Key",
6         # 字段掩码：只声明需要的字段，省费用也降低合规风险
7         "X-Goog-FieldMask": "places.displayName,places.formattedAddress,"
8                             "places.websiteUri,places.id,nextPageToken"}
9
10 def search(query, token=None):
11     body = {"textQuery": query, "languageCode": "en", "pageSize": 20}
12     if token: body["pageToken"] = token
13     r = requests.post(URL, json=body, headers=HEAD, timeout=30)
14     return r.json()
15
16 j = search("consumer electronics distributor in Hamburg")
17 print(len(j.get("places", [])), "条结果")
```

 **提示 Tip** | 先跑通一次再写循环：打印第一条原始返回，确认字段名与嵌套结构，再决定后面怎么解析——这一步能省掉大量调试。

代码二：分页取全并整理成名单

地图搜索单次返回有限，必须处理分页；取完后按地点 ID 去重。

```
1 import time, pandas as pd
2
3 def search_all(query, max_pages=3):
4     out, token = [], None
5     for i in range(max_pages):
6         j = search(query, token)          # 复用上一页的函数
7         out += j.get("places", [])
8         token = j.get("nextPageToken")
9         print(f" 第 {i+1} 页: 累计 {len(out)} 条")
10        if not token:
11            break
12        time.sleep(2)                      # 分页需间隔，令牌才生效
13    return out
14
15 places = search_all("electronics wholesaler in Hamburg")
16 rows = [{"name": p["displayName"]["text"],
17         "address": p.get("formattedAddress", ""),
18         "website": p.get("websiteUri", ""),
19         "place_id": p["id"]} for p in places]  # 仅保存条款允许的字段
20
21 df = pd.DataFrame(rows).drop_duplicates("place_id")
22 df.to_csv("clean/importers_de.csv", index=False, encoding="utf-8-sig")
```



实战 Practice | 交付：这份 CSV 就是一份带地址与官网的候选客户名单；下一步用官网确认产品线（第 9 节 ICP）。

OpenStreetMap Overpass API: 免费替代

覆盖不如 Google，但免费、条款宽松，适合欧美市场。

- ▶ Overpass API 用类 SQL 的查询语言 (Overpass QL) 检索 OSM 数据。
- ▶ 典型查询：限定某个城市 (area) + 某个类别 (shop=electronics) + 返回节点。
- ▶ 类别标签需要查 OSM 的标签规范 (如 electronics、wholesale、doityourself)。
- ▶ 优点：完全免费，返回结果可依 ODbL 许可使用 (需署名并遵守相同方式共享)。
- ▶ 缺点：中小城市与新兴市场的覆盖不完整，名称标准化程度较低。
- ▶ 使用纪律：控制查询范围与频率，避免给公共服务器造成压力。

关键术语 Key Terms

查询语言 Overpass QL

开放数据库许可 ODbL

标签体系 Tagging Scheme

合理使用 Fair Use

提示 Tip | 查询技巧：先用城市名定位 area，再加类别标签；范围太大（如整个国家）容易超时，建议按城市或行政区逐个查询。

代码三：用 Overpass 查询某城市的电子商店

免费替代方案：一条查询取回一个城市里所有电子类商户。

```
1 import requests, pandas as pd
2
3 OVERPASS = "https://overpass-api.de/api/interpreter"
4 query = """
5 [out:json][timeout:60];
6 area["name"="Hamburg"]["admin_level"="4"]->.a;
7 node["shop"~"electronics|hifi"](area.a);
8 out center 300;
9 """
10
11 r = requests.post(OVERPASS, data={"data": query}, timeout=120)
12 r.raise_for_status()
13 els = r.json()["elements"]
14 print(len(els), "家商户")
15
16 rows = [{"name": e.get("tags", {}).get("name", ""),
17         "shop": e.get("tags", {}).get("shop", ""),
18         "website": e.get("tags", {}).get("website", "")} for e in els]
19
20 pd.DataFrame(rows).dropna(subset=["name"]).to_csv(
21     "clean/osm_shops_de.csv", index=False, encoding="utf-8-sig")
```

 **提示 Tip** | 署名义务：使用 OSM 数据须标注“© OpenStreetMap contributors”并遵守 ODbL 许可——写进你的报告与系统界面，这是使用条件不是可选项。

代码四：把地图结果转成可跟进的客户名单

补上业务字段，让名单能直接进入客户开发流程。

```
1 import pandas as pd, re
2
3 df = pd.read_csv("clean/osm_shops_de.csv")
4
5 # 1) 从官网域名反推公司主站，便于人工核对产品线
6 df["domain"] = df["website"].fillna("").str.extract(
7     r"https?:\/\/([~\/]+)", expand=False).str.replace("^www\\.\"", "", regex=True)
8
9 # 2) 按类别粗分客户类型（后续人工修正）
10 type_map = {"electronics": "电子零售商", "hifi": "音响零售商",
11             "mobile_phone": "手机零售商"}
12 df["customer_type"] = df["shop"].map(type_map).fillna("待确认")
13
14 # 3) 补齐客户开发流程需要的字段
15 df["lead_grade"] = "" # A/B/C 线索等级
16 df["next_action"] = "核对官网产品线"
17 df["next_date"] = ""
18
19 df.to_csv("clean/lead_list.csv", index=False, encoding="utf-8-sig")
20 print(df[["name", "customer_type", "domain", "next_action"]].head())
```

 **实战 Practice** | 与第 9 节衔接：这张表已经具备客户名单的基本结构——补上联系人与等级，就能直接进入线索评分与跟进流程。

结果验证：三源交叉

地图名单只是候选，必须验证。

- ▶ 第一源：地图数据——确认地址、类别与营业状态（是否仍在经营）。
- ▶ 第二源：公司官网——确认产品线、渠道类型与规模，判断是否符合 ICP。
- ▶ 第三源：协会名录或展会名单——确认其行业活跃度与身份。
- ▶ 交叉规则：三源都出现的公司优先级最高；只有地图来源的，先做人工核实。
- ▶ 常见噪音：地图上包含已停业、仅做维修、或面向消费者的门店，需要人工剔除。
- ▶ 记录验证结果：把“来源 + 验证方式 + 日期”写进名单，便于后续复核。

关键术语 Key Terms

三源交叉 Triangulation

停业噪音 Closed-business Noise

身份确认 Identity Verification

验证留痕 Verification Log

📊 统计 Statistical | 筛选效率：地图返回 200 家，经“官网产品线核对”通常只剩 60-90 家符合 ICP，再经“协会或展会身份确认”剩 30-50 家值得重点跟进——这就是可执行的核心名单。

合规红线：数据存储与用途限制

■ 这一节最需要提醒的内容。

- ▶ Google Maps Platform 条款对数据缓存、存储与再分发有明确限制，通常只允许长期保存有限字段（如地点 ID），并禁止用于构建或补充其他数据集。
- ▶ 合规做法：用地图数据“当场筛选与核对”，只把允许保存的字段沉淀到自有系统。
- ▶ OSM 数据许可相对宽松，但须署名并遵守相同方式共享 (Share-alike) 要求。
- ▶ 方案设计阶段就要把条款限制写进数据流设计。
- ▶ 声明：本页为课堂提示，具体合规判断请以平台官方条款与专业意见为准。

关键术语 Key Terms

数据缓存限制 Caching Restriction

地点标识 Place ID

再分发 Redistribution

相同方式共享 Share-alike

⚠ 提示 Tip | 一句话记住：地图平台的数据“能用来查，不一定能用来存”——把地图当验证工具，把存储交给 OSM 或自有采集。

与客户开发流程的衔接

■ 本节产出如何进入下一讲。

- ▶ 输出物：一份带地址、官网、类别的候选客户名单（CSV）。
- ▶ 下一步一：补全联系人——从官网与公开组织信息确认采购角色（第 9 节 ICP）。
- ▶ 下一步二：线索评分——按匹配度、意向信号、可触达性打分（第二讲第 9 节）。
- ▶ 下一步三：触达——按客户类型选择话术与渠道（第二讲第 3-4 节）。
- ▶ 效率提升：地图搜索把“找公司”从数天缩短到几分钟，但“判断哪家值得投入”仍需人工完成。

关键术语 Key Terms

名单衔接 List Handoff

线索评分 Lead Scoring

采购角色 Buying Role

人工判断 Human Judgment

 **实战 Practice** | 模块衔接：本讲三节实操解决“数据怎么来”，第 7 节解决“数据怎么分析”，第二讲解决“名单怎么变成订单”。

本节小结：地图找客户三件产出

I 工具的价值在于缩短从“想找”到“能联系”的距离。

- ▶ 一个搜索脚本：按关键词与地区批量获取候选公司名单。
- ▶ 一份清洗后的名单：含名称、地址、官网、类别与来源标注。
- ▶ 一份验证记录：三源交叉的结果与人工核实备注。
- ▶ 验收标准：名单里每一家公司，都能说清“从哪个平台来的、验证过哪些信息”。
- ▶ 合规底线：只保存平台条款允许保存的字段，其余用于当场筛选。

关键术语 Key Terms

候选名单 Candidate List

来源标注 Source Tagging

验证记录 Verification Record

条款合规 Terms Compliance

 **实战 Practice** | 配套资源：三个教程的完整脚本与说明文档已上传至课程主页“实操教程”栏目，可下载后在自己的目标市场上运行。

07

用机器学习把竞品看清：聚类·降维·主题·分类·异常

什么是横向竞争情报

■ “横向”指同一品类、同一价格带上的同类产品，把它们放在同一张表上比较。

- ▶ 横向 (Cross-sectional): 比较同一时点上的多个竞品——谁贵、谁强、谁的口碑好。
- ▶ 纵向 (Longitudinal): 追踪同一对象随时间的变化——第 8 节讲，用于识别趋势。
- ▶ 两者互补：横向回答“现在怎么打”，纵向回答“接下来往哪走”。
- ▶ 本节的产出：一张竞品对比表 + 一张竞品地图 + 一份竞品弱点清单。

关键术语 Key Terms

横向分析 Cross-sectional Analysis

纵向分析 Longitudinal Analysis

竞品对比表 Competitor Matrix

竞品地图 Competitive Map

 图示 Diagram | 本节所有机器学习方法都服务于同一件事：把“人工看几百个产品页面”变成“算法先聚类、人再判断”。人负责定义问题与验证结论，算法负责不知疲倦地比较。

竞争情报的合法边界

■ 能做和不能做，必须在开始之前分清楚。

- ▶ 可以做：公开页面信息、公开评价、公开财报、展会与协会名录、付费数据库的授权使用。
- ▶ 不能做：突破平台反爬与登录限制抓取、获取非公开的商业秘密、冒充客户套取竞品报价。
- ▶ 灰色地带：批量抓取公开数据——技术上可行，但要遵守平台条款与 robots 协议。
- ▶ 底线：任何情报工作都要经得起“如果被对方知道，是否说得过去”这一问。

关键术语 Key Terms

公开信息 Public Information

服务条款 Terms of Service

商业秘密 Trade Secret

爬虫协议 robots.txt

提示 Tip | 课堂纪律：本讲所有演示都基于公开页面与授权数据；请勿在作业中抓取需要登录或明确禁止自动访问的站点。

竞品识别的三个圈层

I 先分清”谁才是真正的竞争对手”，再谈分析。

- ▶ 直接竞品：功能、价格带、目标人群高度重叠的产品。
- ▶ 替代品：解决同一需求但形态不同（如真无线耳机与头戴式耳机）。
- ▶ 平台同类卖家：在同一个搜索结果页里争夺点击的所有卖家。
- ▶ 再加一层”潜在进入者”：上游供应商或大品牌的新品线，可能突然改变格局。

关键术语 Key Terms

直接竞品 Direct Competitor


替代品 Substitute

潜在进入者 Potential Entrant

搜索页竞争 SERP Competition

 **实战 Practice** | 实战做法：在目标平台搜索核心关键词，取前 3 页结果作为”平台同类卖家”圈层——这一圈层最贴近真实的流量争夺，比行业协会名录更直接。

横向竞品分析 workflow



竞品情报的六个维度

▮ 字段设计决定分析上限——采集时没想到的维度，后面补不回来。

- ▶ 价格维度：标价、促销价、价格带位置、是否有阶梯优惠。
- ▶ 规格维度：容量、功率、接口、重量、材质、防护等级。
- ▶ 口碑维度：评分、评论数、差评主题、问答中的高频疑问。
- ▶ 合规维度：认证标识、能效等级、包装与说明书语种。
- ▶ 渠道维度：自营/第三方、线上/线下、区域覆盖、是否多站点。
- ▶ 节奏维度：上新频率、促销节点、广告投放强度。

关键术语 Key Terms

特征字段 Feature Field

价格带 Price Band

口碑 Word of Mouth

上新节奏 Launch Cadence

💡 例 Example | 消费电子示例字段表：型号·价格·电池容量·充电功率·蓝牙版本·防水等级·重量·评分·评论数·差评关键词·认证·主图风格。

为什么这里需要机器学习

I 几百个竞品、几千条评论，人工比较既慢又不可复现。

- ▶ 规模问题：一个细分品类常有 100–500 个在售竞品，评论数千条。
- ▶ 一致性问题：不同人看同一批数据会得到不同结论，无法复核。
- ▶ 隐性结构问题：价格与规格之间、评论主题之间的关联，肉眼很难发现。
- ▶ 机器学习把“看得完、看得一致、看得出结构”变成可复现的流程。

关键术语 Key Terms

可复现性 Reproducibility

人工偏差 Human Bias

高维数据 High-dimensional Data

模式发现 Pattern Discovery



图示 Diagram | 下面 15 个算法按“处理什么数据”排序：文本 → 数值 → 图像 → 多模态。每个算法给出直觉、公式，以及一个消费电子领域的真实用法。

算法一：文本向量化 (Text Embedding)

把文字变成一串数字——语义相近的文本，向量距离更近。

- ▶ **怎么算 (Intuition)**: 用一个预训练模型把每段文字映射到 d 维空间中的一个点；训练时让语义相似的句子互相靠近、无关句子互相远离。
- ▶ **公式 (Formula)**: $e = f_{\theta}(\text{text}) \in \mathbb{R}^d$, 其中 d 常为 384、768 或 1024
- ▶ **用在哪 (Application)**: 把 500 条竞品标题与卖点全部向量化。此后“比较文案”就变成了“算距离”，这是后面所有文本分析的基础。

关键术语 Key Terms

嵌入 Embedding

向量空间 Vector Space

语义相似 Semantic Similarity

预训练模型 Pre-trained Model

📖 **算法 Algorithm** | 课堂演示：把“便携蓝牙音箱防水 IPX7”与“户外音箱防泼溅”向量化，两者相似度通常明显高于它们与“家庭影院音响”的相似度——用词完全不同，语义却很近，这正是传统关键词匹配做不到的。

算法二：余弦相似度 (Cosine Similarity)

不看向量有多长，只看方向像不像——用来判断两段文本是否在说同一件事。

- ▶ **怎么算 (Intuition)**: 两个向量的夹角越小，方向越一致；把内积除以两个向量长度之积，就得到与长度无关的相似度。
- ▶ **公式 (Formula)**: $\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} \in [-1, 1]$
- ▶ **用在哪 (Application)**: 竞品去重（同款产品在多个平台的不同标题）、为每个竞品找出最相似的 5 个对手组成对比组。

关键术语 Key Terms

余弦相似度 Cosine Similarity

去重 Deduplication

最近邻 Nearest Neighbor

阈值 Threshold

⚠ 提示 Tip | 阈值经验值（仅供参考，需按品类校准）：相似度大于 0.92 往往是同款或同代工；0.75–0.92 多为同类直接竞品；低于 0.60 基本不属于同一细分。

算法三：K 均值聚类 (K-means Clustering)

■ 把相似的竞品自动归成几群，不需要事先告诉算法“谁和谁像”。

- ▶ **怎么算 (Intuition)**: 先随机指定 k 个中心，把每个样本分给最近的中心，再重新计算中心，反复迭代直到稳定。
- ▶ **公式 (Formula)**: $\min_{C_1, \dots, C_k} \sum_{i=1}^k \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \mu_i\|^2$
- ▶ **用在哪 (Application)**: 用「价格—评分—销量」三个特征，把 200 个竞品分成高端、性价比、低价三群，一眼看清自己落在哪一群、那一群里谁最强。

关键术语 Key Terms

聚类 Clustering

簇 Cluster

质心 Centroid

肘部法 Elbow Method

⚠ 提示 Tip | k 值怎么定：先用肘部法看组内平方和下降的拐点，再用业务含义确认——“能解释成高端/中端/入门”比“数学上最优”更重要。

算法四：层次聚类 (Hierarchical Clustering)

不需要预先指定分几群，让数据自己长出层次结构。

- ▶ **怎么算 (Intuition)**: 每一步把最相近的两个簇合并，直到全部合成一个；结果画成树状图，在任何高度横切就得到对应数量的分组。
- ▶ **公式 (Formula)**: Ward 距离: $\Delta(A, B) = \sum_{x \in A \cup B} \|x - \mu_{A \cup B}\|^2 - \sum_{x \in A} \|x - \mu_A\|^2 - \sum_{x \in B} \|x - \mu_B\|^2$
- ▶ **用在哪 (Application)**: 看清品类的自然分层: 真无线耳机 → 入耳式 / 半入耳 / 开放式; 同一层内价格带接近, 跨层价格常差 2-5 倍。

关键术语 Key Terms

层次聚类 Hierarchical Clustering

树状图 Dendrogram

沃德距离 Ward Distance

品类结构 Category Structure

💡 例 Example | 消费电子常见分层结果: 第一层分“音频/充电/影像”; 音频层再分“入耳/半入耳/开放式”; 同一层内的产品在价格与规格上高度可比, 跨层比较则意义不大。

算法五：降维与竞品地图 (PCA / t-SNE / UMAP)

■ 把二十几个规格字段压缩成两个坐标，画成一张能看懂的竞品地图。

- ▶ **怎么算 (Intuition)**: PCA 找方差最大的方向做线性投影; t-SNE 与 UMAP 保留局部邻域关系, 把相似的样本挤在一起。
- ▶ **公式 (Formula)**: PCA: $\max_{\|w\|=1} \text{Var}(Xw)$; t-SNE 与 UMAP 则最小化高维与低维邻域分布的差异
- ▶ **用在哪 (Application)**: 把竞品按两个主成分画在平面上, 圈出人少的区域——那就是可能的产品空隙。

关键术语 Key Terms

主成分分析 PCA

流形学习 Manifold Learning

竞品地图 Competitive Map

产品空隙 White Space

⚠ 提示 Tip | 汇报时的分工: 用 PCA 讲“整体往哪个方向走” (坐标轴有明确含义), 用 t-SNE 讲“分成几坨” (局部结构清楚), 但不要再用 t-SNE 解释全局远近。

算法六：主题模型（LDA / BERTopic）

I 从几千条评论里自动抽出“大家到底在抱怨什么”。

- ▶ **怎么算 (Intuition)**: 假设每篇文档由若干主题混合而成，每个主题又是若干词的概率分布；算法反过来从文字中把这两层概率推出来。
- ▶ **公式 (Formula)**: LDA: $p(w | d) = \sum_t p(w | t) p(t | d)$
- ▶ **用在哪 (Application)**: 把 8,000 条竞品差评输入，自动得到主题：续航虚标、连接断连、做工缝隙、客服响应慢——并按占比排序。

关键术语 Key Terms

主题模型 Topic Model

潜在狄利克雷分配 LDA

词分布 Word Distribution

主题占比 Topic Share

 **实战 Practice** | 实战用法：把竞品的差评主题占比与自己产品的能力对比。若对手差评第一主题是“续航”，而你恰好主打续航——这就是最该写进开发信与详情页的卖点。

算法七：情感分析 (Sentiment Analysis)

判断一段文字是好评还是差评，并按主题交叉统计。

- ▶ **怎么算 (Intuition)**: 词典法查情感词；机器学习与预训练模型把文本向量化后做二分类或回归 (1-5 星)。
- ▶ **公式 (Formula)**: $P(\text{正面} | e) = \sigma(\mathbf{w}^T \mathbf{e} + b)$, 其中 $\sigma(z) = 1/(1 + e^{-z})$
- ▶ **用在哪 (Application)**: 生成“竞品弱点矩阵”: 主题 $\times$ 情感, 找出对手口碑崩塌的维度; 也可以盯竞品改版后的口碑变化。

关键术语 Key Terms

情感分析 Sentiment Analysis

极性 Polarity

方面级情感 Aspect-based Sentiment

弱点矩阵 Weakness Matrix

⚠ 提示 Tip | 中文评论的反讽与“表面好评” (如“物流很快, 东西嘛.....”) 会让词典法失手, 这类样本必须人工抽查; 方面级情感 (针对某个属性) 比整体情感更有用。

算法八：命名实体识别（NER）

从一段自由文本里自动抽出规格参数，做成可比的结构化表格。

- ▶ **怎么算 (Intuition)**：把抽取看作序列标注：给每个字打上“属于哪个字段”的标签（BIO 标注），模型学会后见到新文本就能标。
- ▶ **公式 (Formula)**： $\hat{y}_{1:n} = \arg \max_{y_{1:n}} P(y_{1:n} \mid x_{1:n})$
- ▶ **用在哪 (Application)**：从“5000mAh 大电池，支持 PD 20W 快充，IPX7 防水”中抽出容量、快充、防护三个字段——这是规格对比表能自动生成的前提。

关键词语 Key Terms

命名实体识别 NER

序列标注 Sequence Labeling

BIO 标注 BIO Tagging

结构化抽取 Structured Extraction

💡 例 Example | 抽取结果示例：容量 = 5000mAh、快充 = PD 20W、防护 = IPX7、蓝牙 = 5.3。有了这些字段，200 个竞品的规格对比表可以在几分钟内生成。

算法九：文本分类（逻辑回归 / 朴素贝叶斯 / SVM）

■ 把竞品自动归入业务定义的类别，如“主打便携”“主打性能”“主打低价”。

- ▶ **怎么算 (Intuition)**：逻辑回归学一个线性打分再压到概率；朴素贝叶斯用词的条件独立假设算后验；SVM 找最大间隔的分界面。
- ▶ **公式 (Formula)**：逻辑回归 $\sigma(\mathbf{w}^T \mathbf{x} + b)$ ；朴素贝叶斯 $\arg \max_c P(c) \prod_i P(w_i | c)$ ；SVM $\max \frac{2}{\|\mathbf{w}\|}$
- ▶ **用在哪 (Application)**：给 300 个竞品的详情页文案打标签，快速看出“这个品类的主流叙事是什么、哪一类叙事还没人占”。

关键术语 Key Terms

逻辑回归 Logistic Regression

朴素贝叶斯 Naive Bayes

支持向量机 SVM

标注数据 Labeled Data

⚠ 提示 Tip | 类别定义必须由业务给出（互斥且穷尽），模型只负责归类。小样本时朴素贝叶斯与线性 SVM 往往比大模型更稳、更快、更容易解释。

算法十：梯度提升树 (XGBoost / LightGBM)

■ 一棵树不够准，就让几百棵小树依次修正前面的错误。

- ▶ **怎么算 (Intuition)**: 每棵新树拟合当前模型的残差 (负梯度)，再以很小的学习率累加进去，逐步逼近目标。
- ▶ **公式 (Formula)**: $F_m(x) = F_{m-1}(x) + \nu h_m(x)$, h_m 拟合负梯度, ν 为学习率
- ▶ **用在哪 (Application)**: 用规格、价格、评分、评论数预测销量；更重要的是输出特征重要性，告诉你到底哪个规格在影响销量。

关键术语 Key Terms

梯度提升 Gradient Boosting

残差 Residual

特征重要性 Feature Importance

过拟合 Overfitting

 **实战 Practice** | 典型结论：在很多品类里，“评分 + 评论数”对销量的解释力高于参数堆料。这会直接改变你的优先级——先把口碑做起来，再谈参数升级。

算法十一：异常检测 (Isolation Forest / IQR)

I 找出“不正常”的数据：刷评、异常定价、录入错误。

- ▶ **怎么算 (Intuition)**: 异常样本往往“更容易被孤立”: 随机切分数据时, 异常点平均只需更少次数就被单独切开。
- ▶ **公式 (Formula)**: IQR 法: 正常区间 $[Q_1 - 1.5 \text{ IQR}, Q_3 + 1.5 \text{ IQR}]$; 孤立森林用路径长度 $s(x, n) = 2^{-\mathbb{E}[h(x)]/c(n)}$
- ▶ **用在哪 (Application)**: 识别短期大量 5 星好评 (刷评)、远低于成本的定价 (清库存或假货)、单位写错的规格字段。

关键术语 Key Terms

异常检测 Anomaly Detection

四分位距 IQR

孤立森林 Isolation Forest

刷评 Review Manipulation

💡 例 Example | 刷评的典型特征: 3 天内新增 200 条 5 星、平均字数仅 12 字、用户名无历史记录。剔除这些样本后再计算评分, 才是有意义的竞品口碑。

算法十二：协同过滤（Collaborative Filtering）

“买了 A 的人还买了 B”——从共现关系里发现关联与机会。

- ▶ **怎么算 (Intuition)**: 用用户—物品的交互矩阵找相似用户或相似物品，再用相似群体的评分预测未知偏好。
- ▶ **公式 (Formula)**:
$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N(i)} \text{sim}(u, v) (r_{vi} - \bar{r}_v)}{\sum_{v \in N(i)} |\text{sim}(u, v)|}$$
- ▶ **用在哪 (Application)**: 发现关联品类与捆绑机会：耳机 → 保护套、充电盒、耳塞；主力产品竞争激烈时，配件常是更高的毛利来源。

关键术语 Key Terms

协同过滤 Collaborative Filtering

共现矩阵 Co-occurrence Matrix

关联规则 Association Rule

捆绑销售 Bundling

实战 Practice | 同一思路也可用于“关联竞品”：找与你产品共同出现在同一用户购物车里的其他品类，它们往往就是最现实的交叉销售对象。

算法十三：卷积神经网络（CNN）分析商品图

■ 让机器“看懂”主图：有没有人物、是什么场景、留白多少、包装文字是否清晰。

- ▶ **怎么算 (Intuition)**: 用小卷积核在图像上滑动, 检测局部模式 (边缘、色块、文字), 逐层组合成更高层的视觉概念。
- ▶ **公式 (Formula)**: 卷积: $(f * g)(t) = \sum_{\tau} f(\tau) g(t - \tau)$; 深层网络通过参数共享大幅减少需要学习的参数量
- ▶ **用在哪 (Application)**: 把类目 Top 100 的主图做风格聚类, 看出“白底图与场景图”的比例, 以及竞品普遍缺失的展示角度 (如防水演示、佩戴效果)。

关键术语 Key Terms

卷积神经网络 CNN

卷积核 Convolution Kernel

参数共享 Parameter Sharing

视觉特征 Visual Feature

💡 例 Example | 可操作的发现: 若 Top 20 的主图里 16 张是“白底 + 产品居中”, 而你发现使用场景图的点击率更高, 这就是一个低成本的详情页优化方向——用平台自带的数据即可验证。

算法十四：多模态模型与图文一致性

同时理解图片和文字，检查“主图承诺”与“参数表”是否对得上。

- ▶ **怎么算 (Intuition)**: 分别把图像与文本编码到同一向量空间，让匹配的图文对距离更近，从而可以计算图文相似度。
- ▶ **公式 (Formula)**: $s(I, T) = f_I(I)^T f_T(T)$ ，训练目标为拉近匹配对、推远不匹配对
- ▶ **用在哪 (Application)**: 批量检查竞品页面是否存在“图文不符”（主图写 40W、参数表写 20W），也可用来提取图文卖点差异。

关键术语 Key Terms

多模态 Multimodal

图文对齐 Image-Text Alignment

跨模态检索 Cross-modal Retrieval

图文不符 Spec Mismatch

⚠ 提示 Tip | 多模态模型对细粒度数字（型号、认证编号、功率）仍会读错。凡是要写进对比表的参数，必须回原始页面人工核对一次。

算法十五：价格弹性回归

■ 估算“降价 10%，销量能涨多少”，避免盲目跟价。

- ▶ **怎么算 (Intuition)**: 对价格与销量取对数后做线性回归，斜率就是弹性：价格变化 1%，销量变化百分之几。
- ▶ **公式 (Formula)**: $\ln Q = \alpha + \beta \ln P + \gamma X + \varepsilon$ ，其中 β 即价格弹性
- ▶ **用在哪 (Application)**: 用历史促销数据估计弹性，判断跟价是否划算；也可用于新市场定价区间试探。

关键术语 Key Terms

价格弹性 Price Elasticity

对数线性模型 Log-log Model

控制变量 Control Variable

内生性 Endogeneity

📊 公式 Formula | 判断规则：若 $\beta = -1$ ，降价 10% 带来销量 +10%，收入基本不变；若 $|\beta| < 1$ （缺乏弹性），降价反而减少收入——先估弹性，再决定要不要跟价。

算法选择决策树：什么任务用什么方法

I 不用记住所有算法，只要记住“看到什么数据、想问什么问题”。

- ▶ 有文本、想问“分几类”→ 向量化 + 聚类 (K-means / 层次聚类)。
- ▶ 有文本、想问“在说什么”→ 主题模型 (LDA / BERTopic)。
- ▶ 有文本、想问“好坏”→ 情感分析；想问“抽字段”→ 命名实体识别。
- ▶ 有表格数值、想问“谁最重要”→ 梯度提升树 + 特征重要性。
- ▶ 有时间序列、想问“接下来怎么走”→ 第 8 节的时间序列方法。

关键术语 Key Terms

任务映射 Task Mapping

特征重要性 Feature Importance

无监督学习 Unsupervised

有监督学习 Supervised



图示 Diagram | 选择顺序：先看数据类型（文本/表格/图像/时间）→ 再看问题类型（分组/归因/预测/异常）→ 最后才挑具体算法。跳过头两步直接选算法，是最常见的错误。

数据质量与小样本问题

算法再先进，也救不了脏数据与错误的口径。

- ▶ 去重：同一产品在多个平台的不同标题，必须先用相似度合并。
- ▶ 单位对齐：mAh 与 Wh、W 与 V·A、英寸与厘米，全部统一后再建模。
- ▶ 缺失值：规格字段缺失率高时，聚类结果会被缺失模式主导。
- ▶ 小样本：竞品少于 30 个时，优先用简单方法与人工核对，不要上复杂模型。

关键术语 Key Terms

数据清洗 Data Cleaning

缺失值 Missing Value

量纲统一 Unit Normalization

样本量 Sample Size

提示 Tip | 一条实用规则：任何聚类结果都必须能被业务解释。如果算法分成 5 群而你只能解释 3 群，请回到第 1 步重新检查字段与清洗——问题多半出在数据，不在算法。

AI 能做与不能做

I 把能力边界写在前面，才能放心使用。

- ▶ 能做：不知疲倦地比较、归纳、分组、抽取、发现异常，且结果可复现。
- ▶ 不能做：判断哪个规格“对客户更重要”、替你做商业取舍、核实数据来源的真实性。
- ▶ 不能做：从无到有生成市场数据——它只能处理你给它的或已公开的资料。
- ▶ 分工原则：算法负责缩小范围，人负责定义问题与做出判断。

关键术语 Key Terms

能力边界 Capability Boundary

可复现 Reproducible

商业判断 Business Judgment

人机分工 Human-AI Division

📖 算法 Algorithm | 一句话总结本节：这 15 个算法不是让你成为算法工程师，而是让你知道遇到什么数据、想问什么问题、该用哪类方法——以及什么时候该停下来人工核对。

本节小结：横向竞争情报的三件产出

■ 算法跑完，必须有能落到业务上的东西。

- ▶ 竞品对比表：结构化字段 + 分群标签，可排序、可筛选、可复核。
- ▶ 竞品地图：二维平面上看分群与空隙，用于找差异化定位。
- ▶ 竞品弱点清单：主题 × 情感的矩阵，用于确定卖点与开发信重点。
- ▶ 验收标准：以上三件产出，换一个人用同样数据能否复现？

关键术语 Key Terms

可交付物 Deliverable

分群标签 Cluster Label

弱点矩阵 Weakness Matrix

可复现 Reproducible

 **实战 Practice** | 课堂演练：给定一个小型消费电子竞品字段表（约 30 行），用 Excel 或代码完成聚类与主题归纳，产出上述三件交付物中的任意一件即可。

08

纵向看趋势：时间序列分析与五维市场筛选

横向看当下，纵向看走向

第 7 节解决“现在谁强”，本节解决“接下来往哪走”。

- ▶ 横向（第 7 节）：同一时点上的竞品比较，回答“现在怎么打”。
- ▶ 纵向（本节）：同一对象随时间的演变，回答“趋势是否成立、还能持续多久”。
- ▶ 两者结合才有决策价值：趋势向上但竞争已经白热化，未必是好市场。
- ▶ 本节的产出：趋势判断 + 市场短名单 + 每个市场的进入理由与风险。

关键术语 Key Terms

纵向分析 Longitudinal Analysis

趋势 Trend

时间序列 Time Series

市场短名单 Shortlist

 图示 Diagram | 典型错误：只看一年的数据就下结论。单年波动可能来自汇率、一次性促销或统计口径调整，至少需要 24-36 个月的数据才谈得上趋势。

趋势识别的三类信号

不同来源的信号，领先时间与可靠性各不相同。

- ▶ 搜索热度：最领先（常领先销量 6-8 周），但只是“关注”不是“购买”。
- ▶ 平台销量与评论增速：最贴近真实成交，领先 2-4 周，但受平台算法影响。
- ▶ 社媒与论坛讨论：爆发快、衰减也快，适合捕捉新品与话题，需甄别营销噪音。
- ▶ 三者的关系：搜索先动 → 内容跟上 → 销量兑现；三者同向时，趋势判断最可靠。

关键术语 Key Terms

搜索热度 Search Interest

评论增速 Review Velocity

社媒声量 Social Buzz

信号一致性 Signal Consistency

💡 例 Example | 交叉验证示例：某品类关键词搜索量连续 3 个月上升、平台头部商品评论月增速由 5% 升到 12%、Reddit 相关讨论帖数量翻倍——三类信号同向，可以判定为“真实需求上行”。

什么是时间序列

按时间顺序排列的观测值，前后点之间不独立。

- ▶ 时间序列 (Time Series): 同一指标按等间隔时间记录的数值序列。
- ▶ 与普通表格数据的根本差别: 样本之间有顺序与相关性, 不能随机打乱。
- ▶ 两个基本任务: 描述 (趋势是什么、是否在变) 与预测 (下一步会怎样)。
- ▶ 数据要求: 等间隔、口径一致、缺失要说明; 换口径必须断开或调整。

关键术语 Key Terms

等间隔 Equally Spaced

自相关 Autocorrelation

平稳性 Stationarity

缺失值插补 Imputation

提示 Tip | 口径一致是底线: 若某月统计口径调整 (例如海关编码变化), 该点前后的数据不能直接连线, 必须在图上标注断点。

时间序列的四个成分

■ 把一条曲线拆开看，才知道涨在哪里、涨得是否健康。

- ▶ 趋势项 (Trend): 长期方向, 通常用平滑或回归提取。
- ▶ 季节项 (Seasonality): 固定周期的重复波动 (月、季、周)。
- ▶ 循环项 (Cycle): 非固定周期的大尺度波动 (如行业周期)。
- ▶ 随机项 (Residual): 扣掉以上三项后的剩余, 异常事件通常在这里暴露。

关键术语 Key Terms

趋势项 Trend

季节项 Seasonality

循环项 Cycle

残差项 Residual

 **公式 Formula** | 加法模型 $Y_t = T_t + S_t + R_t$; 乘法模型 $Y_t = T_t \times S_t \times R_t$ 。季节波动幅度随规模放大时用乘法, 否则用加法。

算法一：时间序列分解 (STL)

■ 把一条曲线拆成趋势、季节与残差三部分，分别观察。

- ▶ **怎么算 (Intuition)**: 用局部加权回归迭代提取趋势，再从残差中估计季节项，反复几轮直到稳定；对异常值比经典分解更稳健。
- ▶ **公式 (Formula)**: STL 基于 $Y_t = T_t + S_t + R_t$ ，通过局部回归与季节子序列平滑交替迭代
- ▶ **用在哪 (Application)**: 把某品类近 3 年进口额拆开后发现：整体在涨（趋势），但每年 Q1 下跌（季节），最近 6 个月残差持续为负（异常信号）。

关键术语 Key Terms

季节趋势分解 STL

局部加权回归 LOESS

残差诊断 Residual Diagnostics

稳健性 Robustness

⚠ 提示 Tip | 最有价值的信息往往在残差里：残差突然持续为负，说明有趋势与季节都解释不了的力量介入（政策、竞品、平台规则），值得单独调查。

算法二：移动平均与指数平滑

用最近若干期的平均代替单期观测，把噪声压下去。

- ▶ **怎么算 (Intuition)**: 移动平均对最近 k 期等权平均; 指数平滑则对越近的数据给越大权重, 且只需保存一个历史值。
- ▶ **公式 (Formula)**: MA: $\hat{y}_t = \frac{1}{k} \sum_{i=1}^k y_{t-i}$; SES:
 $\hat{y}_{t+1} = \alpha y_t + (1 - \alpha) \hat{y}_t$
- ▶ **用在哪 (Application)**: 平滑搜索热度曲线, 避免被单个促销节点的尖峰误导; 也可以做趋势的粗筛。

关键术语 Key Terms

移动平均 Moving Average

指数平滑 Exponential Smoothing

平滑系数 Smoothing Factor

滞后 Lag

⚠ 提示 Tip | 权衡: 窗口越长越平滑但越滞后; α 越大越灵敏但越容易被噪声带偏。判断大方向用大窗口, 做预警用小窗口。

算法三：Holt-Winters 三重指数平滑

I 在指数平滑基础上，同时跟踪水平、趋势和季节三件事。

- ▶ **怎么算 (Intuition)**: 三个递推式分别更新水平、趋势与季节因子，再加权组合成预测值。
- ▶ **公式 (Formula)**: $\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$;
 $b_t = \beta(\ell_t - \ell_{t-1}) + (1 - \beta)b_{t-1}$; $s_t = \gamma(y_t - \ell_t) + (1 - \gamma)s_{t-m}$
- ▶ **用在哪 (Application)**: 预测未来 3 个季度的品类需求，为备货、排产与展会排期提供依据。

关键术语 Key Terms

三重指数平滑 Holt-Winters

水平项 Level

季节因子 Seasonal Factor

预测区间 Prediction Interval

💡 例 Example | 消费电子的强季节性：北半球 Q4 假日季、开学季、部分地区雨季对户外音频产品的影响——这些周期项必须被显式建模，否则会被误读成“趋势”。

算法四：ARIMA 与 SARIMA

I 用历史值、差分和历史误差三部分组合出预测。

- ▶ **怎么算 (Intuition)**: 先把不平稳的序列差分到平稳, 再用自回归 (AR) 与移动平均 (MA) 项解释剩余结构, 季节版本再加上季节项。
- ▶ **公式 (Formula)**: $ARIMA(p, d, q)$; SARIMA 增加季节项 $(P, D, Q)_m$, d 、 D 为差分阶数
- ▶ **用在哪 (Application)**: 对进口额、搜索指数做 1–6 个月的短期预测, 用于设定备货与广告预算。

关键术语 Key Terms

自回归 AR

差分 Differencing

移动平均项 MA Term

平稳性检验 Stationarity Test

⚠ 提示 Tip | 前置检查不能省: 先做平稳性检验 (如 ADF), 差分到平稳再建模。对不平稳序列直接套 ARIMA, 会得到“拟合很好、预测没用”的假象。

算法五：变点检测 (Change Point Detection)

找出“趋势突然改变”的那一天、那一月。

- ▶ **怎么算 (Intuition)**: 在序列上滑动并比较前后两段的统计特征；当均值或方差发生显著跳变时，判定为变点。
- ▶ **公式 (Formula)**: CUSUM 统计量
$$S_t = \max(0, S_{t-1} + y_t - \mu - \delta);$$
或用 PELT 等方法最小化分段代价
- ▶ **用在哪 (Application)**: 识别竞品突然降价、某国加征关税、平台算法调整导致的流量突变——这些都是策略必须响应的时刻。

关键术语 Key Terms

变点 Change Point

累积和控制图 CUSUM

分段 Segmentation

结构性突变 Structural Break

💡 **例 Example** | 实战发现：某竞品价格在 3 月中旬出现结构性变点，此后搜索热度同步上行——很可能是一轮降价促销的开始。据此把自己的促销排期错开两周，避免正面价格战。

算法六：增长率与复合增长率

单看一年会误判，必须用复合增长率看长期速度。

► **怎么算 (Intuition)**: 同比增长率比较去年同期 (消除季节影响); 复合增长率把多年的变化摊平到每一年。

► **公式 (Formula)**: 同比 YoY = $\frac{y_t - y_{t-12}}{y_{t-12}}$; 复合增长

$$\text{CAGR} = \left(\frac{V_{\text{末}}}{V_{\text{初}}} \right)^{1/n} - 1$$

► **用在哪 (Application)**: 用 CAGR 横向比较多个目标市场的增长速度, 避免被某一年的异常高增长带偏。

关键术语 Key Terms

同比增长 YoY

环比增长 MoM

复合增长率 CAGR

基数效应 Base Effect

📊 公式 Formula | 算例: 某市场进口额由 1.0 亿增至 1.6 亿、历时 3 年, 则 $\text{CAGR} = (1.6/1.0)^{1/3} - 1 \approx 17\%$; 若中间有一年跳涨 60%, 说明存在一次性因素, 需查清原因再判断可持续性。

算法七：生命周期阶段判断

判断品类处于导入、成长、成熟还是衰退，策略完全不同。

- ▶ **怎么算 (Intuition)**: 用两个维度定位: 增长率 (纵向速度) 与渗透率或玩家数量 (横向拥挤度)。
- ▶ **公式 (Formula)**: 经验判据: 成长期通常“增速高 (年增 15% 以上) 且渗透率低 (低于 30%)”; 成熟期表现为增速趋平、价格战频发
- ▶ **用在哪 (Application)**: 判断该品类在目标市场处于哪个阶段, 决定是全面进入、试点进入还是观望。

关键术语 Key Terms

产品生命周期 Product Life Cycle

渗透率 Penetration Rate

成长期 Growth Stage

成熟期 Maturity

 **图示 Diagram** | 四阶段与信号: 导入期 (增速低、玩家少、教育与认知成本高) → 成长期 (增速高、玩家涌入、格局未定) → 成熟期 (增速平、价格战、渠道为王) → 衰退期 (负增长、替代品出现)。

算法八：预测精度评估 (MAE / RMSE / MAPE)

预测必须带误差范围，否则无法用于决策。

- ▶ **怎么算 (Intuition)**: 把预测值与真实值逐点比较: MAE 看平均偏差, RMSE 对大误差更敏感, MAPE 看相对误差。
- ▶ **公式 (Formula)**: $MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$;
 $RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$; $MAPE = \frac{100\%}{n} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|$
- ▶ **用在哪 (Application)**: 比较不同预测方法的可靠性, 并为汇报中的预测值配上误差区间。

关键术语 Key Terms

平均绝对误差 MAE

均方根误差 RMSE

平均绝对百分比误差 MAPE

回测 Backtest

⚠ 提示 Tip | MAPE 在真实值接近 0 时会爆炸, 此时应改用 MAE。向决策者汇报时, 永远给出“预测值 ± 误差范围”, 而不是一个孤零零的点估计。

算法九：领先指标与滞后指标

■ 有些指标先动，有些后动；先动的可以用来预警。

- ▶ **怎么算 (Intuition)**: 计算两个序列在不同时滞下的相关性，相关性最高处的时滞就是领先期数。
- ▶ **公式 (Formula)**: 互相关 $\rho(k) = \text{CORR}(x_t, y_{t+k})$, 取 $|\rho(k)|$ 最大处的 k 作为领先期
- ▶ **用在哪 (Application)**: 用关键词搜索热度领先平台销量 1-2 个月的关系，提前判断品类走势并安排备货。

关键术语 Key Terms

领先指标 Leading Indicator

滞后指标 Lagging Indicator

互相关 Cross-correlation

时滞 Time Lag

💡 例 Example | 典型规律：搜索热度在旺季前 6-8 周起量，平台销量在旺季前 2-3 周才起来。中间这段窗口，就是备货与广告投放的最佳时机。

算法十：机器学习预测（Prophet / 梯度提升 / LSTM）

■ 把时间序列变成有特征的表格问题，或用专门处理序列的模型。

- ▶ **怎么算 (Intuition)**: Prophet 把序列拆成趋势、季节与节假日三段分别建模再相加；梯度提升靠手工构造滞后特征；LSTM 用循环结构记忆长期依赖。
- ▶ **公式 (Formula)**: Prophet: $y(t) = g(t) + s(t) + h(t) + \varepsilon_t$ (趋势 + 季节 + 节假日)
- ▶ **用在哪 (Application)**: 预测需求峰值，用于排产、备货与广告预算；相比 ARIMA 更易处理缺失值与节假日。

关键术语 Key Terms

趋势季节分解模型 Prophet

滞后特征 Lag Feature

长短期记忆网络 LSTM

外生变量 Exogenous Variable

⚠ 提示 Tip | 模型对外生冲击无能为力：关税变动、平台规则调整、疫情这类事件必须由人给出情景假设，并作为回归变量输入，模型才能反映它们。

算法十一：时间序列的过拟合与数据泄漏

用未来数据训练模型，会得到漂亮但毫无用处的结果。

- ▶ **怎么算 (Intuition)**: 随机划分数据集在时间序列上是错误的做法，因为训练集里混入了未来信息。
- ▶ **公式 (Formula)**: 正确做法：训练集必须完全早于验证集与测试集；特征只能使用当期及以前可获得的信息
- ▶ **用在哪 (Application)**: 任何回测都必须按时间顺序切分；涉及“事后才知道”的变量（如最终销量）绝不能作为特征。

关键术语 Key Terms

数据泄漏 Data Leakage


时间切分 Temporal Split

前视偏差 Look-ahead Bias


滚动回测 Walk-forward Validation

⚠ 提示 Tip | 三条铁律：不能随机打乱时间顺序；特征只能用当期及以前的信息；报告结果时必须说明切分方式。违反任何一条，回测准确率都不足采信。

时间序列分解示意：趋势项、趋势 + 季节、以及实际观测



产品生命周期四阶段：增长率的形状



Google Trends 的正确读法

■ 它给的是相对热度，不是绝对销量——用错会得出完全错误的规模判断。

- ▶ 相对指数：100 表示该时段内的最高点，其余按比例缩放，因此不能跨关键词直接比大小。
- ▶ 跨地区比较要在同一时间窗、同一关键词下进行，并注意样本量小的地区噪声更大。
- ▶ 正确的用法：看方向与拐点（什么时候起量、什么时候见顶），而不是看规模。
- ▶ 常见误用：把两个不同关键词的指数直接相减，得出“某国需求是另一国的 3 倍”。

关键术语 Key Terms

相对指数 Relative Index

归一化 Normalization

拐点 Inflection Point

样本量偏差 Small-sample Bias

⚠ 提示 Tip | 要做跨市场比较时的正确做法：固定同一个关键词、同一时间窗，先取各地区曲线，再用当地的品类进口额或平台销量去校准绝对规模——热度只能定方向，规模要靠贸易数据。

从趋势判断到市场筛选

趋势是否成立

三类信号同向

处于哪个阶段

生命周期

能不能进

门槛与成本

划不划算

五维评分

趋势只回答“值不值得看”，评分卡才回答“值不值得做”

目标市场筛选：五个维度

■ 把”感觉这个市场不错”变成可打分、可复核的判断。

- ▶ 市场规模：品类进口额与本地消费规模，决定天花板。
- ▶ 市场增速：三年 CAGR 与最近一年增速，判断是否仍在成长。
- ▶ 竞争强度：头部集中度与价格战程度，判断切入难度。
- ▶ 进入门槛：认证、关税、渠道与本地化要求，判断一次性投入。
- ▶ 自身匹配度：产品定位、产能、资金与团队能力，判断”是不是我的机会”。

关键术语 Key Terms

市场筛选 Market Screening

竞争强度 Competitive Intensity

进入门槛 Entry Barrier

战略匹配 Strategic Fit

📊 公式 Formula | 加权评分： $S = \sum_{i=1}^5 w_i s_i$, $\sum w_i = 1$ 。权重按企业当前阶段设定：起步期重”门槛低”，扩张期重”规模大”。

市场筛选评分卡：三个候选国的算例（示意）

维度	权重	A 国	B 国	C 国	说明	评分依据
市场规模	25%	5	3	4	进口额	Comtrade 三年数据
市场增速	25%	3	5	4	CAGR	三年复合增速
竞争强度	20%	2	4	3	集中度	头部品牌份额
进入门槛	15%	3	3	2	认证关税	认证费用与税率
自身匹配	15%	4	3	5	产品定位	与现有产品线契合度
加权总分	100%	3.55	3.65	3.65	—	评分 1–5 分，5 分为最优

来源：表中数字为课堂算例，用于演示评分方法，不代表任何真实国家的实际数据。

评分卡怎么用才不出错

I 评分卡是讨论工具，不是自动决策机器。

- ▶ 权重必须由业务方事先确定，不能看到结果后再调权重。
- ▶ 每一分都要写依据：哪个数据源、哪个年份、什么口径。
- ▶ 总分相近时（差距小于 0.3），看“短板”决定——短板的修复成本决定实际可行性。
- ▶ 评分卡之外保留“一票否决”：触碰认证红线或合规风险的市场直接排除。

关键术语 Key Terms

权重事先确定 Ex-ante Weights

评分依据 Scoring Rationale

短板效应 Bottleneck Effect

一票否决 Veto Criterion

 **实战 Practice** | 课堂讨论：上表中 A 国规模最大但竞争最激烈，B 国与 C 国总分相同。若你的产品是新品、资金有限，你会选哪个？请用“短板法”给出理由。

四个常见错误

这些错误在真实报告里反复出现。

- ▶ 只看规模不看门槛：市场很大，但认证与渠道成本吃掉了全部利润。
- ▶ 只看大盘不看细分：大盘在跌，但你所在的细分价格带可能在涨（反之亦然）。
- ▶ 用单年数据判断趋势：一次性促销、汇率或口径调整都会造成假象。
- ▶ 忽略自身匹配：评测得分最高的市场，未必是你现有产品与团队能拿下的市场。

关键术语 Key Terms

大盘与细分 Aggregate vs Segment

可得性偏差 Availability Bias

能力匹配 Capability Fit

假趋势 Spurious Trend

提示 Tip | 一条自检：如果你的结论换成竞争对手来做也能得出，那么这个结论没有形成优势——调研的价值在于找到“别人没看到或不相信”的切口。

本节小结：纵向分析的三件产出

趋势判断必须落到“进不进、怎么进”上。

- ▶ 趋势结论：该品类在目标市场处于哪个生命周期阶段，信号是否一致。
- ▶ 市场短名单：用多维评分卡从长名单收敛到 2-3 个市场，并写明每个市场的进入理由。
- ▶ 风险清单：每个市场的主要门槛与不确定性，以及需要进一步验证的假设。
- ▶ 与第 7 节的衔接：短名单确定后，用横向竞品分析看“这些市场里谁在卖、卖得怎么样”。

关键术语 Key Terms

趋势结论 Trend Conclusion

短名单 Shortlist

风险清单 Risk Register

待验证假设 Assumption to Validate

 **实战 Practice** | 课堂演练：任选一个消费电子细分品类，用 Comtrade 或 Trade Map 查 2 个国家的三年进口数据，判断趋势并给出评分卡雏形——这就是第 11 节案例的前半部分。

09

谁才是值得投入的客户：ICP 与画像卡

市场选对了，客户选错一样卖不动

「ICP 回答”什么样的公司值得投入”，Persona 回答”对接人关心什么”。

- ▶ 市场层面（第 8 节）：确定进入哪个国家、哪个品类。
- ▶ 客户层面（本节）：确定在这个市场里，先打哪一类公司、找哪一类人。
- ▶ 两者是不同粒度：国家 → 客户类型 → 具体公司 → 具体联系人。
- ▶ 本节的产出：一份 ICP 定义 + 若干张画像卡 + 一份可执行的客户筛选条件。

关键术语 Key Terms

理想客户画像 ICP

用户画像 Persona

客户筛选 Account Filtering

目标清单 Target List

 图示 Diagram | 顺序不能颠倒：先定义 ICP（公司长什么样），再定义 Persona（人关心什么）。跳过 ICP 直接找人，会得到一份“看起来很多、实际都无法成交”的名单。

ICP 与 Persona：两个层次，两种用途

■ 一个描述公司，一个描述人。

- ▶ ICP (Ideal Customer Profile)：从公司维度描述“最容易成交、最值得投入”的客户类型。
- ▶ Persona (用户画像)：从个人维度描述“决策链上的人关心什么、担心什么”。
- ▶ ICP 用于筛名单：把 5,000 家公司收敛到 300 家。
- ▶ Persona 用于写内容：决定开发信、报价单与演示材料里该强调什么。

关键术语 Key Terms

公司维度 Firmographic

个人维度 Demographic

筛选条件 Filter Criteria

内容策略 Content Strategy

💡 例 Example | 举例：ICP 是“年进口额 500 万–5,000 万美元、有自有渠道的中型分销商”；Persona 是“采购经理，40 岁上下，最怕库存积压与售后返修，最看重交期与认证完整性”。

B2B 客户画像的六个维度

六个维度写清楚，客户名单才有筛选价值。

- ▶ 行业与产品线：做什么品类、有没有互补产品线。
- ▶ 公司规模：员工数、年营收、进口额量级。
- ▶ 采购角色：进口商、分销商、零售商、品牌方、工程师、电商卖家。
- ▶ 渠道结构：线上/线下、自营/第三方、覆盖区域。
- ▶ 采购周期与节奏：何时下单、多久补货、旺季在什么时候。
- ▶ 交易条件：付款方式、信用期、最小起订量接受度。

关键术语 Key Terms

渠道结构 Channel Structure

采购周期 Purchase Cycle

信用期 Credit Terms

最小起订量 MOQ

 **实战 Practice** | 实战筛选条件示例：年进口额 300 万美元以上 + 有 5 年以上历史 + 已有中国供应商 + 品类重合度大于 30%——四条同时满足，才进入优先联系名单。

B2C 客户画像的四个维度

■ To C 不需要公司信息，但需要场景与行为。

- ▶ 人群特征：年龄、性别、收入、地域、家庭阶段。
- ▶ 使用场景：在什么场合用、和谁一起用、替代了什么。
- ▶ 价格敏感度：愿意为哪些特性多付钱、在哪些点上极度敏感。
- ▶ 购买与复购：决策时长、评价依赖度、复购间隔。

关键术语 Key Terms

使用场景 Use Case

价格敏感度 Price Sensitivity

复购率 Repurchase Rate

决策时长 Decision Time

💡 例 Example | 消费电子示例：美国 25–35 岁户外运动爱好者，徒步与露营场景，愿意为防水与续航多付 20%，但对品牌溢价敏感；购买前平均查看 4.2 条评论，复购间隔约 14 个月。

画像的数据来源

■ 画像不是猜出来的，是从已有数据里读出来的。

- ▶ 海关提单数据：看到“谁在进口、进口什么、从哪里进、多大规模”。
- ▶ 平台买家与评价：从评论者身份、提问内容反推真实使用场景。
- ▶ 展会与协会名录：高质量的公司名单，且多有公开的产品线信息。
- ▶ 领英与公司官网：组织架构、采购角色、近期动态。
- ▶ 已有客户：最可靠的一组样本——用它来校准 ICP。

关键术语 Key Terms

提单数据 Bill of Lading


名录 Directory

组织架构 Org Chart

基准样本 Benchmark Sample

⚠ 提示 Tip | 合规提醒：领英等平台对自动化访问有明确限制；本讲建议手工核对重点客户，把自动化留给公开名录与授权数据。

从线索到画像的流程



用 AI 把零散信息结构化画像卡

这是 AI 在客户开发环节最稳妥、最有价值的用法之一。

- ▶ 输入：你已核实的公开信息（官网介绍、产品线页面、新闻稿、展会资料）。
- ▶ 任务：按固定字段抽取并填写画像卡，缺失项明确标注“未获取”。
- ▶ 要求：每条字段附上来源链接，便于人工复核。
- ▶ 禁止：让 AI 凭“行业常识”补全你没提供的公司信息。

关键术语 Key Terms

结构化抽取 Structured Extraction

字段模板 Field Template

来源标注 Source Attribution

缺失标注 Missing Flag

⚠ 提示 Tip | 提示词模板：「以下是某公司的公开资料（粘贴）。请按以下字段抽取信息：产品线、渠道类型、进口规模、采购角色、覆盖区域。每个字段必须给出原文出处；资料中没有的字段写“未提及”，不要推测。」

画像卡的字段设计

字段要可勾选、可打分、可检索，否则就是一段无法使用的好文字。

- ▶ 定性字段：产品线、渠道类型、覆盖区域、认证要求。
- ▶ 定量字段：年进口额区间、员工规模、SKU 数量、补货频次。
- ▶ 打分字段：品类重合度（1-5）、采购能力（1-5）、可达性（1-5）。
- ▶ 状态字段：已联系/已回复/已报价/已寄样/成交/搁置——用于后续跟进管理。

关键术语 Key Terms

字段类型 Field Type

打分字段 Scored Field

状态机 Status Machine

可检索 Searchable

📦 实战 Practice | 实用建议：画像卡直接做成表格（Excel 或 CRM），第一列放公司名，最后一列放“下一步动作与日期”。能被排序和筛选的画像，才是能驱动动作的画像。

采购角色：决策链上的五类人

I 找对人，比说对话更重要。

- ▶ 使用者 (User)：真正使用产品的人，关心体验与易用性。
- ▶ 影响者 (Influencer)：技术或品质部门，关心规格、认证与兼容性。
- ▶ 决策者 (Decision Maker)：老板或业务负责人，关心投入产出与风险。
- ▶ 采购 (Buyer)：采购部门，关心价格、交期与付款条件。
- ▶ 把关者 (Gatekeeper)：如财务、法务或认证部门，能否决但不推动。

关键术语 Key Terms

决策链 Decision Chain

使用者 User

影响者 Influencer

把关者 Gatekeeper

⚠ 提示 Tip | 常见错误：只联系采购，忽略影响者与把关者。消费电子尤其如此——品质或认证部门一句“这个认证不完整”，就能让一笔谈好的订单停摆。

采购角色与关注点对照表：同一产品，五种说法

角色	最关心	开发信里应该强调什么
使用者	体验、易用性、外观	场景化描述：在什么场合解决什么问题
影响者	规格、认证、兼容性	参数与认证清单，附检测报告编号
决策者	投入产出、风险、增长	市场机会与竞品对比，说明为什么现在做
采购	价格、交期、付款条件	报价区间、交期承诺、MOQ 与账期方案
把关者	合规、责任、可追溯	合规文件完整性、责任边界与售后条款

用法：同一份产品资料，写给五类人要改写五次。群发同一封邮件，等于对五类人都没说对话。

渠道类型决定打法

I 同样叫“客户”，合作方式完全不同。

- ▶ 进口商/分销商：看重价格空间与独家区域，适合长单与稳定供货。
- ▶ 零售商：看重动销与退换货政策，适合小批量、多频次。
- ▶ 品牌方：看重代工能力与品控，适合自有品牌定制 (OEM/ODM)。
- ▶ 电商卖家：看重上新速度与一件代发能力，适合柔性供应链。
- ▶ 工程师/集成商：看重技术方案与项目配合，适合定制与技术支持。

关键术语 Key Terms

分销商 Distributor

原始设备制造 OEM

原始设计制造 ODM

代发 Dropshipping

 **实战 Practice** | 策略含义：如果你的产能适合长单大单，就别把时间花在电商卖家身上；反之亦然。ICP 里“渠道类型”这一条，往往比“公司规模”更能预测成交概率。

画像验证：用已成交客户回测

■ 没验证过的画像，只是一份自我感觉良好的文字。

- ▶ 把现有客户按画像字段逐个打分，看成交客户是否集中在某几个特征上。
- ▶ 若成交客户的特征高度分散，说明画像过宽，需要收紧条件。
- ▶ 若成交客户集中在某个特征而你此前没注意到，说明该特征才是真正关键变量。
- ▶ 用验证后的画像去筛选新名单，成交率提升才有意义。

关键术语 Key Terms

回测 Backtest

特征集中度 Feature Concentration

画像收紧 Profile Tightening

成交率 Win Rate

💡 例 Example | 回测示例：某企业统计 30 家成交客户发现，其中 22 家都有“已有中国供应商且合作超过 3 年”这一特征——说明“换供应商的经验”比“规模大小”更能预测成交，画像应据此调整。

画像的四个常见错误

■ 这些错误会让画像变成装饰品。

- ▶ 过于宽泛：“年营收 1,000 万美元以上、对消费电子感兴趣”——这几乎筛不掉任何人。
- ▶ 只看规模：大公司采购流程长、账期压力大，未必适合初创供应商。
- ▶ 忽略决策链：只写公司特征，不写对接人角色与关注点。
- ▶ 凭印象填写：没有来源、没有日期的画像，无法复核也无法迭代。

关键术语 Key Terms

可操作性 Actionability

可复核 Verifiable

决策链 Decision Chain

迭代 Iteration

⚠ 提示 Tip | 自检问题：拿着这份画像，另一个人能不能独立筛出一份名单？如果答案是“不能”，说明画像还不够具体。

画像范例 (B2B): 德国中型消费电子分销商

一份可直接用于筛选的画像卡。

- ▶ 公司特征: 员工 50-200 人, 年营收 2,000 万-1 亿欧元, 进口占比 60% 以上。
- ▶ 产品线: 音频配件、充电类、智能家居, 有自有品牌但以代理为主。
- ▶ 渠道: 线下连锁 + 自有电商 + 亚马逊欧洲站。
- ▶ 合规要求: CE、RoHS、REACH 齐全, 要求德文说明书与欧代信息。
- ▶ 对接角色: 品类采购经理 (决策) + 品质工程师 (把关)。

关键术语 Key Terms

品类采购经理 Category Buyer

授权代表 Authorized Representative

自有品牌 Private Label

代理 Agency

 **实战 Practice** | 开发信要点: 强调认证完整性、德语资料齐备、交期稳定性与欧洲售后支持——这四点正好对应上述角色最关心的内容。

画像范例 (B2C): 美国户外音频用户

■ To C 画像要能直接指导产品与内容。

- ▶ 人群: 25-35 岁, 中高收入, 常住户外运动活跃地区。
- ▶ 场景: 徒步、露营、骑行; 关注防水、续航、佩戴稳固。
- ▶ 价格: 可接受 60-120 美元, 为防水与续航愿意多付约 20%。
- ▶ 行为: 购买前看 4 条以上评论, 重视真实使用视频与售后评价。

关键术语 Key Terms

场景化需求 Scenario-based Need

支付意愿 Willingness to Pay

评论依赖度 Review Reliance

内容种草 Content Seeding

💡 例 Example | 由此推导的动作: 详情页首屏直接演示防水与续航; 联系户外类中小博主做真实场景测评; 在差评回复中主动解决“佩戴松动”这一高频抱怨。

画像如何驱动后续动作

I 画像的终点不是文档，而是一系列具体决定。

- ▶ 决定主推产品：优先推与目标客户产品线互补、且重合度高的型号。
- ▶ 决定内容重点：按决策链角色分别准备材料，而不是一份通稿。
- ▶ 决定渠道选择：分销优势地区走代理，电商活跃地区走平台。
- ▶ 决定报价策略：对价格敏感型客户给阶梯价，对技术型客户给整体方案。
- ▶ 衔接下一讲：画像完成后，就进入客户触达与开发信撰写。

关键术语 Key Terms

内容分层 Content Layering

渠道匹配 Channel Fit

阶梯报价 Tiered Pricing

下讲衔接 Next Lecture

 **实战 Practice** | 本讲到这里，你已经完成了“选市场 + 选客户”两件事；下一讲解决第三件事——怎么把客户真正触达并转化。

本节小结：画像三件产出

■ 能被筛选、能被复核、能被迭代，画像才有价值。

- ▶ 一份 ICP 定义：3-5 条硬性筛选条件，能量化、能执行。
- ▶ 若干张画像卡：字段完整、来源可查、含决策链角色。
- ▶ 一份目标名单：按打分排序，第一列公司名、最后一列下一步动作与日期。
- ▶ 验收标准：把这份名单交给同事，他能否按同样的标准独立复现？

关键术语 Key Terms

硬性条件 Hard Criteria

画像卡 Profile Card

目标名单 Target List

可复现 Reproducible

 图示 Diagram | 提醒：ICP 与画像不是一次性的文档，而是随成交数据迭代的工具——每成交 10 家客户，就值得回测更新一次。

10

教学难点：让 AI 输出经得起核对

为什么这是本讲最难的环节

AI 让“产出”变得容易，也让“可信”变得更难。

- ▶ 产出门槛降低：一份看起来完整的报告，几分钟就能生成。
- ▶ 核实成本上升：阅读速度跟不上生成速度，人容易跳过核对直接采用。
- ▶ 后果放大：调研结论会直接影响选市场、备货与报价，错的代价很高。
- ▶ 本节的产出：一套可操作的验证流程 + 一张可信度评分卡。

关键术语 Key Terms

产出门槛 Production Barrier

核实成本 Verification Cost

决策风险 Decision Risk

可用性 Usability

 图示 Diagram | 本节的立场：不是“少用 AI”，而是“把 AI 用在能被核实的位置上”。可信度不来自模型更强，而来自流程更严。

AI 调研输出的四类错误

知道错误长什么样，才认得出它。

- ▶ 来源虚构：给出不存在的报告名、机构名或链接（幻觉）。
- ▶ 数据过时：引用几年前的数字，却当成现状。
- ▶ 口径混淆：把不同国家、不同年份、不同统计口径的数字并列。
- ▶ 以偏概全：用少量样本或单一平台数据推断整体市场。

关键术语 Key Terms

幻觉 Hallucination

时效性 Recency

口径一致性 Comparability

样本代表性 Representativeness

⚠ 提示 Tip | 四类错误的共同特征：**** 看起来都很合理 ****。它们不会以明显错误的形式出现，而是以“格式完整、语气自信”的形式出现——这正是危险之处。

错误一：来源虚构

最危险的一类错误，因为它伪造了证据本身。

- ▶ 典型表现：引用一份“某机构 2025 年报告”，但该报告并不存在。
- ▶ 常见变体：把真实机构与不存在的报告名组合；把真实报告的作者或年份写错。
- ▶ 识别方法：点开链接、搜索报告全名、到该机构官网核对。
- ▶ 一条规则：** 无法点开核对的来源，一律视为不存在 **。

关键术语 Key Terms

引用虚构 Fabricated Citation

可验证来源 Verifiable Source

链式核对 Chain Verification

零信任 Zero Trust

💡 例 Example | 真实形态：“根据 Statista 2025 年东南亚消费电子报告，该市场规模为 320 亿美元。”——听起来完全可信，但若 Statista 官网查不到该报告，这句话就必须整句删掉。

错误二：数据过时

模型的知識有截止日期，統計數據的發布也有滯后。

- ▶ 模型层面：训练数据截止之后发生的事情，模型不知道。
- ▶ 统计层面：官方统计通常滞后 6–18 个月发布，去年的数可能还没出。
- ▶ 表现：把三年前的市场规模当作现状，把已停产的型号当作在售产品。
- ▶ 应对：所有数字都标注年份；关键判断必须用最新可得数据复核。

关键术语 Key Terms

知识截止 Knowledge Cutoff

发布滞后 Publication Lag

时点标注 Time Stamping

最新可得 Latest Available

⚠ 提示 Tip | 写作规范：任何市场数字后面都必须跟年份，例如“2024 年进口额为……”。没有年份的数字，在报告里等于没有来源。

错误三：口径混淆

❗ 数字都对，放在一起就错了。

- ▶ 时间口径：把 2023 年的进口额与 2025 年的增速放在同一张表。
- ▶ 地域口径：把“ 欧盟整体” 与“ 德国” 的数据混用。
- ▶ 计价口径：FOB 与 CIF 混用，导致成本估算偏差。
- ▶ 品类口径：HS 编码不一致，把不同品类加总。

关键术语 Key Terms

口径一致性 Comparability

货币与单位 Currency and Unit

统计口径 Statistical Definition

可比性检查 Comparability
Check

⚠ 提示 Tip | 一张必查清单：年份是否一致？币种是否统一？FOB 还是 CIF？HS 编码是否同一版本？四个问题都必须有明确答案。

错误四：以偏概全

用可见的样本推断整体，是最隐蔽的错误。

- ▶ 平台样本偏差：只看电商平台，忽略线下渠道占比很高的市场。
- ▶ 样本量不足：用 20 条评论推断“消费者普遍认为……”。
- ▶ survivorship 偏差：只看到在售的赢家，看不到已退出市场的失败者。
- ▶ 语言偏差：只用英文检索，漏掉占多数的小语种本地信息。

关键术语 Key Terms

抽样偏差 Sampling Bias

幸存者偏差 Survivorship Bias

样本量 Sample Size

覆盖偏差 Coverage Bias

💡 例 Example | 典型表述：“调研了 30 个竞品的评论，用户普遍抱怨续航不足。”——30 个样本不足以支撑“普遍”，应改为“在抽样的 30 个竞品中，续航是出现频次最高的差评主题”。

■ 一条可用结论必须同时具备这五项。

- ▶ 结论 (Claim): 明确、可判定、不含模糊形容词。
- ▶ 来源 (Source): 可点开核对的原始出处, 不是二手转述。
- ▶ 时间 (Time): 数据的统计年份与获取日期。
- ▶ 口径 (Definition): 单位、币种、统计范围与计价方式。
- ▶ 置信度 (Confidence): 高/中/低, 并说明不确定性来自哪里。

关键术语 Key Terms

证据链 Evidence Chain


可判定性 Falsifiability

置信度 Confidence Level

不确定性 Uncertainty

 图示 Diagram | 写法示范: "该品类在 A 国 2024 年进口额约 X 亿美元 (来源: UN Comtrade, 2026-03 获取; 口径: HS 8518, CIF 计价); 置信度中——因 2025 年数据尚未发布, 且转口贸易可能造成低估。"

三重验证法



验证一：官方来源交叉

I 同一个数字，至少找到两个独立来源。

- ▶ 独立来源指数据产生方不同：如联合国数据库与目标国海关是两个独立来源。
- ▶ 相互转述的媒体文章不算独立来源——它们可能都源自同一份原始报告。
- ▶ 若两个来源差异大于 15%，需要给出解释或在报告中同时列出。
- ▶ 差异本身就是信息：往往提示口径不同或存在转口贸易。

关键术语 Key Terms

独立来源 Independent Source

交叉验证 Cross-validation

差异解释 Discrepancy Explanation

原始出处 Primary Source

 **实战 Practice** | 操作步骤：先在 UN Comtrade 查到数字 → 再到目标国海关或统计局核对 → 若一致，写“两源一致”；若不一致，把两个数字都写出来并说明可能原因。

验证二：数字复算

I 能自己算的，一定要自己算一遍。

- ▶ 增长率、占比、CAGR、单位换算——这些计算不应依赖 AI。
- ▶ 用计算器或表格重算一遍，成本极低但能拦下大量错误。
- ▶ 特别注意：百分比的分母是什么、加减是否符合会计逻辑。
- ▶ 发现算不通时，先怀疑数据口径，再怀疑计算。

关键术语 Key Terms

复算 Recomputation

分母陷阱 Denominator Trap

单位换算 Unit Conversion

算术校验 Arithmetic Check

💡 例 Example | 课堂演示：AI 给出“该市场三年增长 45%，CAGR 为 15%”。复算： $(1.45)^{1/3} - 1 \approx 13.2\%$ ，而非 15%。差 1.8 个百分点，长期预测会被放大成显著偏差。

验证三：量级与常识检查

用粗略估算判断数字是否离谱。

- ▶ 费米估算 (Fermi Estimate)：用人口、渗透率、人均消费等粗参数快速估出量级。
- ▶ 检查方法：算出的市场容量，分摊到人均或每店销量，看是否合理。
- ▶ 常见离谱信号：人均消费超过当地收入水平、增速连续多年超过 50%、份额总和超过 100%。
- ▶ 量级不对时，先回到口径与单位找问题。

关键术语 Key Terms

费米估算 Fermi Estimate

量级检查 Order-of-magnitude
Check

合理性检验 Sanity Check

自下而上 Bottom-up

💡 例 Example | 量级检查示例：某报告称某国该品类市场 50 亿美元、人口 5,000 万，则人均约 100 美元/年。对照当地人均可支配收入，若明显偏高，则该数字很可能把区域整体口径当成了本国口径。

提示工程要点（一）：要求给出来源

在提示里就把“可核实”作为硬性要求。

- ▶ 明确要求：每条结论后附来源名称与可访问链接。
- ▶ 明确禁止：不允许引用无法提供链接的来源。
- ▶ 明确标注：无法核实的部分单独列出，写“未找到可靠来源”。
- ▶ 复核动作：拿到输出后，先抽查 3 条引用是否能打开。

关键术语 Key Terms

来源要求 Citation Requirement

可访问链接 Accessible Link

抽查 Spot Check

零信任 Zero Trust

提示 Tip | 提示词模板：「请为每一条结论提供来源名称与可点击的链接。如果你无法提供真实链接，请明确写“未找到可靠来源”，不要编造引用。宁可少写，也不要不确定的信息。」

提示工程要点（二）：区分事实与推断

让模型把“看到的”和“想到的”分开写。

- ▶ 要求分栏输出：事实（来自资料） / 推断（模型分析） / 建议（行动）。
- ▶ 事实栏必须附来源；推断栏必须说明依据；建议栏必须说明前提。
- ▶ 这样做的价值：读者能一眼看出哪些需要核实、哪些只是观点。
- ▶ 交付前自检：把推断误读为事实，是报告最常见的失真方式。

关键术语 Key Terms

事实与推断 Fact vs Inference

分栏输出 Separated Output

依据说明 Rationale

可追溯 Traceable

💡 例 Example | 分栏示例——事实：A 国 2024 年该品类进口额 X（来源）。推断：需求仍在增长，但增速放缓（依据：三年增速由 20% 降至 8%）。建议：先小批量试单（前提：认证周期约 8 周）。

提示工程要点（三）：要求标注不确定性

■ 不确定不是缺点，隐藏不确定才是。

- ▶ 要求模型对每条结论给出置信度（高 / 中 / 低）并说明原因。
- ▶ 要求列出“这条结论在什么情况下会不成立”。
- ▶ 要求指出“还缺哪些信息才能提高置信度”。
- ▶ 报告价值往往体现在最后这一项：它直接告诉决策者下一步该补什么数据。

关键术语 Key Terms

置信度 Confidence

失效条件 Falsification Condition

信息缺口 Information Gap

下一步验证 Next Validation

 **实战 Practice** | 在报告里保留“待验证假设”一节：把置信度低的结论集中列出，并写明验证方法（如查目标国海关原始数据、联系当地渠道商访谈）。

什么时候不能用 AI

I 五类场景，必须人工主导或完全不用。

- ▶ 需要一手数据的场合：真实客户访谈、实地考察、样品测试。
- ▶ 涉及法律与合规责任的场合：认证结论、合同条款、税务处理。
- ▶ 涉及未公开信息的场合：竞品内部数据、客户私有信息。
- ▶ 高风险决策的最终依据：金额巨大且不可逆的投入决策。
- ▶ 需要署名的对外交付：最终报告必须由人负责，AI 只能作为过程工具。

关键术语 Key Terms

一手数据 Primary Data

法律责任 Legal Liability

不可逆决策 Irreversible Decision

署名责任 Accountability

⚠ 提示 Tip | 一条底线：涉及金额、合规与法律后果的结论，必须以官方文件或专业人士意见为准，AI 输出只能作线索。

调研报告可信度评分卡

维度	权重	评分要点	常见扣分项
来源可核实	25%	抽查引用能否打开、是否为原始来源	引用二手转述、链接打不开
口径一致性	20%	年份、币种、单位、统计范围统一	混用不同年份或 FOB/CIF
证据链完整	20%	结论含五要素（来源/时间/口径/置信度）	只有结论没有依据
方法可复现	15%	他人能否用同方法得到相似结论	检索式与筛选条件缺失
不确定披露	10%	是否列出假设、缺口与失效条件	全部结论都“高度确定”
可执行性	10%	结论能否直接指导下一步动作	通篇宏观、无具体动作
合计	100%	一票否决：引用无法核实、数据无年份	—

用法：本表可直接作为课堂评分标准；总分 80 分以上视为可用于内部决策，60 分以下需重做。

从“AI 说”到“我判断”

■ 报告里不该出现“AI 认为”，只该出现“据某来源”。

- ▶ 引用格式：来源名称 + 数据年份 + 获取日期 + 口径说明。
- ▶ 主语规范：写“据 UN Comtrade 数据”，不写“AI 分析显示”。
- ▶ 推断标注：凡不是直接来自来源的判断，明确标注为“本报告推断”。
- ▶ 责任声明：报告末尾注明编制人与复核人。

关键术语 Key Terms

引用规范 Citation Format

推断标注 Inference Flag

编制与复核 Author and Reviewer

专业责任 Professional Responsibility

⚠ 提示 Tip | 一句可记住的规则：**** 报告里每一个数字都要能被追问三层 ****——谁发布的？什么时候？什么口径？三层都答得上，这个数字才能留下。

反面案例剖析

看一个典型的“不可用结论”。

- ▶ 原句：“根据 AI 综合分析，东南亚消费电子市场前景广阔，2025 年规模约 800 亿美元，建议尽快进入。”
- ▶ 问题一：无来源、无年份口径，“AI 综合分析”不是来源。
- ▶ 问题二：800 亿美元是区域整体还是单一国家？统计范围不明。
- ▶ 问题三：“前景广阔”不可判定，无法指导任何动作。
- ▶ 问题四：没有任何风险与门槛信息，直接给出“尽快进入”。

关键术语 Key Terms

不可判定表述 Unfalsifiable Statement

范围不明 Ambiguous Scope

行动缺失 No Actionable Step

风险缺位 Missing Risk

提示 Tip | 课堂讨论：这句话在真实会议上会被追问什么？把可能的三次追问写下来，就得到了改写这份结论所需的信息清单。

I 同样的主题，改写成可用的形式。

- ▶ 改写后："A 国 2024 年该品类进口额约 X 亿美元 (UN Comtrade, CIF, HS 8518; 2026-03 获取)。
- ▶ 三年 CAGR 约 Y%，其中 2024 年增速明显放缓 (来源：目标国海关月度数据)。
- ▶ 前三大来源国合计占 Z%，集中度中等，新供应商存在进入空间。
- ▶ 主要门槛：认证周期约 8 周、关税 M%；建议先以 1-2 个 SKU 小批量试单，置信度中 (待补：2025 年全年数据、当地渠道访谈)。"

关键术语 Key Terms

可判定 Falsifiable

可执行 Actionable

置信度标注 Confidence Flag

待补信息 Missing Information

 **实战 Practice** | 对比要点：改写后的每一句都能被追问、也都能回答；每一个数字都能追溯；最后一句直接给出了下一步动作与需要补充的信息。

本节小结：可信度的三条底线

■ 把本节压缩成三句话。

- ▶ 无来源不写：任何数字必须有可点开核对的出处与年份。
- ▶ 不核实不用：抽查引用、复算数字、检查量级，三步缺一不可。
- ▶ 不确定要讲：置信度、失效条件与信息缺口，必须写进报告。

关键术语 Key Terms

无来源不写 No Source, No Claim

三重验证 Triple Verification

披露不确定 Disclose Uncertainty

专业底线 Professional Bottom Line

 图示 Diagram | 本节与第 7、8 节的关系：算法负责把数据变结构，时间序列负责把数据变趋势，而本节负责把结论变可信——三者缺一，调研都无法真正用于决策。

11

案例教学：把前七节方法串成一份调研报告

案例背景：一家典型的深圳消费电子企业

■ 案例企业为教学虚构，但设定取自深圳同类企业的常见形态。

- ▶ 企业画像：宝安某中型消费电子企业，员工约 300 人，主营蓝牙音频与充电配件。
- ▶ 现状：主要做 ODM 代工与少量自有品牌，客户集中在北美，近年来订单波动加大。
- ▶ 诉求：希望开拓 1-2 个新的海外市场，降低对单一市场的依赖。
- ▶ 资源约束：可投入的首批市场开拓预算有限，认证与试单费用需要精打细算。
- ▶ 决策问题：** 先做哪个市场？先打哪类客户？用什么产品切入？**

关键术语 Key Terms

原始设备制造 OEM

原始设计制造 ODM

市场集中度风险 Concentration

Risk

试单 Trial Order

 图示 Diagram | 案例的意义：这家企业的资源约束是真实的——预算有限、认证周期长、需要尽快看到结果。所有方法都必须服务于“在约束下做出可执行的决策”。

案例任务：交付一份目标市场调研报告

I 本讲所有方法，最终都要落到这一份报告上。

- ▶ 交付物一：目标市场短名单（2-3 个），含加权评分与进入理由。
- ▶ 交付物二：每个市场的趋势判断（处于生命周期哪个阶段，信号是否一致）。
- ▶ 交付物三：主要竞品的横向对比表与竞品地图，指出可能的产品空隙。
- ▶ 交付物四：ICP 定义 + 1 张画像卡（B2B 或 B2C 任选其一）。
- ▶ 交付物五：证据链完整的关键结论，附置信度与待验证假设。

关键术语 Key Terms

短名单 Shortlist


趋势判断 Trend Assessment

竞品地图 Competitive Map

证据链 Evidence Chain

⚠ 提示 Tip | 评分导向：报告质量不看篇幅，只看“每一个数字是否能被追问三层”与“结论是否能直接指导下一步动作”。

案例的八步 workflow



第一步：定义问题与验收标准

■ 先写清楚“什么算完成”，后面的工作才有方向。

- ▶ 决策问题：在 3 个候选市场中，选出 1 个作为 12 个月内的重点开拓对象。
- ▶ 决策标准：市场规模足够、增速为正、门槛可承受、与现有产品线匹配。
- ▶ 验收标准：结论必须有可核实来源；成本估算误差控制在 $\pm 20\%$ 以内。
- ▶ 时间约束：课堂内完成框架与关键结论，细节数据课后按同一方法补齐。

关键术语 Key Terms

决策问题 Decision Question

验收标准 Acceptance Criteria

容差 Tolerance

范围界定 Scoping

 **实战 Practice** | 课堂做法：先用 5 分钟把“决策问题 + 验收标准”写在纸上，全组确认后再动手查数据——跳过这一步的小组，通常会在中途反复返工。

第二步：数据源清单与检索式

I 把第 2 节和第 3 节的方法直接套用。

- ▶ 规模与增速：UN Comtrade、ITC Trade Map、目标国海关与统计局。
- ▶ 门槛与成本：目标国关税查询、认证机构官网、物流商报价。
- ▶ 竞争态势：目标国主流电商平台的价格带与评论数据。
- ▶ 客户名单：海关提单数据、行业协会会员名录、目标国展会参展商名单。
- ▶ 检索式：site:.de filetype:pdf (Importeur OR Distributor) Elektronik Liste。

关键术语 Key Terms

贸易数据 Trade Data

关税查询 Tariff Lookup

参展商名单 Exhibitor List

检索式 Search Query

💡 例 Example | 课堂提示：三个候选市场各查一遍，把关键数字填入同一张表（来源 + 年份 + 口径三列必须有）——这张表就是第 3 步与第 5 步的数据底座。

第三步：趋势分析（纵向）

用第 8 节的时间序列方法判断趋势是否成立。

- ▶ 分解：用 STL 或人工观察把进口额拆成趋势、季节与残差。
- ▶ 增速：计算三年 CAGR 与最近一年同比，判断是加速还是放缓。
- ▶ 变点：检查是否有结构性突变（政策、汇率、竞品进入）。
- ▶ 阶段：结合增速与渗透率判断处于导入、成长、成熟还是衰退阶段。

关键术语 Key Terms

趋势分解 Trend Decomposition

复合增长率 CAGR

变点检测 Change Point Detection

生命周期 Life Cycle

 **实战 Practice** | 课堂产出：为三个候选市场各画一张三年趋势图，标注数据来源与年份，并写出“处于哪个阶段、依据是什么”一句话结论。

第四步：横向竞品分析

用第 7 节的机器学习方法看清竞争格局。

- ▶ 聚类：按价格、评分、评论数把竞品分成 3-4 群，看自己落在哪一群。
- ▶ 主题：对差评做主题归纳，找出对手口碑最弱的维度。
- ▶ 地图：用两个主成分画竞品地图，圈出人少的价格—性能区间。
- ▶ 异常：剔除刷评与异常定价样本后再计算平均评分。

关键术语 Key Terms

聚类分析 Cluster Analysis

主题归纳 Topic Synthesis

竞品地图 Competitive Map

异常剔除 Outlier Removal

 **实战 Practice** | 课堂产出：一张竞品对比表（10-15 个竞品）+ 一句结论：“在 X 价格带、Y 规格组合上，竞争相对稀疏、且对手口碑存在明显短板。”

第五步：市场筛选评分卡

I 把前三步的结果汇成一张可讨论的打分表。

- ▶ 五个维度：市场规模、市场增速、竞争强度、进入门槛、自身匹配度。
- ▶ 权重由小组事先确定并说明理由（例如起步期更看重“门槛低”）。
- ▶ 每一分都要写依据：哪个来源、哪个年份、什么口径。
- ▶ 总分相近时看短板：哪一项一旦不达标，会导致项目失败。

关键术语 Key Terms

加权评分 Weighted Scoring

权重约定 Weight Agreement

短板分析 Bottleneck Analysis

敏感性 Sensitivity

 **实战 Practice** | 课堂讨论：如果改变权重后第一名发生变化，说明结论不稳定——这时应把两个市场并列，并说明各自适用的前提条件。

第六步：客户画像

I 从“哪个市场”落到“找谁”。

- ▶ 定义 ICP：3-5 条硬性条件（规模、渠道类型、品类重合度、是否已有中国供应商）。
- ▶ 建立画像卡：字段完整、来源可查、含决策链角色与关注点。
- ▶ 找到对接人：从公司官网、行业名录与公开组织信息中确认角色。
- ▶ 回测校准：用企业现有成交客户检验画像条件是否合理。

关键术语 Key Terms

硬性条件 Hard Criteria

画像卡 Profile Card

决策链角色 Buying Role

回测 Backtest

 **实战 Practice** | 课堂产出：一张 ICP 定义 + 一张画像卡。注意：画像卡里每条字段都要能追溯到来源，没有来源的字段写“未提及”。

第七步：结论与证据链

I 把结论写成“可被追问三层”的形式。

- ▶ 结论句式：市场 + 年份 + 数字 + 口径 + 来源 + 置信度。
- ▶ 推断标注：凡不是直接来自来源的判断，明确写“本报告推断”。
- ▶ 每一条推荐都要附上“依据哪张表、哪一步分析”。
- ▶ 无法核实的内容宁可删除，也不要保留模糊表述。

关键术语 Key Terms

结论句式 Claim Template

推断标注 Inference Flag

可追问 Traceable

删除而非模糊 Delete, Don't Vague

💡 例 Example | 对照：把“东南亚市场前景广阔”改写为“A 国 2024 年该品类进口额约 X 亿美元（来源/口径/年份），三年 CAGR 约 Y%，前三大来源国合计占 Z%；建议以 1-2 个 SKU 小批量试单，置信度中”。

第八步：风险与待验证假设

一份好报告的收尾，是告诉读者“哪里可能错”。

- ▶ 列出 3–5 条待验证假设（如“当地消费者愿意为此功能多付 20%”）。
- ▶ 每条假设写明验证方法（查数据、渠道访谈、小批量试单）。
- ▶ 列出主要风险：认证延期、汇率波动、渠道冲突、平台规则变化。
- ▶ 给出停止条件：出现什么情况应当立刻收手。

关键术语 Key Terms

待验证假设 Assumption to Validate

验证方法 Validation Method

风险清单 Risk Register

停止条件 Stop Condition

提示 Tip | 课堂要求：所有小组都必须写“停止条件”。敢于写下何时退出，说明真的想清楚了成本与风险。

报告结构与课堂评分标准

报告部分	权重	应包含内容	评分要点
问题与标准	10%	决策问题、验收标准、范围	是否明确可判定
数据与来源	25%	数据源清单、口径表、检索式	能否复现与核实
趋势分析	20%	三年趋势、阶段判断、变点	是否用对时间序列方法
竞品分析	20%	对比表、分群、弱点清单	结论能否被业务解释
市场筛选	15%	加权评分卡与依据	权重是否事先确定
画像与结论	10%	ICP、画像卡、下一步动作	是否可执行
一票否决	—	引用无法核实、数据无年份、无停止条件	出现即不及格

本表即第 10 节“可信度评分卡”在案例中的具体应用。

课堂演练方式与时间安排

■ 这是一次带做的案例教学，不是课后作业。

- ▶ 分组：4-5 人一组，建议分工为“数据采集 / 趋势分析 / 竞品分析 / 整合撰写”。
- ▶ 时间分配（建议）：定问题与检索式 15 分钟 → 查数据 30 分钟 → 分析与建模 35 分钟 → 撰写结论 20 分钟 → 小组交叉互评 20 分钟。
- ▶ 工具：Excel 或在线表格即可；有编程基础的同学可以写脚本处理评论数据。
- ▶ 交叉互评：用上一页评分表互评，重点挑“来源是否可核实”与“结论是否可执行”。
- ▶ 教师点评：重点讲三件事——口径是否对齐、算法结论是否被业务解释、停止条件是否合理。

关键术语 Key Terms

分组协作 Group Work

交叉互评 Peer Review

带做案例 Guided Case

课堂产出 In-class Deliverable

 **实战 Practice** | 说明：本讲不布置课后作业。案例在课堂上完成框架与关键结论；课后如需完善，可按同一方法补齐数据，但不作为考核要求。

常见问题答疑

■ 这些是往届课堂上最常被问到的几个问题。

- ▶ 数据查不到怎么办？→ 换口径或换来源，并在报告中说明“该数据未获取”，不要用 AI 生成替代。
- ▶ 三个市场都差不多怎么选？→ 看短板与自身匹配度；结论不稳定时并列两个方案并写明前提。
- ▶ 评论数据太多处理不完？→ 先抽样 200 条做主题归纳，再用抽样结论去检验全量。
- ▶ 不会写代码能做吗？→ 能。本讲所有方法都可以用表格与人工抽样近似实现，代码只是提高效率。
- ▶ 时间不够怎么办？→ 优先完成“问题定义 + 数据来源表 + 一张趋势图 + 一句可执行结论”这四件事。

关键术语 Key Terms

数据缺口 Data Gap

抽样 Sampling

最小可行产出 Minimum Viable Output

方法近似 Method Approximation

⚠ 提示 Tip | 最后提醒：案例的目标不是做出一份完美的报告，而是让你亲身体会“AI 帮了忙，但核实仍然要靠自己”这一件事。

12

一页流程图、一份清单、一个提醒

一页流程图：从问题到决策

本讲全部内容，可以压缩成这条链路。

- ▶ 定义问题与验收标准 → 选择数据源 → 采集与口径对齐。
- ▶ 纵向：时间序列分解、增速与变点 → 趋势与生命周期判断。
- ▶ 横向：向量化、聚类、降维、主题、异常 → 竞品分群与弱点清单。
- ▶ 收敛：五维评分卡 → 市场短名单；ICP 与画像卡 → 目标客户名单。
- ▶ 交付：证据链完整的结论 + 待验证假设 + 停止条件。

关键术语 Key Terms

纵向分析 Longitudinal

横向分析 Cross-sectional

评分卡 Scorecard

证据链 Evidence Chain



图示 Diagram | 贯穿全讲的一句话：算法负责缩小范围，人负责定义问题与做出判断；而证据链负责让判断站得住。

本讲数据源与工具清单（完整网址）

用途	官方入口（完整网址）	打开后先看什么
国别宏观指标	https://data.worldbank.org/	人口、收入、物流绩效指数
贸易流向（品类）	https://comtradeplus.un.org/	按 HS 编码的进出口额与来源国
贸易分析（易读版）	https://www.trademap.org/	国别与品类的增速与集中度
关税与规则	https://www.wto.org/english/res_e/statis_e/statis_e.htm	关税水平与贸易规则背景
投资与海运	https://unctadstat.unctad.org/	海运连通性与投资数据
汇率与宏观预测	https://www.imf.org/en/Data	汇率与国际收支
中国报关与统计	http://www.customs.gov.cn/	报关政策与统计月报
国别贸易指南	http://www.mofcom.gov.cn/	政策、合规与市场指南
美国进口明细	https://dataweb.usitc.gov/	HS 编码 × 国别 × 金额
欧盟统计	https://ec.europa.eu/eurostat	成员国贸易与消费统计
搜索趋势	https://trends.google.com/trends/	相对热度与拐点（非绝对规模）

来源：入口地址以官方站点为准；部分站点在校园网环境下可能需代理访问，建议课前核对一次并截图存档。

本讲结论：三件事

如果只记住三句话，记住这三句。

- ▶ 数据源决定上限：来源分级、口径对齐、免费优先，是调研质量的地基。
- ▶ 算法决定效率：横向用聚类与主题看清竞争，纵向用时间序列看清趋势。
- ▶ 证据链决定可信度：无来源不写、不核实不用、不确定要讲——这是全部方法的落点。

关键术语 Key Terms

数据源分级 Source Tiering

方法效率 Method Efficiency

证据链 Evidence Chain

专业底线 Professional Bottom Line

 **实战 Practice** | 下讲预告：第二讲进入“客户开发与市场进入策略”——线索挖掘、多语种开发信、社媒触达、线索评分，以及市场进入模式的选择与定价体系设计。

想进一步深入的方向。

- ▶ 贸易数据：UN Comtrade 与 ITC Trade Map 的官方使用指南。
- ▶ 时间序列：任何一本《时间序列分析》教材的前四章（分解、平滑、ARIMA、评估）。
- ▶ 文本分析：主题模型与嵌入模型的基础教程；中文文本预处理要点。
- ▶ 数据合规：GDPR 与个人信息保护法中关于商业数据使用的条款。
- ▶ 建议动手：用本课案例的数据，自己跑一遍分解与聚类，比读十篇文章更有用。

关键术语 Key Terms

延伸学习 Further Reading

动手实践 Hands-on

合规条款 Compliance Clause

数据伦理 Data Ethics

⚠ 提示 Tip | 最后一句：本讲教的方法都会过时，但“先核对来源、再下结论”这个习惯不会。

谢谢

下一讲：海外客户挖掘、开发邮件与市场进入策略。

模块三 | 第一讲 | 海外市场调研智能化